
ForL0 State Backend

测试用例及报告

2026 年 4 月

目 录

1	文档概述	1
1.1	测试平台	1
1.2	测试范围	1
1.3	测试结果摘要	1
2	测试环境	2
2.1	鲲鹏服务器（主测试平台）	3
2.2	Intel 参考平台	3
3	功能测试用例	3
3.1	状态类型正确性测试（FT）	3
3.2	Checkpoint 与 Savepoint 测试（CP / CO）	4
3.3	异步快照与快照一致性测试（AS / SC）	4
3.4	窗口聚合测试（WA）	5
3.5	MiniCluster 端到端测试（MC）	5
3.6	Rescale 测试（RS）	6
3.7	状态语义单元测试（SE）	6
3.8	Hot Cache 集成测试（HC）	7
3.9	Java 单元测试（UT）	7
3.10	C++ 原生引擎单元测试（NT）	7
3.11	功能测试覆盖矩阵	9
4	功能测试报告	9
4.1	测试执行方式	9
4.2	测试结果	10
4.3	结果说明	10
5	性能基准测试	10
5.1	WordCount Benchmark	11
5.1.1	测试设计	11
5.1.2	测试执行	11

5.2	NexMark Benchmark	11
5.2.1	测试设计	11
5.2.2	测试执行	12
6	性能基准测试报告	12
6.1	WordCount Benchmark 报告（鲲鹏）	12
6.1.1	测试配置	12
6.1.2	吞吐量网格	12
6.1.3	数据明细	13
6.1.4	数据解读	14
6.2	WordCount Benchmark 报告（Intel 参考平台）	15
6.2.1	测试配置	15
6.2.2	吞吐量网格	15
6.2.3	数据明细	16
6.2.4	数据解读	17
6.2.5	微架构剖析（Intel VTune）	18
6.2.6	数据解读	19
6.3	NexMark Benchmark 报告	19
6.3.1	鲲鹏平台：TM 限制 4 核	20
6.3.2	Intel 参考平台：核数不限，三档 TaskManager 内存	20
6.3.3	数据解读	20
6.4	Flink 状态算子级 JMH 基准（Intel 参考平台）	21
7	测试结论	22

1 文档概述

本文档给出 ForL0 State Backend 的测试用例清单与测试执行结果，涵盖功能测试、C++ 原生引擎单元测试，以及基于 WordCount 与 NexMark 的性能基准测试。功能测试用于验证与 Flink 状态后端接口的语义一致性；性能基准测试用于量化在鲲鹏服务器与 Intel 参考平台上的实际收益。

1.1 测试平台

项目	配置
生产目标平台	鲲鹏系列处理器 / openEuler / aarch64
参考对比平台	Intel x86_64 服务器（仅用于 NexMark 场景下 GC 压力的横向对照）
JDK	BiSheng JDK 1.8（aarch64） / OpenJDK 1.8（x86_64）
Apache Flink	1.20.3
ForL0 State Backend	1.0-SNAPSHOT
原生引擎	libforl0_engine.so（aarch64，NEON 启用）
L0 依赖	libl0mempool.so、/dev/hisi_l0 设备节点（运行期可选）

1.2 测试范围

- **功能测试：**覆盖 ValueState、ListState、MapState、ReducingState、AggregatingState 五类 KeyedState，以及 Checkpoint、Savepoint、窗口聚合、倾斜负载、SPI 自动发现等运行时行为。
- **原生引擎单元测试：**C++ 层的 SwissTable、StateTable、CoW 快照、Checkpoint 往返、类型布局解析、TimeWindow namespace、TypedInnerMap 等核心数据结构。
- **性能基准测试：**WordCount 纯状态微基准与 NexMark 端到端流处理查询集。

1.3 测试结果摘要

全部功能测试用例与原生引擎单元测试通过，通过率 100%。性能基准测试的详细数据见 § 5。

测试套件	用例数	通过	失败	通过率
ForL0StateTypesITCase	8	8	0	100%
ForL0CheckpointSavepointITCase	5	5	0	100%
ForL0CheckpointOptimizationITCase	3	3	0	100%
ForL0WindowAggregateITCase	3	3	0	100%
ForL0MiniClusterITCase	5	5	0	100%
ForL0RescaleITCase	3	3	0	100%
ForL0AsyncSnapshotITCase	2	2	0	100%
ForL0SnapshotConsistencyITCase	3	3	0	100%
ForL0StateSemanticsTest	13	13	0	100%
HotCacheIntegrationTest	8	8	0	100%
ListAppendDebugTest	1	1	0	100%
Java 侧合计	54	54	0	100%
swiss_table_test	28	28	0	100%
type_layout_parser_test	20	20	0	100%
time_window_namespace_test	18	18	0	100%
checkpoint_round_trip_test	12	12	0	100%
state_table_cow_test	12	12	0	100%
typed_inner_map_test	12	12	0	100%
hot_cache_phase_b_test	11	11	0	100%
hot_cache_test	10	10	0	100%
hot_cache_manager_test	7	7	0	100%
C++ 原生引擎合计	130	130	0	100%
合计	184	184	0	100%

2 测试环境

除特别说明外，所有性能基准测试均在容器化的 Flink Standalone 集群中运行。**默认集群拓扑：3 个 Docker 容器——1 个 JobManager（2 核 / 8 GB）+ 2 个 TaskManager（各 4 核 / 16 GB），总任务并行度 8。**集群由 docker/docker-compose.yml 一键拉起，镜像内预置 ForL0 State Backend 的 JAR 与原生库，JobManager 与 TaskManager 之间通过容器网络通信。表格中所列” TM 内存”、” 核数限制” 等数值即为单个 TaskManager 容器的资源上限。

2.1 鲲鹏服务器（主测试平台）

项目	配置
处理器	鲲鹏系列处理器（aarch64）
操作系统	openEuler
内核特性	支持鲲鹏 L0 Cache 的内核驱动及 /dev/hisi_l0 设备节点
JDK	BiSheng JDK 1.8, JAVA_HOME=/opt/bisheng-jdk1.8.0
Maven	3.6+
Flink	1.20.3 Standalone 集群（Docker Compose）
默认集群拓扑	1 JM (2 核 / 8 GB) + 2 TM (各 4 核 / 16 GB), 总并行度 8
Heap / Managed 内存	Heap 11.7 GB, Managed 512 MB (NexMark 场景)

2.2 Intel 参考平台

Intel 参考平台仅用于 NexMark 场景下 GC 压力的横向对照，以及 Flink 状态算子级别的 JMH 微基准。该平台不依赖 L0 硬件。

项目	配置
处理器	Intel x86_64 服务器
操作系统	Linux
默认集群拓扑	1 JM (2 核 / 8 GB) + 2 TM (各 4 核 / 16 GB), 总并行度 8
TaskManager 内存	默认 16 GB; NexMark 下另扫描 18/20 GB 两档 (JVMHeap 12/14/15 GB)
核数限制	默认每 TM 4 核, 如需扩充案例将在对应节说明

3 功能测试用例

功能测试用例覆盖 11 个 Java 测试类共 54 个 @Test 方法，外加 9 个 C++ 测试套件共 130 个 TEST 用例，总计 184 项。下文按测试主题分组列出全部用例。

3.1 状态类型正确性测试 (FT)

测试类 ForL0StateTypesITCase（基于 Flink MiniCluster），覆盖五类 KeyedState 的读写路径与若干常用类型组合。

编号	用例名称	测试方法	主要验证点
FT-01	ValueState	testValueState()	6 条 记 录 / 3 个 key (a:3,b:2,c:1) , 计数累加
FT-02	ListState (String)	testListState()	6 条 String 记录, 验证追加顺序
FT-03	ReducingState	testReducingState()	6 条 Integer 记录, 验证求和归约
FT-04	AggregatingState	testAggregatingState()	自定义聚合函数, 聚合结果匹配
FT-05	MapState (Generic)	testMapState()	String → Integer 的 5 条 Tuple 记录
FT-06	MapState (Long, Long)	testMapStateLongLong()	Long → Long 类型特化路径
FT-07	MapState (Long, String)	testMapStateLongString()	Long → String 混合宽度路径
FT-08	ListState (Long)	testListStateLong()	5 条 Long 记录 / 2 个 key

3.2 Checkpoint 与 Savepoint 测试 (CP / CO)

CP 系 列 对 应 ForL0CheckpointSavepointITCase (5 项) , CO 系 列 对 应 ForL0CheckpointOptimizationITCase (3 项) 。

编号	用例名称	测试方法	主要验证点
CP-01	周期性 Checkpoint	testPeriodicCheckpointCompletes()	200 ms 间隔, ExactlyOnce 模式, chk-* 目录生成
CP-02	Savepoint 与恢复	testSavepointAndRestore()	1000 条记录 → Savepoint → 恢复 → 数据一致
CP-03	Savepoint 精确状态	testSavepointAndRestore_ExactState()	恢复后 count 值精确等于 N
CP-04	外部化 Checkpoint	testExternalizedCheckpoint_ExactState()	RETAIN_ON_CANCELLATION 后文件保留
CP-05	多状态类型 Savepoint 兼容	testSavepointCompatibilityMultiStateTypes()	Value / List / Map 混合 + 多 namespace
CO-01	多 Checkpoint 周期	testMultipleCheckpointCycles()	连续多轮 Checkpoint 触发与确认
CO-02	多状态类型恢复	testSavepointRestoreWithMultipleStateTypes()	500 条记录混合状态操作恢复
CO-03	大规模 Key 恢复	testSavepointRestoreWithManyKeys()	大规模 Key 分布式 Savepoint 恢复

3.3 异步快照与快照一致性测试 (AS / SC)

AS 系列对应 ForL0AsyncSnapshotITCase, 验证异步快照路径下的访问安全性; SC 系列对应 ForL0SnapshotConsistencyITCase, 验证快照前后状态一致性。

编号	用例名称	测试方法	主要验证点
AS-01	异步 Checkpoint 后继 续累加	asyncCheckpointRestore_AllowsContinuedAccumulation()	异步快照过程中状态可继续 读改写并完成恢复
AS-02	快照中欠写恢复	asyncCheckpointUnderWrites_RestorePreservesNonZeroState()	异步窗口内尚未确认的写入 在恢复后保持非零
SC-01	启用缓存的快照恢复	snapshotRestore_CacheEnabled_PreservesValueAndList()	启用 L0 Cache 时 Value/ List 状态恢复一致
SC-02	单热点 Key 快照恢复	snapshotRestore_CacheEnabled_SingleHotKey()	单热点 Key 在缓存重建后值 正确
SC-03	清空后快照	snapshotAfterClear_PreserveEmpty()	clear() 后 Snapshot 恢复仍 为空

3.4 窗口聚合测试 (WA)

测试类 ForL0WindowAggregateITCase。

编号	用例名称	测试方法	主要验证点
WA-01	滑动窗口聚合	testSlidingWindowAggregateWithTuple2LongLong()	1000 ms 窗口 / 200 ms 滑 动, Tuple2<Long,Long> 累加 器
WA-02	高负载窗口聚合	testHighLoadWindowAggregate()	10 000 条记录 / 1000 个 key
WA-03	窗口 Checkpoint 恢复	testWindowAggregateCheckpointRestore()	无界数据源 + Checkpoint + 重启

3.5 MiniCluster 端到端测试 (MC)

测试类 ForL0MiniClusterITCase, 覆盖 SPI 加载、倾斜负载、滑动窗口、压力场景。

编号	用例名称	测试方法	主要验证点
MC-01	SPI 加载 ValueState	testValueStateWordCountWithSPI()	SPI 自动发现并加载 ForL0 State Backend
MC-02	高负载倾斜 ValueState	testSkewedHighLoadValueState()	2000 万记录 / 100 万 key / 80% 流量集中于 1% 热点
MC-03	大规模状态压力	testLargeScaleStateStress()	大规模 Key 持续读改写下的 稳定性
MC-04	滑动窗口 WordCount	testSlidingEventTimeWindowWordCount()	EventTime 滑动窗口 + Val- ueState
MC-05	滑动窗口 WordCount 压力	testSlidingEventTimeWindowWordCount_Stress()	高速率事件流下窗口聚合稳定 性

3.6 Rescale 测试 (RS)

测试类 ForL0RescaleITCase, 验证作业并行度变化时 Key Group 重新分配与状态迁移。

编号	用例名称	测试方法	主要验证点
RS-01	缩容 2 → 1	testScaleDown_2_to_1()	并行度从 2 降为 1, 状态合并后语义保持
RS-02	扩容 1 → 2	testScaleUp_1_to_2()	并行度从 1 扩为 2, Key Group 重分配正确
RS-03	扩容 2 → 4	testScaleUp_2_to_4()	并行度从 2 扩为 4, 状态完整性保持

3.7 状态语义单元测试 (SE)

测试类 ForL0StateSemanticsTest, 针对状态接口的边界语义 (空值、null 参数、迭代器、计数等) 逐项验证。

编号	用例名称	测试方法	主要验证点
SE-01	ValueState 默认值	valueStateDefaultIsNullForEmptyKey()	未初始化 key 读取返回 null
SE-02	ValueState update(null)	valueStateUpdateNullClearsEntry()	update(null) 等价于 clear()
SE-03	ValueState clear 同步缓存	valueStateClearRemovesFromBothCacheAndTable()	clear() 同步移除 L0 缓存与底层表项
SE-04	多个 ValueState 独立性	multipleValueStatesAreIndependent()	同一 key 下多个 ValueState 互不干扰
SE-05	ListState add(null) 抛出	listStateAddNullThrows()	单元素 null 入参抛出 NPE
SE-06	ListState addAll(null)	listStateAddAllNullArgumentThrows()	列表 null 入参抛出 NPE
SE-07	ListState addAll 含 null	listStateAddAllListContainingNullThrows()	列表元素含 null 抛出 NPE
SE-08	ListState update(null)	listStateUpdateNullArgumentThrows()	update(null) 抛出 NPE
SE-09	ListState update(empty)	listStateUpdateEmptyClearsState()	update([]) 等价于 clear()
SE-10	MapState 允许 null 值	mapStateAllowsNullValue()	put(k, null) 允许, 迭代时可见
SE-11	getKeys 反映已注册 key	getKeysReflectsRegisteredKeys()	getKeys() 与实际持有 key 集合一致
SE-12	applyToAllKeys 唯一访问	applyToAllKeysVisitsEachKeyExactlyOnce()	applyToAllKeys() 不重复访问
SE-13	KV 计数与增删一致	numKeyValueStateEntriesMatchesInsertsAndDeletes()	numKeyValueStateEntries() 与累计增删一致

3.8 Hot Cache 集成测试 (HC)

测试类 `HotCacheIntegrationTest`, 验证 L0 Cache 在不同标量类型组合下的行为一致性、可观测指标以及在无 L0 平台上的兜底关闭路径。

编号	用例名称	测试方法	主要验证点
HC-01	long×long 等价性	<code>longLongValueStateBehavesIdenticallyWithCacheOnOrOff()</code>	缓存开/关结果完全一致
HC-02	int×long 路径	<code>intLongValueStateRoundtrip()</code>	int → long 类型回环一致
HC-03	int×double 路径	<code>intDoubleValueStateRoundtrip()</code>	int → double 类型回环一致
HC-04	long×double 路径	<code>longDoubleValueStateRoundtrip()</code>	long → double 类型回环一致
HC-05	无 L0 平台门控	<code>managerGateClosesOnPlatformsWithoutL0()</code>	设备不可用时 Manager 自动关闭
HC-06	配置禁用时指标为零	<code>managerMetricsAreZeroWhenDisabledByConfig()</code>	显式禁用后所有缓存指标恒为 0
HC-07	扩展指标聚合	<code>extendedManagerMetricsExposeAggregateCounters()</code>	命中 / 替换 / 失效计数器正确聚合
HC-08	Manager 失活时再均衡安全	<code>rebalanceIsSafeWhenManagerInactive()</code>	Manager 关闭状态下再均衡不抛异常

3.9 Java 单元测试 (UT)

编号	用例名称	测试方法	主要验证点
UT-01	ListState 追加路径	<code>testListAppendDoesNotCreateNewArrayList()</code>	ListState 追加不重复创建 ArrayList

3.10 C++ 原生引擎单元测试 (NT)

通过 CMake 构建的 GoogleTest 套件, 源码位于 `src/main/native/test/`, 由 `ctest` 统一驱动。本节按套件汇总, 每个套件下用例数即对应 `TEST/TEST_F` 数量。

编号	测试套件	用例数	覆盖范围
NT-01	swiss_table_test.cpp	28	插入 / 查找 / 删除 / 迭代 / rehash / grow / 复合负载
NT-02	state_table_cow_test.cpp	12	Copy-On-Write 快照、写时分裂、并发读视图
NT-03	checkpoint_round_trip_test.cpp	12	Checkpoint 序列化 → 反序列化 → 一致性比对
NT-04	type_layout_parser_test.cpp	20	Java 类型描述符解析与 C++ 内存布局映射
NT-05	time_window_namespace_test.cpp	18	TimeWindow namespace 增删、过期清理
NT-06	typed_inner_map_test.cpp	12	类型化 Inner Map 的 put / remove / iterate
NT-07	hot_cache_test.cpp	10	L0 Hot Cache 基本路径与命中 / 替换
NT-08	hot_cache_phase_b_test.cpp	11	Hot Cache Phase B 增量路径与回写
NT-09	hot_cache_manager_test.cpp	7	Hot Cache Manager 生命周期、再均衡
原生引擎合计		130	

3.11 功能测试覆盖矩阵

功能特性	覆盖的测试用例
ValueState 读写 / 边界	FT-01, SE-01..04, MC-01, MC-02, MC-04
ListState 读写 / 边界	FT-02, FT-08, SE-05..09, UT-01
MapState 读写 / 边界	FT-05, FT-06, FT-07, SE-10
ReducingState / AggregatingState	FT-03, FT-04
状态遍历与计数	SE-11, SE-12, SE-13
Checkpoint 生成 / 多周期	CP-01, CP-04, CO-01
Savepoint 触发与恢复	CP-02, CP-03, CP-05, CO-02, CO-03
异步快照路径	AS-01, AS-02
快照前后一致性	SC-01, SC-02, SC-03
多状态类型混合 / 多 namespace	CP-05, CO-02
时间窗口聚合	WA-01, WA-02
窗口 + Checkpoint	WA-03
高负载 / 热点 key	MC-02, MC-03, MC-05
SPI 自动发现	MC-01
并行度变化 (Rescale)	RS-01, RS-02, RS-03
L0 Cache 类型组合 / 指标 / 兜底	HC-01..08
SwissTable / NEON SIMD	NT-01
CoW 快照一致性	NT-02
Checkpoint 序列化往返	NT-03
类型布局 / TimeWindow / Inner Map	NT-04, NT-05, NT-06
Hot Cache 路径 / 管理器	NT-07, NT-08, NT-09

4 功能测试报告

4.1 测试执行方式

在鲲鹏服务器上运行 Java 侧的全量集成测试与 C++ 原生引擎测试：

```
# Java 侧：集成测试 + 单元测试
cd $PROJECT_ROOT
mvn test -Djava.library.path=src/main/resources/native

# C++ 侧：原生引擎单元测试
cd $PROJECT_ROOT/src/main/native
mkdir -p build && cd build
cmake .. -DFORLO_BUILD_TESTS=ON -DCMAKE_BUILD_TYPE=Release
make -j$(nproc)
ctest --output-on-failure
```

4.2 测试结果

全部 184 项测试用例（Java 54 项 + C++ 130 项）执行通过，无失败项与跳过项。各测试套件的通过情况已在 § 1.3 汇总。完整 JUnit 报告位于 `target/surefire-reports/`，CTest 报告位于 `src/main/native/build/Testing/`。

4.3 结果说明

- **状态类型**：5 类 KeyedState 全部通过，包含 MapState<Long,Long>、MapState<Long,String> 与 ListState<Long> 的特化路径。
- **状态语义边界**：13 项 ForL0StateSemanticsTest 用例覆盖默认值、null 参数、clear() 与缓存同步、getKeys()、applyToAllKeys()、numKeyValueStateEntries() 等接口契约。
- **容错机制**：周期性 Checkpoint、Savepoint、外部化 Checkpoint、异步快照（AS-01/02）、快照一致性（SC-01..03）以及多周期 Checkpoint（CO-01）的触发、恢复、状态一致性均满足 ExactlyOnce 语义。
- **并行度变化**：RS-01..03 验证缩容 2→1、扩容 1→2 / 2→4 场景下 Key Group 重新分配与状态迁移的正确性。
- **窗口**：EventTime 滑动窗口在高负载（10 000 条记录 / 1000 个 key）以及窗口跨 Checkpoint 重启场景下行为正确。
- **倾斜负载与压力**：MC-02 用例下 80% 流量集中于 1% 的热点 key，2000 万条记录结束后所有 key 状态精确匹配；MC-03 / MC-05 在大规模状态与高速率事件流下保持稳定。
- **L0 Cache**：HC-01..08 验证缓存开/关等价性、4 类标量类型组合、无 L0 平台兜底关闭、扩展指标聚合，确保启用与禁用路径的语义对齐。
- **SPI 加载**：Flink 通过 SPI 机制自动发现并加载 ForL0 State Backend，无需额外配置（MC-01）。
- **原生引擎**：9 个 GoogleTest 套件、130 项用例覆盖 SwissTable、CoW、序列化、类型布局、TimeWindow namespace、TypedInnerMap、Hot Cache 主路径与管理器，全部通过。

5 性能基准测试

性能基准测试由两部分组成：WordCount 纯状态微基准用于隔离状态后端对 ValueState 读写路径的影响；NexMark 端到端查询集用于评估在真实流处理负载（窗口聚合、会话窗口、TopN、去重、双流 Join 等）下的综合收益。

5.1 WordCount Benchmark

5.1.1 测试设计

WordCount 基准构造了最紧凑的 ValueState 读改写循环，尽量排除窗口、定时器、侧输出等其他算子开销。拓扑结构为：

SkewedWordSource → KeyedProcessFunction (value() → +1 → update()) → MetricsSink

参数	取值	说明
num_keys	1 M, 2 M, 4 M, 6 M, 8 M, 10 M	key 基数扫描
skew_factor	0, 0.2, 0.4, 0.6, 0.8, 1.0	Zipf 倾斜因子扫描
num_records	2 000 000 000	单次运行 20 亿条记录
arrival_rate	0	无限速
parallelism	8	并行度
checkpoint_interval	0	Checkpoint 关闭，最大吞吐量

扫描组合共 $6 \times 6 = 36$ 组，每组在 HashMapStateBackend 与 ForL0 State Backend 下各运行一次，记录总吞吐量 throughput。

5.1.2 测试执行

```
cd benchmark/scripts
# 二维网格扫描 (kunpeng 已完成)
python sweep_wordcount_grid.py

# 单独运行一组对比
python run_benchmark.py --test wordcount --backend all \
    --num-keys 1000000 --skew 0.0
```

原始结果以 JSON 存储于 results/kunpeng/wordcount_sweep/raw/；绘图输出在 results/kunpeng/wordcount_sweep/figures/。

5.2 NexMark Benchmark

5.2.1 测试设计

NexMark 基于在线拍卖场景，包含 Person / Auction / Bid 三类事件（比例 1 : 3 : 46）。选取具备代表性的 8 个有状态查询进行测试：

查询	事件数	状态类型	典型负载特征
q4	80 000 000	窗口聚合	分类平均价格
q5	80 000 000	滑动窗口	热门商品
q8	100 000 000	会话窗口	新用户监控
q9	40 000 000	双流 Join	中标结果
q11	80 000 000	会话窗口	用户会话
q18	80 000 000	去重	最近关闭拍卖
q19	80 000 000	TopN	拍卖 TOP-10 价格
q20	60 000 000	分组聚合	拍卖价格分段

5.2.2 测试执行

```
cd benchmark/scripts
# 全查询集对比
python run_benchmark.py --test nexmark --backend all

# 指定查询 + 指定后端
python run_benchmark.py --test nexmark --backend forl0 --query q4,q19,q20
```

6 性能基准测试报告


6.1 WordCount Benchmark 报告（鲲鹏）

6.1.1 测试配置

配置项	取值
平台	鲲鹏服务器, openEuler, aarch64
并行度	8
num_keys 扫描	{1 M, 2 M, 4 M, 6 M, 8 M, 10 M}
skew_factor 扫描	{0, 0.2, 0.4, 0.6, 0.8, 1.0}
每组记录数	2 000 000 000
Checkpoint	关闭
L0 Cache	启用
测试轮数	完整网格扫描 2 轮（以第 2 轮稳定值为准）


6.1.2 吞吐量网格

WordCount Throughput — HashMapStateBackend
best: num_keys=1M, skew=1, throughput=0.975 M/s/core



(a) HashMapStateBackend

WordCount Throughput — ForL0StateBackend
best: num_keys=1M, skew=0, throughput=0.918 M/s/core



(b) ForL0 State Backend

图1 鲲鹏平台 WordCount 在 $(num_keys, skew_factor)$ 网格上的吞吐量对比: (a) HashMapStateBackend, (b) ForL0 State Backend。




图2 ForL0 State Backend 相对 HashMapStateBackend 的吞吐量比值（鲲鹏）

6.1.3 数据明细

下表给出 36 组扫描点的吞吐量（单位：Mrecords/sec）及 ForL0 State Backend 相对 HashMapStateBackend 的比值。

num_keys	skew	HashMap	ForL0	比值	时间差 (s)
1 M	0.0	7.618	7.342	0.964	9.88
1 M	0.2	6.203	6.027	0.972	9.39
1 M	0.4	6.113	6.010	0.983	5.62
1 M	0.6	6.050	6.207	1.026	-8.35
1 M	0.8	6.197	6.087	0.982	5.87
1 M	1.0	7.797	6.859	0.880	34.95
2 M	0.0	7.178	7.053	0.983	4.96
2 M	0.2	5.918	5.820	0.983	5.69
2 M	0.4	6.079	5.807	0.955	15.38
2 M	0.6	6.027	6.023	0.999	0.22
2 M	0.8	6.046	6.003	0.993	2.37
2 M	1.0	7.718	6.945	0.900	28.82
4 M	0.0	6.928	6.626	0.956	13.18
4 M	0.2	5.789	5.624	0.971	10.15
4 M	0.4	5.867	5.662	0.965	12.31
4 M	0.6	5.666	5.675	1.002	-0.57
4 M	0.8	5.885	5.744	0.976	8.37
4 M	1.0	7.152	6.858	0.959	11.96
6 M	0.0	6.708	6.477	0.966	10.62
6 M	0.2	5.807	5.497	0.947	19.39
6 M	0.4	5.731	5.509	0.961	14.08
6 M	0.6	5.667	5.509	0.972	10.13
6 M	0.8	5.881	5.536	0.941	21.22
6 M	1.0	7.154	6.732	0.941	17.49
8 M	0.0	6.768	6.286	0.929	22.64
8 M	0.2	5.723	5.402	0.944	20.79
8 M	0.4	5.722	5.434	0.950	18.49
8 M	0.6	5.641	5.411	0.959	15.11
8 M	0.8	5.843	5.596	0.958	15.13
8 M	1.0	6.618	6.725	1.016	-4.80
10 M	0.0	6.786	6.003	0.885	38.38
10 M	0.2	5.854	5.440	0.929	26.06
10 M	0.4	5.619	5.494	0.978	8.09
10 M	0.6	5.693	5.522	0.970	10.88
10 M	0.8	5.659	5.659	1.000	-0.02
10 M	1.0	6.972	6.837	0.981	5.68

6.1.4 数据解读

- **两侧吞吐量基本对齐。**36 组扫描中，ForL0 State Backend 与 HashMapStateBackend 的吞吐量比值均集中在 0.88–1.03 区间，平均比值约 0.96。考虑到 ForL0 State Backend

需要跨 JNI 完成每次 ValueState 读改写，此差距可归因于 JNI 调用自身的常量开销，而非哈希索引本身。

- **微基准无法暴露 ForL0 State Backend 的主要收益来源。** WordCount 的单条记录仅执行 `value() → +1 → update()`，整个负载为纯访问性循环，无 GC 压力、无复杂状态组合、无窗口 / 定时器。这类场景下 HashMapStateBackend 在大堆上已经处于内存墙极限，两种后端的瓶颈都是 Long 装箱与单次哈希定位，差异被 JNI 固定开销掩盖。
- **趋势稳定，不随规模发散。** 随着 `num_keys` 从 1 M 扩大到 10 M，两者吞吐量同步下降（工作集超出 L2 容量所致），比值保持稳定。说明 ForL0 State Backend 的分层结构在 key 规模扩大时未引入额外开销。
- **倾斜维度表现一致。** 在 `skew_factor = 1.0` 的强倾斜下，两种后端均因热点 key 命中高层缓存而提速，比值仍在 0.88–1.02 范围。

真正体现 ForL0 State Backend 价值的是 NexMark 端到端查询下的 GC 压力和复杂状态组合场景（§ 5.3）。


6.2 WordCount Benchmark 报告（Intel 参考平台）

6.2.1 测试配置

配置项	取值
平台	Intel x86_64 参考服务器
集群拓扑	Docker 默认拓扑（1 JM + 2 TM，TM 每个 4 核 / 16 GB），总并行度 8
L0 Cache	不可用（Intel 平台不具备该硬件）
其他参数	与 § 5.1.1 一致（ <code>num_keys × skew_factor</code> 扫描网格）


6.2.2 吞吐量网格

WordCount Throughput — HashMapStateBackend
best: num_keys=1M, skew=1, throughput=1.780 M/s/core



(a) HashMapStateBackend

WordCount Throughput — ForL0StateBackend
best: num_keys=1M, skew=0, throughput=2.183 M/s/core



(b) ForL0 State Backend

图 3 Intel 平台 WordCount 在 $(num_keys, skew_factor)$ 网格上的吞吐量对比: (a) HashMapStateBackend, (b) ForL0 State Backend.

WordCount Speedup — ForL0 vs HashMap
best: num_keys=2M, skew=0, speedup=1.414x




图 4 ForL0 State Backend 相对 HashMapStateBackend 的吞吐量比值 (Intel)

6.2.3 数据明细

下表给出 36 组扫描点的吞吐量 (单位: Mrecords/sec) 及 ForL0 State Backend 相对 HashMapStateBackend 的比值; 原始数据见 `results/intel/wordcount_sweep/raw/wordcount_grid_sweep_20260423_025206_final.json`。

num_keys	skew	HashMap	ForL0	比值	时间差 (s)
1 M	0.0	13.153	17.464	1.328	37.54
1 M	0.2	11.001	14.663	1.333	45.40
1 M	0.4	10.786	14.673	1.360	49.12
1 M	0.6	11.188	14.538	1.299	41.19
1 M	0.8	11.128	14.627	1.314	43.00
1 M	1.0	14.243	15.471	1.086	11.15
2 M	0.0	12.140	17.170	1.414	48.26
2 M	0.2	10.068	13.599	1.351	51.58
2 M	0.4	10.364	13.033	1.258	39.52
2 M	0.6	10.138	13.082	1.290	44.40
2 M	0.8	11.080	13.887	1.253	36.49
2 M	1.0	13.740	14.068	1.024	3.40
4 M	0.0	11.812	16.040	1.358	44.63
4 M	0.2	9.806	13.041	1.330	50.59
4 M	0.4	9.657	12.858	1.332	51.57
4 M	0.6	9.819	12.832	1.307	47.84
4 M	0.8	10.813	13.487	1.247	36.66
4 M	1.0	13.595	15.704	1.155	19.76
6 M	0.0	11.382	14.564	1.280	38.39
6 M	0.2	9.687	12.592	1.300	47.62
6 M	0.4	9.937	12.529	1.261	41.64
6 M	0.6	9.911	12.659	1.277	43.81
6 M	0.8	10.556	13.297	1.260	39.05
6 M	1.0	12.836	14.591	1.137	18.74
8 M	0.0	11.494	14.853	1.292	39.34
8 M	0.2	9.631	12.374	1.285	46.03
8 M	0.4	9.388	12.560	1.338	53.80
8 M	0.6	9.662	11.754	1.217	36.84
8 M	0.8	10.364	11.791	1.138	23.35
8 M	1.0	11.162	15.028	1.346	46.10
10 M	0.0	11.568	14.782	1.278	37.59
10 M	0.2	9.933	12.476	1.256	41.04
10 M	0.4	9.497	12.135	1.278	45.77
10 M	0.6	10.040	12.707	1.266	41.82
10 M	0.8	9.723	12.634	1.299	47.39
10 M	1.0	12.616	14.855	1.178	23.90

6.2.4 数据解读


- Intel 平台下 ForL0 State Backend 在全部 36 组扫描点上一致领先于 HashMapState-Backend，吞吐量比值最低 1.024、最高 1.414，平均 **1.270**；对应每组 2×10^9 条记录

的端到端耗时平均缩短约 37 s。这与鲲鹏下 WordCount 两者持平（平均比值约 0.96）的结论形成鲜明对比。

- **趋势与倾斜度解耦。**从 $skew_factor = 0$ 的均匀分布到 1.0 的强倾斜，比值均位于 1.02–1.41 区间，未因热点 key 出现退化；相对峰值常出现在 $skew \in [0.0, 0.4]$ 的均匀/弱倾斜区，符合 ForL0 State Backend 紧凑布局提升 cache 命中率的预期。
- **规模维度稳定。**num_keys 从 1 M 扩大到 10 M，ForL0 吞吐量从 14.5–17.5 M/s 缓慢下降到 12.0–14.9 M/s，HashMap 同步下降；比值保持在 1.14–1.35 区间，说明 SwissTable 布局在 key 规模扩大到 10 M 量级时仍能维持稳定加速。
- **与 VTune 剖析结果一致** (§ 5.2.4)。微架构分析显示 WordCount 热路径在 ForL0 State Backend 下 Memory Bound 从 48.1% 降至 15.3%、DRAM Bound 从 30.8% 降至 2.2%。Intel 平台未启用 L0 Cache 硬件，全部收益来源于 SwissTable 紧凑布局与 SWAR 并行匹配；微架构指标的改善直接映射为上表的 $1.27\times$ 平均吞吐增益。
- **鲲鹏与 Intel 的差异来源。**鲲鹏下两者持平，推测与 aarch64 上 JNI 调用开销相对 x86 更高、HashMap 在鲲鹏 L2/L3 层级上已较为充分利用相关；Intel 平台的显著加速则验证了 ForL0 State Backend 在 x86 平台同样具有良好的硬件亲和性，而不依赖特定的 L0 硬件。

6.2.5 微架构剖析（Intel VTune）

为定位 ForL0 State Backend 在 Intel 平台上的优化瓶颈，使用 Intel VTune Profiler 的 Memory Access / Microarchitecture Exploration 分析类型在 60 s 采样窗口内对 WordCount 流水线进行了优化前后两次剖析。两次采样的 Elapsed Time 均严格控制为 60.001 s，仅状态访问路径发生变化，可直接对比 μ Pipe 的失速分布。



(a) 优化前：Memory Bound 占 48.1% Pipeline Slots

(b) 优化后：Memory Bound 降至 15.3% Pipeline Slots

图 5 Intel VTune Memory Access 分析：WordCount 在 ForL0 State Backend 优化前后的 μ Pipe 与 Back-End Bound 拆解对比。

关键指标对比如下表：

指标	优化前	优化后	变化	说明
Elapsed Time	60.001 s	60.001 s	—	采样窗口对齐
Instructions Retired	1.98×10^{12}	3.49×10^{12}	$\uparrow 1.76\times$	同窗口内完成更多有效指令
CPI Rate	0.615	0.375	$\downarrow 39\%$	单指令时钟下降
Retiring	30.4%	50.9%	$\uparrow 20.5\text{pp}$	流水线产出比显著提升
Memory Bound	48.1%	15.3%	$\downarrow 32.8\text{pp}$	主要优化收益
L3 Bound	10.7%	8.5%	$\downarrow 2.2\text{pp}$	L3 命中率提升
DRAM Bound	30.8%	2.2%	$\downarrow 28.6\text{pp}$	主存访问几乎消除
Memory Latency	50.5%	23.9%	$\downarrow 26.6\text{pp}$	长延迟访存减少
Back-End Bound	58.1%	29.5%	$\downarrow 28.6\text{pp}$	后端失速显著缓解
Front-End Bound	6.9%	12.4%	$\uparrow 5.5\text{pp}$	相对占比上升 (绝对失速降低后被放大)

6.2.6 数据解读

- **Memory Bound 由 48.1% 降至 15.3%**（图 5）。优化前 μPipe 中 Back-End Bound 占据近 60% 的 Pipeline Slots，其中 Memory Bound 一项就占 48.1%；优化后 Memory Bound 降至 15.3%，Back-End Bound 同步从 58.1% 降至 29.5%。这是 ForL0 State Backend 的紧凑 SwissTable 布局与 L0 Cache 抑制 cache miss 的直接体现。
- **DRAM Bound 由 30.8% 降至 2.2%**。优化前最大的瓶颈是 DRAM 访问，其中 Memory Latency 子项占 50.5%；优化后 DRAM Bound 几乎消失（2.2%），表明状态访问已基本不再触发主存往返，热路径数据落在 L1/L2/L3 之内。
- **Retiring 由 30.4% 提升到 50.9%，CPI 由 0.615 降至 0.375**。同样的 60 s 采样窗口内 Instructions Retired 从 1.98×10^{12} 提升至 3.49×10^{12} ，意味着 $1.76\times$ 的有效吞吐改善，与 NexMark 端到端结果方向一致。
- **Front-End Bound 占比相对上升属于预期现象**。绝对值（取指/解码失速）变化不大，但由于 Back-End Bound 大幅下降，前端在比例上从 6.9% 上升到 12.4%。这并非新瓶颈，而是优化后流水线更接近指令级并行上限的副产物。

6.3 NexMark Benchmark 报告

NexMark 场景下，ForL0 State Backend 的主要优势在于：通过 native 状态与 L0 Cache 将大部分访问从 JVM 堆中剥离，使 TaskManager 的 Full GC 频率与单次暂停时间显著下降，从而在堆预算紧张、Managed 内存受限的条件下保持稳定吞吐。

6.3.1 鲲鹏平台：TM 限制 4 核

后端	q4	q5	q8	q9	q11	q18	q19	q20
HashMap (heap)	716 s★	103 s	72 s	201 s★	98 s	134 s	638 s★	542 s★
ForL0 w/L0	147 s	103 s	62 s	105 s	96 s	93 s	119 s	91 s
ForL0 w/o L0	159 s	100 s	62 s	107 s	102 s	98 s	121 s	94 s
Baseline (收益评估)	181 s	104 s	–	111 s	85 s	116 s	167 s	121 s
相对 heap 提升	387%	0%	16.1%	91.4%	2.1%	44.1%	436.1%	495.1%
相对 baseline 收益	23.1%	1.0%	–	5.7%	–11.5%	24.7%	40.3%	33.0%

注：标记★的项为 HashMapStateBackend 下因 Full GC 过度导致的大幅拖慢。**Baseline** 来自《收益评估》中的历史参考数据（q8 未提供），“相对 baseline 收益”为 ForL0 State Backend (w/L0) 相对该参考值的提升幅度。运行环境：TaskManager Heap 11.7 GB, Managed 512 MB, TM 限制 4 核。

6.3.2 Intel 参考平台：核数不限，三档 TaskManager 内存

TM 内存	后端	q4	q5	q8	q9	q11	q18	q19	q20
16 G/H12 G	heap	352 s	63 s	39 s	232 s	44 s	53 s	卡死	卡死
16 G/H12 G	forl0	61 s	56 s	36 s	46 s	35 s	34 s	47 s	40 s
18 G/H14 G	heap	156 s	64 s	36 s	46 s	53 s	53 s	279 s	313 s
18 G/H14 G	forl0	57 s	52 s	36 s	46 s	37 s	38 s	45 s	38 s
20 G/H15 G	heap	57 s	64 s	38 s	45 s	37 s	61 s	123 s	84 s
20 G/H15 G	forl0	57 s	52 s	36 s	45 s	37 s	35 s	43 s	38 s

6.3.3 数据解读

- 在堆预算紧张的场景下收益最大。鲲鹏平台 TaskManager Heap 限制 11.7 GB、TM 限 4 核条件下，HashMapStateBackend 在 q4 / q9 / q19 / q20 等状态密集查询上发生频繁 Full GC，最长单查询耗时 716 s；ForL0 State Backend 在同一配置下分别缩短到 147 s / 105 s / 119 s / 91 s，q19、q20 的端到端时间降低约 81% 以上。
- Intel 平台在堆预算宽裕后两者趋同。当 TaskManager 内存从 16 GB 逐步放宽到 20 GB，HashMap 的 GC 压力得到缓解（q4 从 352 s 降到 57 s），ForL0 State Backend 保持 52–57 s 基本不变，验证了 ForL0 State Backend 的主要收益来自避免堆上驻留大规模状态，而非改变单条访问的最优路径。
- L0 Cache 在 NexMark 上的边际贡献有限。w/ L0 与 w/o L0 两行在鲲鹏平台上差距在个位数秒级（q4: 147 s vs 159 s，q19: 119 s vs 121 s），说明 NexMark 场景下 L0 主要承担 MapState / ListState 的元数据加速，吞吐瓶颈已让位于序列化与窗口调度；L0 Cache 的主要价值体现在高频细粒度 ValueState 场景（详见设计说明书）。
- 卡死用例消失。Intel 16 G 档下 HashMap 在 q19 / q20 出现卡死，ForL0 State Backend

在相同配置下可正常完成，表明即使在较紧的堆预算下 ForL0 State Backend 仍能保证作业可用性。




图 6 NexMark 查询执行时间对比。(a) 鲲鹏 openEuler 平台、TaskManager 4 核 / Heap 11.7 GB 下 HashMapStateBackend、ForL0 State Backend (启用 / 关闭 L0 Cache) 与《收益评估》提供的历史 baseline 四方对比，红色数值标注 HashMap 出现 Full GC 拖慢的查询；(b) Intel x86_64 参考平台在 16 / 18 / 20 GB 三档 TaskManager 内存下两种后端的扫描结果，红色斜线段表示 HashMap 在该配置下卡死无法完成。

6.4 Flink 状态算子级 JMH 基准 (Intel 参考平台)

除端到端查询外，使用 Flink 官方 `flink-benchmarks` 仓库中的 `StateBackendBenchmark` 对 `ValueState`、`ListState`、`MapState` 的典型算子单独打点。该基准纯粹比较状态后端在算子层的吞吐，排除上层拓扑影响。




图 7 Flink StateBackend JMH 基准：ForL0 State Backend 与 HashMapStateBackend 的算子吞吐 (Intel 参考平台，单位 ops/ms)

在该基准下 ForL0 State Backend 在 14 个操作点中 13 个呈现正向提升：`value.Add` +87.2%、`value.Update` +59.5%、`map.Add` +110.0%、`map.Remove` +74.4%、`list.GetAndIterate` +131.5%；仅 `list.Append` 出现 -8.9% 的回退。该结果

与 NexMark 端到端收益方向一致：算子层的哈希定位与迭代路径得到加速，上层查询在状态密集场景下的整体加速才得以兑现。

7 测试结论

1. **功能正确性**：184 项测试用例（Java 集成与单元 54 项 + C++ 原生 GoogleTest 130 项）全部通过，覆盖 5 类 KeyedState 及其语义边界、Checkpoint/Savepoint/异步快照/快照一致性、窗口聚合、倾斜与压力负载、并行度变化（Rescale）、L0 Cache 类型组合与兜底、SPI 加载，以及 SwissTable/CoW/序列化/类型布局/Hot Cache 等原生数据结构。
2. **接口兼容性**：ForL0 State Backend 通过 SPI 被 Flink 自动发现并加载，与 Flink 1.20.3 的 StateBackend 接口、Checkpoint/Savepoint 协议完全兼容，用户作业无需修改。
3. **原生引擎稳定性**：SwissTable、CoW 快照、Checkpoint 序列化往返、TypedInnerMap 等底层结构通过 CTest 验证，序列化与恢复路径在大规模 key 和混合状态类型下均保持一致性。
4. **性能特征（Intel 平台收益显著）**：在 Intel x86_64 参考平台，ForL0 State Backend 在 WordCount 全部 36 组网格扫描点上一致领先于 HashMapStateBackend，平均吞吐量比值 **1.270**、最高 1.414；这一加速与 VTune 微架构剖析高度吻合——Memory Bound 从 48.1% 降至 15.3%、DRAM Bound 从 30.8% 降至 2.2%、CPI 从 0.615 降至 0.375。NexMark 端到端查询在 Intel 16 GB 紧内存档位下，q4 / q9 等状态密集查询从 352 s / 232 s 缩短至 61 s / 46 s，并且 q19 / q20 由 HashMap 下的”卡死”转为 ForL0 State Backend 可稳定完成。**Flink 状态算子级 JMH 基准**进一步佐证：14 个操作点中 13 个正向提升，value.Add +87.2%、map.Add +110.0%、list.GetAndIterate +131.5%。
5. **鲲鹏平台收益不明显（当前阶段局限）**：在相同拓扑与扫描参数下，ForL0 State Backend 在鲲鹏上 WordCount 微基准与 HashMap 吞吐量基本持平（平均比值 ≈ 0.96 ）。推测主要原因有两方面：一是 aarch64 平台的 JNI 调用开销相对 x86 偏高，覆盖掉了 SwissTable 紧凑布局的增益；二是鲲鹏处理器上特定硬件指令（如 SWAR 64 位匹配、bit-scan、CRC32C 散列等）的 IPC 表现与 x86 存在差异，而当前实现未针对鲲鹏做进一步的微架构调优。NexMark 在鲲鹏上仍能观测到明显收益，但这主要来自堆外迁移 + GC 压力缓解这一系统级效果，而非算法层的硬件亲和。综上，**当前阶段 ForL0 State Backend 的”算法加速”收益仅在 Intel 平台得到充分验证**，在鲲鹏上尚需对 JNI 路径与平台特定指令路径做进一步优化。