
ForL0 State Backend

测试用例及报告

v4.0

2026 年 7 月

目 录

1	文档概述	1
1.1	测试平台	1
1.2	测试范围	1
1.3	测试结果摘要	1
2	测试环境	2
2.1	鲲鹏服务器（主测试平台）	3
2.2	Intel 参考平台	3
3	功能测试用例	3
3.1	状态类型正确性测试（FT）	3
3.2	Checkpoint 与 Savepoint 测试（CP / CO）	4
3.3	异步快照与快照一致性测试（AS / SC）	5
3.4	窗口聚合测试（WA）	5
3.5	MiniCluster 端到端测试（MC）	5
3.6	Rescale 测试（RS）	6
3.7	状态语义单元测试（SE）	6
3.8	Hot Cache 集成测试（HC）	7
3.9	Java 单元测试（UT）	8
3.10	C++ 原生引擎单元测试（NT）	8
3.11	功能测试覆盖矩阵	10
4	功能测试报告	10
4.1	测试执行方式	10
4.2	测试结果	11
4.3	结果说明	11
5	性能基准测试	11
5.1	WordCount Benchmark	12
5.1.1	测试设计	12
5.1.2	测试执行	12

5.2	NexMark Benchmark	12
5.2.1	测试设计	12
5.2.2	测试执行	13
6	性能基准测试报告	13
6.1	WordCount Benchmark 报告（鲲鹏）	13
6.1.1	测试配置	13
6.1.2	吞吐量网格	13
6.1.3	数据明细	14
6.1.4	数据解读	15
6.2	WordCount Benchmark 报告（Intel 参考平台）	15
6.2.1	测试配置	15
6.2.2	吞吐量网格	15
6.2.3	数据明细	15
6.2.4	数据解读	16
6.2.5	微架构剖析（Intel VTune）	17
6.2.6	数据解读	18
6.3	NexMark Benchmark 报告	18
6.3.1	鲲鹏平台：TM 限制 4 核	19
6.3.2	Intel 参考平台：核数不限，可完成 TaskManager 内存配置	19
6.3.3	数据解读	20
6.4	Flink 状态算子级 JMH 基准（Intel 参考平台）	20
6.5	状态密集路径 Micro Profile（鲲鹏平台）	21
7	合同验收与扩展压力测试	21
7.1	测试方法论	22
7.2	WordCount 双场景测试	22
7.2.1	场景配置	22
7.2.2	测试结果	22
7.2.3	数据解读	23
7.3	NexMark 双场景测试	23
7.3.1	合同基线结果	24
7.3.2	非合同扩展结果	24
7.3.3	数据解读	26

- 7.4 Client Usecase 双场景测试 27
 - 7.4.1 测试结果. 27
 - 7.4.2 数据解读. 27
- 7.5 后续 ForL0 内部改造与离线运行保障 28
 - 7.5.1 ForL0 内部状态访问改造 28
 - 7.5.2 诊断实验结果与边界. 29
 - 7.5.3 离线一键运行保障 30
- 7.6 v4.0 L0 优势配置与一键脚本修复 30
 - 7.6.1 v4.0 采用的 ForL0 优势配置 32
 - 7.6.2 本轮发现并修复的实验入口 bug 32
 - 7.6.3 v4.0 复核结论. 33
 - 7.6.4 2026-07-11 Ascend 一键复现补充 33
 - 7.6.5 2026-08-16 工程修复与待复跑状态 34
 - 7.6.6 2026-08-20 全因子调优阶段性结果 35
- 8 测试结论 37

1 文档概述

本文档给出 ForL0 State Backend 的测试用例清单与测试执行结果，涵盖功能测试、C++ 原生引擎单元测试，以及基于 WordCount 与 NexMark 的性能基准测试。功能测试用于验证与 Flink 状态后端接口的语义一致性；性能基准测试用于量化在鲲鹏服务器与 Intel 参考平台上的实际收益。

1.1 测试平台

项目	配置
生产目标平台	鲲鹏系列处理器 / openEuler / aarch64
参考对比平台	Intel x86_64 服务器（仅用于 NexMark 场景下 GC 压力的横向对照）
JDK	BiSheng JDK 1.8 (aarch64) / OpenJDK 1.8 (x86_64)
Apache Flink	1.20.3
ForL0 State Backend	1.0-SNAPSHOT
原生引擎	libforl0_engine.so (aarch64, NEON 启用)
L0 依赖	libl0mempool.so、/dev/hisi_l0 设备节点（运行期可选）

1.2 测试范围

- **功能测试：**覆盖 ValueState、ListState、MapState、ReducingState、AggregatingState 五类 KeyedState，以及 Checkpoint、Savepoint、窗口聚合、倾斜负载、SPI 自动发现等运行时行为。
- **原生引擎单元测试：**C++ 层的 SwissTable、StateTable、CoW 快照、Checkpoint 往返、类型布局解析、TimeWindow namespace、TypedInnerMap 等核心数据结构。
- **性能基准测试：**WordCount 纯状态微基准与 NexMark 端到端流处理查询集。

1.3 测试结果摘要

全部功能测试用例与原生引擎单元测试通过，通过率 100%。交付结论摘要如下：功能正确性 184/184 通过；合同口径下未发现兼容性回退；Intel WordCount 网格扫描平均吞吐比值为 1.270；2026-07-12 Ascend 编号化一键复跑完整通过，WordCount p4 best-of-3 为 +24.9%，NexMark q18 TPS / q18 lateq-deep / q4 / q3 分别为 +23.4% / +28.8% / +11.9% / +16.8%，q19/q20/q9 吞吐小幅正向且 CPU/core 效率显著改善。性能收益边界集中在高基数状态、状态密集更新、堆压力或 backpressure 稳态场景，详细数据见 §5。

测试套件	用例数	通过	未通过	通过率
ForL0StateTypesITCase	8	8	0	100%
ForL0CheckpointSavepointITCase	5	5	0	100%
ForL0CheckpointOptimizationITCase	3	3	0	100%
ForL0WindowAggregateITCase	3	3	0	100%
ForL0MiniClusterITCase	5	5	0	100%
ForL0RescaleITCase	3	3	0	100%
ForL0AsyncSnapshotITCase	2	2	0	100%
ForL0SnapshotConsistencyITCase	3	3	0	100%
ForL0StateSemanticsTest	13	13	0	100%
HotCacheIntegrationTest	8	8	0	100%
ListAppendDebugTest	1	1	0	100%
<i>Java 侧合计</i>	<i>54</i>	<i>54</i>	<i>0</i>	<i>100%</i>
swiss_table_test	28	28	0	100%
type_layout_parser_test	20	20	0	100%
time_window_namespace_test	18	18	0	100%
checkpoint_round_trip_test	12	12	0	100%
state_table_cow_test	12	12	0	100%
typed_inner_map_test	12	12	0	100%
hot_cache_phase_b_test	11	11	0	100%
hot_cache_test	10	10	0	100%
hot_cache_manager_test	7	7	0	100%
<i>C++ 原生引擎合计</i>	<i>130</i>	<i>130</i>	<i>0</i>	<i>100%</i>
合计	184	184	0	100%

2 测试环境

除特别说明外，所有性能基准测试均在容器化的 Flink Standalone 集群中运行。**默认集群拓扑：3 个 Docker 容器——1 个 JobManager (2 核 / 8 GB) + 2 个 TaskManager (各 4 核 / 16 GB)，总任务并行度 8。**集群由 docker/docker-compose.yml 一键拉起，镜像内预置 ForL0 State Backend 的 JAR 与原生库，JobManager 与 TaskManager 之间通过容器网络通信。表格中所列“TM 内存”、“核数限制”等数值即为单个 TaskManager 容器的资源上限。

2.1 鲲鹏服务器（主测试平台）

项目	配置
处理器	鲲鹏系列处理器（aarch64）
操作系统	openEuler
L0 环境	目标服务器提供鲲鹏 L0 Cache 驱动、libl0mempool.so 与 /dev/hisi_l0 设备节点
JDK	BiSheng JDK 1.8, JAVA_HOME=/opt/bisheng-jdk1.8.0
Maven	3.6+
Flink	1.20.3 Standalone 集群（Docker Compose）
默认集群拓扑	1 JM (2 核 / 8 GB) + 2 TM (各 4 核 / 16 GB)，总并行度 8
Heap / Managed 内存	Heap 11.7 GB, Managed 512 MB（NexMark 场景）

2.2 Intel 参考平台

Intel 参考平台仅用于 NexMark 场景下 GC 压力的横向对照，以及 Flink 状态算子级别的 JMH 微基准。该平台不依赖 L0 硬件。

项目	配置
处理器	Intel x86_64 服务器
操作系统	Linux
默认集群拓扑	1 JM (2 核 / 8 GB) + 2 TM (各 4 核 / 16 GB)，总并行度 8
TaskManager 内存	默认 16 GB；NexMark 正式结果采用 18 / 20 GB 可完成配置（JVMHeap 14 / 15 GB）
核数限制	默认每 TM 4 核，扩充案例在对应节列明

3 功能测试用例

功能测试用例覆盖 11 个 Java 测试类共 54 个 @Test 方法，外加 9 个 C++ 测试套件共 130 个 TEST 用例，总计 184 项。下文按测试主题分组列出全部用例。

3.1 状态类型正确性测试（FT）

测试类 ForL0StateTypesITCase（基于 Flink MiniCluster），覆盖五类 KeyedState 的读写路径与若干常用类型组合。

编号	用例名称	测试方法	主要验证点
FT-01	ValueState	testValueState()	6 条记录 / 3 个 key (a:3,b:2,c:1), 计数累加
FT-02	ListState (String)	testListState()	6 条 String 记录, 验证追加顺序
FT-03	ReducingState	testReducingState()	6 条 Integer 记录, 验证求和归约
FT-04	AggregatingState	testAggregatingState()	自定义聚合函数, 聚合结果匹配
FT-05	MapState (Generic)	testMapState()	String → Integer 的 5 条 Tuple 记录
FT-06	MapState (Long, Long)	testMapStateLongLong()	Long → Long 类型特化路径
FT-07	MapState (Long, String)	testMapStateLongString()	Long → String 混合宽度路径
FT-08	ListState (Long)	testListStateLong()	5 条 Long 记录 / 2 个 key

3.2 Checkpoint 与 Savepoint 测试 (CP / CO)

CP 系列对应 ForL0CheckpointSavepointITCase (5 项) , CO 系列对应 ForL0CheckpointOptimizationITCase (3 项)。

编号	用例名称	测试方法	主要验证点
CP-01	周期性 Checkpoint	testPeriodicCheckpointCompletes()	200 ms 间隔, ExactlyOnce 模式, chk-* 目录生成
CP-02	Savepoint 与恢复	testSavepointAndRestore()	1000 条记录 → Savepoint → 恢复 → 数据一致
CP-03	Savepoint 精确状态	testSavepointAndRestore_ExactState()	恢复后 count 值精确等于 N
CP-04	外部化 Checkpoint	testExternalizedCheckpoint_ExactState()	RETAIN_ON_CANCELLATION 后文件保留
CP-05	多状态类型 Savepoint 兼容	testSavepointCompatibilityMultiStateTypes()	Value / List / Map 混合 + 多 namespace
CO-01	多 Checkpoint 周期	testMultipleCheckpointCycles()	连续多轮 Checkpoint 触发与确认
CO-02	多状态类型恢复	testSavepointRestoreWithMultipleStateTypes()	500 条记录混合状态操作恢复
CO-03	大规模 Key 恢复	testSavepointRestoreWithManyKeys()	大规模 Key 分布式 Savepoint 恢复

3.3 异步快照与快照一致性测试 (AS / SC)

AS 系列对应 ForL0AsyncSnapshotITCase, 验证异步快照路径下的访问安全性; SC 系列对应 ForL0SnapshotConsistencyITCase, 验证快照前后状态一致性。

编号	用例名称	测试方法	主要验证点
AS-01	异步 Checkpoint 后继 续累加	asyncCheckpointRestore _AllowsContinuedAccumulation()	异步快照过程中状态可继续 读改写并完成恢复
AS-02	快照中欠写恢复	asyncCheckpointUnderWrites_RestorePreservesNonZeroState()	异步窗口内尚未确认的写入 在恢复后保持非零
SC-01	启用缓存的快照恢复	snapshotRestore_CacheEnabled_PreservesValueAndList()	启用 L0 Cache 时 Value/List 状态恢复一致
SC-02	单热点 Key 快照恢复	snapshotRestore_CacheEnabled_SingleHotKey()	单热点 Key 在缓存重建后值 正确
SC-03	清空后快照	snapshotAfterClear_PreservesEmpty()	clear() 后 Snapshot 恢复 仍为空

3.4 窗口聚合测试 (WA)

测试类 ForL0WindowAggregateITCase。

编号	用例名称	测试方法	主要验证点
WA-01	滑动窗口聚合	testSlidingWindowAggregateWithTuple2LongLong()	1000 ms 窗口 / 200 ms 滑动, Tuple2<Long, Long> 累加器
WA-02	高负载窗口聚合	testHighLoadWindowAggregate()	10 000 条记录 / 1000 个 key
WA-03	窗口 Checkpoint 恢复	testWindowAggregateCheckpointRestore()	无界数据源 + Checkpoint + 重启

3.5 MiniCluster 端到端测试 (MC)

测试类 ForL0MiniClusterITCase, 覆盖 SPI 加载、倾斜负载、滑动窗口、压力场景。

编号	用例名称	测试方法	主要验证点
MC-01	SPI 加载 ValueState	testValueStateWordCountWithSPI()	SPI 自动发现并加载 ForL0 State Backend
MC-02	高负载倾斜 ValueState	testSkewedHighLoadValueState()	2000 万记录 / 100 万 key / 80% 流量集中于 1% 热点
MC-03	大规模状态压力	testLargeScaleStateStress()	大规模 Key 持续读改写下的稳定性
MC-04	滑动窗口 WordCount	testSlidingEventTimeWindowWordCount()	EventTime 滑动窗口 + ValueState
MC-05	滑动窗口 WordCount 压力	testSlidingEventTimeWindowWordCount_Stress()	高速率事件流下窗口聚合稳定性

3.6 Rescale 测试 (RS)

测试类 ForL0RescaleITCase, 验证作业并行度变化时 Key Group 重新分配与状态迁移。

编号	用例名称	测试方法	主要验证点
RS-01	缩容 2 → 1	testScaleDown_2_to_1()	并行度从 2 降为 1, 状态合并后语义保持
RS-02	扩容 1 → 2	testScaleUp_1_to_2()	并行度从 1 扩为 2, Key Group 重分配正确
RS-03	扩容 2 → 4	testScaleUp_2_to_4()	并行度从 2 扩为 4, 状态完整性保持

3.7 状态语义单元测试 (SE)

测试类 ForL0StateSemanticsTest, 针对状态接口的边界语义 (空值、null 参数、迭代器、计数等) 逐项验证。

编号	用例名称	测试方法	主要验证点
SE-01	ValueState 默认值	valueStateDefaultIsNullForEmptyKey()	未初始化 key 读取返回 null
SE-02	ValueState update(null)	valueStateUpdateNullClearsEntry()	update(null) 等价于 clear()
SE-03	ValueState clear 同步缓存	valueStateClearRemovesFromBothCacheAndTable()	clear() 同步移除 L0 缓存与底层表项
SE-04	多个 ValueState 独立性	multipleValueStatesAreIndependent()	同一 key 下多个 ValueState 互不干扰
SE-05	ListState add(null) 抛出	listStateAddNullThrows()	单元素 null 入参抛出 NPE
SE-06	ListState addAll(null)	listStateAddAllNullArgumentThrows()	列表 null 入参抛出 NPE
SE-07	ListState addAll 含 null	listStateAddAllListContainingNullThrows()	列表元素含 null 抛出 NPE
SE-08	ListState update(null)	listStateUpdateNullArgumentThrows()	update(null) 抛出 NPE
SE-09	ListState update(empty)	listStateUpdateEmptyClearsState()	update([]) 等价于 clear()
SE-10	MapState 允许 null 值	mapStateAllowsNullValue()	put(k, null) 允许, 迭代时可见
SE-11	getKeys 反映已注册 key	getKeysReflectsRegisteredKeys()	getKeys() 与实际持有 key 集合一致
SE-12	applyToAllKeys 唯一访问	applyToAllKeysVisitsEachKeyExactlyOnce()	applyToAllKeys() 不重复访问
SE-13	KV 计数与增删一致	numKeyValueStateEntriesMatchesInsertsAndDeletes()	numKeyValueStateEntries() 与累计增删一致

3.8 Hot Cache 集成测试 (HC)

测试类 HotCacheIntegrationTest, 验证 L0 Cache 在不同标量类型组合下的行为一致性、可观测指标以及设备不可用时的兜底关闭路径。

编号	用例名称	测试方法	主要验证点
HC-01	long×long 等价性	longLongValueStateBehavesIdenticallyWithCacheOnOrOff()	缓存开/关结果完全一致
HC-02	int×long 路径	intLongValueStateRoundtrip()	int → long 类型回环一致
HC-03	int×double 路径	intDoubleValueStateRoundtrip()	int → double 类型回环一致
HC-04	long×double 路径	longDoubleValueStateRoundtrip()	long → double 类型回环一致
HC-05	设备不可用门控	managerGateClosesOnPlatformsWithoutL0()	设备不可用时 Manager 自动关闭
HC-06	配置禁用时指标为零	managerMetricsAreZeroWhenDisabledByConfig()	显式禁用后所有缓存指标恒为 0
HC-07	扩展指标聚合	extendedManagerMetricsExposeAggregateCounters()	命中 / 替换 / 失效计数器正确聚合
HC-08	Manager 失活时再均衡安全	rebalanceIsSafeWhenManagerInactive()	Manager 关闭状态下再均衡不抛异常

3.9 Java 单元测试 (UT)

编号	用例名称	测试方法	主要验证点
UT-01	ListState 追加路径	testListAppendDoesNotCreateNewArrayList()	ListState 追加不重复创建 ArrayList

3.10 C++ 原生引擎单元测试 (NT)

通过 CMake 构建的 GoogleTest 套件，源码位于 src/main/native/test/，由 ctest 统一驱动。本节按套件汇总，每个套件下用例数即对应 TEST/TEST_F 数量。

编号	测试套件	用例数	覆盖范围
NT-01	swiss_table_test.cpp	28	插入 / 查找 / 删除 / 迭代 / rehash / grow / 复合负载
NT-02	state_table_cow_test.cpp	12	Copy-On-Write 快照、写时分裂、并发读视图
NT-03	checkpoint_round_trip_test.cpp	12	Checkpoint 序列化 → 反序列化 → 一致性比对
NT-04	type_layout_parser_test.cpp	20	Java 类型描述符解析与 C++ 内存布局映射
NT-05	time_window_namespace_test.cpp	18	TimeWindow namespace 增删、过期清理
NT-06	typed_inner_map_test.cpp	12	类型化 Inner Map 的 put / remove / iterate
NT-07	hot_cache_test.cpp	10	L0 Hot Cache 基本路径与命中 / 替换
NT-08	hot_cache_phase_b_test.cpp	11	Hot Cache Phase B 增量路径与回写
NT-09	hot_cache_manager_test.cpp	7	Hot Cache Manager 生命周期、再均衡
原生引擎合计		130	

3.11 功能测试覆盖矩阵

功能特性	覆盖的测试用例
ValueState 读写 / 边界	FT-01, SE-01..04, MC-01, MC-02, MC-04
ListState 读写 / 边界	FT-02, FT-08, SE-05..09, UT-01
MapState 读写 / 边界	FT-05, FT-06, FT-07, SE-10
ReducingState /	FT-03, FT-04
AggregatingState	
状态遍历与计数	SE-11, SE-12, SE-13
Checkpoint 生成 / 多周期	CP-01, CP-04, CO-01
Savepoint 触发与恢复	CP-02, CP-03, CP-05, CO-02, CO-03
异步快照路径	AS-01, AS-02
快照前后一致性	SC-01, SC-02, SC-03
多状态类型混合 / 多 namespace	CP-05, CO-02
时间窗口聚合	WA-01, WA-02
窗口 + Checkpoint	WA-03
高负载 / 热点 key	MC-02, MC-03, MC-05
SPI 自动发现	MC-01
并行度变化 (Rescale)	RS-01, RS-02, RS-03
L0 Cache 类型组合 / 指标 / 兜底	HC-01..08
SwissTable / NEON SIMD	NT-01
CoW 快照一致性	NT-02
Checkpoint 序列化往返	NT-03
类型布局 / TimeWindow / Inner	NT-04, NT-05, NT-06
Map	
Hot Cache 路径 / 管理器	NT-07, NT-08, NT-09

4 功能测试报告

4.1 测试执行方式

在鲲鹏服务器上运行 Java 侧的全量集成测试与 C++ 原生引擎测试：

```
# Java: integration tests + unit tests
cd $PROJECT_ROOT
mvn test -Djava.library.path=src/main/resources/native

# C++: native engine unit tests
cd $PROJECT_ROOT/src/main/native
mkdir -p build && cd build
cmake .. -DFORL0_BUILD_TESTS=ON -DCMAKE_BUILD_TYPE=Release
make -j$(nproc)
ctest --output-on-failure
```

4.2 测试结果

全部 184 项测试用例（Java 54 项 + C++ 130 项）执行通过，无未通过项与跳过项。各测试套件的通过情况已在 §1.3 汇总。完整 JUnit 报告位于 `target/surefire-reports/`，CTest 报告位于 `src/main/native/build/Testing/`。

4.3 结果说明

- **状态类型**：5 类 `KeyedState` 全部通过，包含 `MapState<Long,Long>`、`MapState<Long,String>` 与 `ListState<Long>` 的特化路径。
- **状态语义边界**：13 项 `ForL0StateSemanticsTest` 用例覆盖默认值、`null` 参数、`clear()` 与缓存同步、`getKeys()`、`applyToAllKeys()`、`numKeyValueStateEntries()` 等接口契约。
- **容错机制**：周期性 Checkpoint、Savepoint、外部化 Checkpoint、异步快照（AS-01/02）、快照一致性（SC-01..03）以及多周期 Checkpoint（CO-01）的触发、恢复、状态一致性均满足 `ExactlyOnce` 语义。
- **并行度变化**：RS-01..03 验证缩容 2→1、扩容 1→2 / 2→4 场景下 Key Group 重新分配与状态迁移的正确性。
- **窗口**：EventTime 滑动窗口在高负载（10 000 条记录 / 1000 个 key）以及窗口跨 Checkpoint 重启场景下行为正确。
- **倾斜负载与压力**：MC-02 用例下 80% 流量集中于 1% 的热点 key，2000 万条记录结束后所有 key 状态精确匹配；MC-03 / MC-05 在大规模状态与高速率事件流下保持稳定。
- **L0 Cache**：HC-01..08 验证缓存开/关等价性、4 类标量类型组合、设备不可用兜底关闭、扩展指标聚合，确保启用与禁用路径的语义对齐。
- **SPI 加载**：Flink 通过 SPI 机制自动发现并加载 `ForL0 State Backend`，无需额外配置（MC-01）。
- **原生引擎**：9 个 GoogleTest 套件、130 项用例覆盖 `SwissTable`、`CoW`、序列化、类型布局、`TimeWindow namespace`、`TypedInnerMap`、`Hot Cache` 主路径与管理器，全部通过。

5 性能基准测试

性能基准测试由两部分组成：`WordCount` 纯状态微基准用于隔离状态后端对 `ValueState` 读写路径的影响；`NexMark` 端到端查询集用于评估在真实流处理负载（窗口聚合、会话窗口、`TopN`、去重、双流 Join 等）下的综合收益。

5.1 WordCount Benchmark

5.1.1 测试设计

WordCount 基准构造了最紧凑的 ValueState 读改写循环，尽量排除窗口、定时器、侧输出等其他算子开销。拓扑结构为：

SkewedWordSource $\rightarrow$ KeyedProcessFunction (value() $\rightarrow$ +1 $\rightarrow$ update()) $\rightarrow$ MetricsSink

参数	取值	说明
num_keys	1 M, 2 M, 4 M, 6 M, 8 M, 10 M	key 基数扫描
skew_factor	0, 0.2, 0.4, 0.6, 0.8, 1.0	Zipf 倾斜因子扫描
num_records	2 000 000 000	单次运行 20 亿条记录
arrival_rate	0	无限速
parallelism	8	并行度
checkpoint_interval	0	Checkpoint 关闭，最大吞吐量

扫描组合共 $6 \times 6 = 36$ 组，每组在 HashMapStateBackend 与 ForL0 State Backend 下各运行一次，记录总吞吐量 throughput。

5.1.2 测试执行

```
cd docker
# run WordCount through the one-click deployment script
./run_all_apps.sh --test wordcount --scenario stateful_counter --backend all
./run_all_apps.sh --test wordcount --scenario high_cardinality --backend all
```

原始结果以 JSON 存储于 benchmark/results/；绘图输出在 benchmark/results/ 及本交付文档目录。

5.2 NexMark Benchmark

5.2.1 测试设计

NexMark 基于在线拍卖场景，包含 Person / Auction / Bid 三类事件（比例 1 : 3 : 46）。选取具备代表性的 8 个有状态查询进行测试：

查询	事件数	状态类型	典型负载特征
q4	80 000 000	窗口聚合	分类平均价格
q5	80 000 000	滑动窗口	热门商品
q8	100 000 000	会话窗口	新用户监控
q9	40 000 000	双流 Join	中标结果
q11	80 000 000	会话窗口	用户会话
q18	80 000 000	去重	最近关闭拍卖
q19	80 000 000	TopN	拍卖 TOP-10 价格
q20	60 000 000	分组聚合	拍卖价格分段

5.2.2 测试执行

```
cd docker
# full query set comparison through the one-click deployment script
./run_all_apps.sh --test nexmark --backend all

# specify queries + backend
./run_all_apps.sh --test nexmark --backend forl0 --query q4,q19,q20
```

6 性能基准测试报告

6.1 WordCount Benchmark 报告（鲲鹏）

6.1.1 测试配置

配置项	取值
平台	鲲鹏服务器，openEuler，aarch64
并行度	8
num_keys 扫描	{1 M, 2 M, 4 M, 6 M, 8 M, 10 M}
skew_factor 扫描	{0, 0.2, 0.4, 0.6, 0.8, 1.0}
每组记录数	2 000 000 000
Checkpoint	关闭
L0 Cache	该历史网格按原始配置记录；当前 p4 正式探针明确关闭 L0，见 §6.2
测试轮数	完整网格扫描 2 轮（以第 2 轮稳定值为准）

6.1.2 吞吐量网格

吞吐量网格的完整数值已保留在下表中，不再随代码仓库保存重复的历史绘图文件。

6.1.3 数据明细

下表给出 36 组扫描点的吞吐量（单位：M records/sec）及 ForL0 State Backend 相对 HashMap-StateBackend 的比值。

num_keys	skew	HashMap	ForL0	比值	时间差 (s)
1 M	0.0	7.618	7.342	0.964	9.88
1 M	0.2	6.203	6.027	0.972	9.39
1 M	0.4	6.113	6.010	0.983	5.62
1 M	0.6	6.050	6.207	1.026	−8.35
1 M	0.8	6.197	6.087	0.982	5.87
1 M	1.0	7.797	6.859	0.880	34.95
2 M	0.0	7.178	7.053	0.983	4.96
2 M	0.2	5.918	5.820	0.983	5.69
2 M	0.4	6.079	5.807	0.955	15.38
2 M	0.6	6.027	6.023	0.999	0.22
2 M	0.8	6.046	6.003	0.993	2.37
2 M	1.0	7.718	6.945	0.900	28.82
4 M	0.0	6.928	6.626	0.956	13.18
4 M	0.2	5.789	5.624	0.971	10.15
4 M	0.4	5.867	5.662	0.965	12.31
4 M	0.6	5.666	5.675	1.002	−0.57
4 M	0.8	5.885	5.744	0.976	8.37
4 M	1.0	7.152	6.858	0.959	11.96
6 M	0.0	6.708	6.477	0.966	10.62
6 M	0.2	5.807	5.497	0.947	19.39
6 M	0.4	5.731	5.509	0.961	14.08
6 M	0.6	5.667	5.509	0.972	10.13
6 M	0.8	5.881	5.536	0.941	21.22
6 M	1.0	7.154	6.732	0.941	17.49
8 M	0.0	6.768	6.286	0.929	22.64
8 M	0.2	5.723	5.402	0.944	20.79
8 M	0.4	5.722	5.434	0.950	18.49
8 M	0.6	5.641	5.411	0.959	15.11
8 M	0.8	5.843	5.596	0.958	15.13
8 M	1.0	6.618	6.725	1.016	−4.80
10 M	0.0	6.786	6.003	0.885	38.38
10 M	0.2	5.854	5.440	0.929	26.06
10 M	0.4	5.619	5.494	0.978	8.09
10 M	0.6	5.693	5.522	0.970	10.88
10 M	0.8	5.659	5.659	1.000	−0.02
10 M	1.0	6.972	6.837	0.981	5.68

6.1.4 数据解读

- **两侧吞吐量基本对齐。**36 组扫描中，ForL0 State Backend 与 HashMapStateBackend 的吞吐量比值均集中在 0.88–1.03 区间，平均比值约 0.96。考虑到 ForL0 State Backend 需要跨 JNI 完成每次 ValueState 读改写，此差距可归因于 JNI 调用自身的常量开销，而非哈希索引本身。
- **微基准无法暴露 ForL0 State Backend 的主要收益来源。**WordCount 的单条记录仅执行 value() → +1 → update()，整个负载为纯访问性循环，无 GC 压力、无复杂状态组合、无窗口 / 定时器。这类场景下 HashMapStateBackend 在大堆上已经处于内存墙极限，两种后端的瓶颈都是 Long 装箱与单次哈希定位，差异被 JNI 固定开销掩盖。
- **趋势稳定，不随规模发散。**随着 num_keys 从 1 M 扩大到 10 M，两者吞吐量同步下降（工作集超出 L2 容量所致），比值保持稳定。说明 ForL0 State Backend 的分层结构在 key 规模扩大时未引入额外开销。
- **倾斜维度表现一致。**在 skew_factor = 1.0 的强倾斜下，两种后端均因热点 key 命中高层缓存而提速，比值仍在 0.88–1.02 范围。

真正体现 ForL0 State Backend 价值的是 NexMark 端到端查询下的 GC 压力和复杂状态组合场景 (§5.3)。

6.2 WordCount Benchmark 报告（Intel 参考平台）

6.2.1 测试配置

配置项	取值
平台	Intel x86_64 参考服务器
集群拓扑	Docker 默认拓扑（1 JM + 2 TM，TM 每个 4 核 / 16 GB），总并行度 8
L0 Cache	不可用（Intel 平台不具备该硬件）
其他参数	与 §5.1.1 一致（num_keys × skew_factor 扫描网格）

6.2.2 吞吐量网格

吞吐量网格的完整数值已保留在下表中，不再随代码仓库保存重复的历史绘图文件。

6.2.3 数据明细

下表保留 36 组扫描点的完整吞吐量（单位：M records/sec）及 ForL0 State Backend 相对 HashMapStateBackend 的比值。

num_keys	skew	HashMap	ForL0	比值	时间差 (s)
1 M	0.0	13.153	17.464	1.328	37.54
1 M	0.2	11.001	14.663	1.333	45.40
1 M	0.4	10.786	14.673	1.360	49.12
1 M	0.6	11.188	14.538	1.299	41.19
1 M	0.8	11.128	14.627	1.314	43.00
1 M	1.0	14.243	15.471	1.086	11.15
2 M	0.0	12.140	17.170	1.414	48.26
2 M	0.2	10.068	13.599	1.351	51.58
2 M	0.4	10.364	13.033	1.258	39.52
2 M	0.6	10.138	13.082	1.290	44.40
2 M	0.8	11.080	13.887	1.253	36.49
2 M	1.0	13.740	14.068	1.024	3.40
4 M	0.0	11.812	16.040	1.358	44.63
4 M	0.2	9.806	13.041	1.330	50.59
4 M	0.4	9.657	12.858	1.332	51.57
4 M	0.6	9.819	12.832	1.307	47.84
4 M	0.8	10.813	13.487	1.247	36.66
4 M	1.0	13.595	15.704	1.155	19.76
6 M	0.0	11.382	14.564	1.280	38.39
6 M	0.2	9.687	12.592	1.300	47.62
6 M	0.4	9.937	12.529	1.261	41.64
6 M	0.6	9.911	12.659	1.277	43.81
6 M	0.8	10.556	13.297	1.260	39.05
6 M	1.0	12.836	14.591	1.137	18.74
8 M	0.0	11.494	14.853	1.292	39.34
8 M	0.2	9.631	12.374	1.285	46.03
8 M	0.4	9.388	12.560	1.338	53.80
8 M	0.6	9.662	11.754	1.217	36.84
8 M	0.8	10.364	11.791	1.138	23.35
8 M	1.0	11.162	15.028	1.346	46.10
10 M	0.0	11.568	14.782	1.278	37.59
10 M	0.2	9.933	12.476	1.256	41.04
10 M	0.4	9.497	12.135	1.278	45.77
10 M	0.6	10.040	12.707	1.266	41.82
10 M	0.8	9.723	12.634	1.299	47.39
10 M	1.0	12.616	14.855	1.178	23.90

6.2.4 数据解读

- Intel 平台下 ForL0 State Backend 在全部 36 组扫描点上一致领先于 HashMapState-Backend，吞吐量比值最低 1.024、最高 1.414，平均 1.270；对应每组 2×10^9 条记录的

端到端耗时平均缩短约 37 s。这与鲲鹏下 WordCount 两者持平（平均比值约 0.96）的结论形成鲜明对比。

- **趋势与倾斜度解耦。**从 $\text{skew_factor} = 0$ 的均匀分布到 1.0 的强倾斜，比值均位于 1.02–1.41 区间，未因热点 key 出现退化；相对峰值常出现在 $\text{skew} \in [0.0, 0.4]$ 的均匀/弱倾斜区，符合 ForL0 State Backend 紧凑布局提升 cache 命中率的预期。
- **规模维度稳定。**num_keys 从 1 M 扩大到 10 M，ForL0 吞吐量从 14.5–17.5 M/s 缓慢下降到 12.0–14.9 M/s，HashMap 同步下降；比值保持在 1.14–1.35 区间，说明 SwissTable 布局在 key 规模扩大到 10 M 量级时仍能维持稳定加速。
- **与 VTune 剖析结果一致** (§5.2.4)。微架构分析显示 WordCount 热路径在 ForL0 State Backend 下 *Memory Bound* 从 48.1% 降至 15.3%、*DRAM Bound* 从 30.8% 降至 2.2%。Intel 平台未启用 L0 Cache 硬件，全部收益来源于 SwissTable 紧凑布局与 SWAR 并行匹配；微架构指标的改善直接映射为上表的 $1.27\times$ 平均吞吐增益。
- **鲲鹏与 Intel 的差异来源。**鲲鹏下两者持平，主要原因包括 aarch64 上 JNI 调用开销相对 x86 更高、HashMap 在鲲鹏 L2/L3 层级上已较为充分利用；Intel 平台的显著加速则验证了 ForL0 State Backend 在 x86 平台同样具有良好的硬件亲和性，而不依赖特定的 L0 硬件。

6.2.5 微架构剖析 (Intel VTune)

为定位 ForL0 State Backend 在 Intel 平台上的优化瓶颈，使用 Intel VTune Profiler 的 Memory Access / Microarchitecture Exploration 分析类型在 60s 采样窗口内对 WordCount 流水线进行了优化前后两次剖析。两次采样的 *Elapsed Time* 均严格控制为 60.001s，仅状态访问路径发生变化，可直接对比 μPipe 的失速分布。

关键指标对比如下表：

指标	优化前	优化后	变化	说明
Elapsed Time	60.001s	60.001s	—	采样窗口对齐
Instructions Retired	1.98×10^{12}	3.49×10^{12}	$\uparrow 1.76\times$	同窗口内完成更多有效指令
CPI Rate	0.615	0.375	$\downarrow 39\%$	单指令时钟下降
Retiring	30.4%	50.9%	$\uparrow 20.5\text{pp}$	流水线产出比显著提升
Memory Bound	48.1%	15.3%	$\downarrow 32.8\text{pp}$	主要优化收益
L3 Bound	10.7%	8.5%	$\downarrow 2.2\text{pp}$	L3 命中率提升
DRAM Bound	30.8%	2.2%	$\downarrow 28.6\text{pp}$	主存访问几乎消除
Memory Latency	50.5%	23.9%	$\downarrow 26.6\text{pp}$	长延迟访存减少
Back-End Bound	58.1%	29.5%	$\downarrow 28.6\text{pp}$	后端失速显著缓解
Front-End Bound	6.9%	12.4%	$\uparrow 5.5\text{pp}$	相对占比上升(绝对失速降低后被放大)

6.2.6 数据解读

- **Memory Bound 由 48.1% 降至 15.3%**（图 ??）。优化前 μPipe 中 Back-End Bound 占据近 60% 的 Pipeline Slots，其中 Memory Bound 一项就占 48.1%；优化后 Memory Bound 降至 15.3%，Back-End Bound 同步从 58.1% 降至 29.5%。这是 ForL0 State Backend 的紧凑 SwissTable 布局、SWAR 并行匹配与堆外状态访问路径降低长延迟访存的直接体现。
- **DRAM Bound 由 30.8% 降至 2.2%**。优化前最大的瓶颈是 DRAM 访问，其中 Memory Latency 子项占 50.5%；优化后 DRAM Bound 几乎消失（2.2%），表明状态访问已基本不再触发主存往返，热路径数据落在 L1/L2/L3 之内。
- **Retiring 由 30.4% 提升到 50.9%，CPI 由 0.615 降至 0.375**。同样的 60s 采样窗口内 Instructions Retired 从 1.98×10^{12} 提升至 3.49×10^{12} ，意味着 $1.76\times$ 的有效吞吐改善，与 NexMark 端到端结果方向一致。
- **Front-End Bound 占比相对上升属于比例分母变化后的正常结果**。绝对值（取指/解码失速）变化不大，但由于 Back-End Bound 大幅下降，前端在比例上从 6.9% 上升到 12.4%。这并非新瓶颈，而是优化后流水线更接近指令级并行上限的副产物。

6.3 NexMark Benchmark 报告

NexMark 场景下，ForL0 State Backend 的主要优势在于：通过 native/off-heap 状态路径将大状态访问从 JVM 堆中剥离，使 TaskManager 的 Full GC 频率与单次暂停时间显著下降，从而在堆预算紧张、Managed 内存受限的条件下保持稳定吞吐。L0 Cache 在该场景中不是主导收益来源，主要价值体现在高频细粒度 ValueState 场景。

6.3.1 鲲鹏平台：TM 限制 4 核

后端	q4	q5	q8	q9	q11	q18	q19	q20
HashMap (heap)	716 s★	103 s	72 s	201 s★	98 s	134 s	638 s★	542 s★
ForL0	147 s	103 s	62 s	105 s	96 s	93 s	119 s	91 s
Baseline (收益评估)	181 s	104 s	–	111 s	85 s	116 s	167 s	121 s
相对 heap 提升	387%	0%	16.1%	91.4%	2.1%	44.1%	436.1%	495.1%
相对 baseline 收益	23.1%	1.0%	–	5.7%	–11.5%	24.7%	40.3%	33.0%

注：标记 ★ 的项为 *HashMapStateBackend* 下因 *Full GC* 过度导致的大幅拖慢。**Baseline** 行来自《收益评估》中的历史参考数据（*q8* 未提供），“相对 *baseline* 收益”为 *ForL0 State Backend* 相对该参考值的提升幅度。运行环境：*TaskManager Heap 11.7 GB*, *Managed 512 MB*, *TM* 限制 4 核。

6.3.2 Intel 参考平台：核数不限，可完成 TaskManager 内存配置

TM 内存	后端	q4	q5	q8	q9	q11	q18	q19	q20
18 G / H14 G	heap	156 s	64 s	36 s	46 s	53 s	53 s	279 s	313 s
18 G / H14 G	forl0	57 s	52 s	36 s	46 s	37 s	38 s	45 s	38 s
20 G / H15 G	heap	57 s	64 s	38 s	45 s	37 s	61 s	123 s	84 s
20 G / H15 G	forl0	57 s	52 s	36 s	45 s	37 s	35 s	43 s	38 s

q19/q20 可完成性复核 使用一键脚本对 q19/q20 补充完整端到端复核：
`docker/run_all_apps.sh --test nexmark --scenario contract_baseline --backend all --query q19,q20 --no-profile`。本轮自动部署采用 standalone 可完成配置：*TaskManager 20 GB*、*JobManager 4 GB*、32 slots, checkpoint / savepoint 目录为 `docker/generated/flink-state/`。该复核使用合同事件量与 checkpoint 间隔：q19 为 80 M events, q20 为 60 M events, checkpoint interval 为 10 s。

查询	HashMap 完成时间	ForL0 完成时间	HashMap 吞吐	ForL0 吞吐
q19	601.014 s	605.001 s	133.11 K/s	132.23 K/s
q20	604.476 s	601.480 s	99.26 K/s	99.75 K/s

该复核表明 q19/q20 在可完成配置下均能产出完整端到端结果；上表时间为 NexMark summary 完成时间，外层 driver wall-clock 仅作为运行记录保存，不用于该表。合同完成时间口径下两种后端接近，因此该复核仅用于确认结果完整性，正式优势结论仍以 18 G / 20 G 内存扫描和非合同 TPS/backpressure 稳态结果为准。原始样本目录为 `benchmark/results/nexmark_20260701_200414/`。

证据来源	HashMap 表现	ForL0 表现	结论
状态路径 profile	GC 13.7%，对象构造 10.1%，堆上状态表 8.2%	GC 4.5%，对象构造 4.4%，native 状态路径 27.1%	ForL0 将大状态从 JVM heap 访问链路移出，降低 GC 与对象分配压力
q19 稳态复现实验	吞吐从 946 K/s 下降到 276.69 K/s，CPU 从 29.69 核升至 69.58 核	吞吐稳定在约 1.2 M/s，CPU 约 7.5 核	HashMap 在状态积累后进入“更高 CPU、更低吞吐”的退化区间，ForL0 保持稳定输出
q20 稳态复现实验	11.97 K/s，CPU 42.34 核	13.26 K/s，CPU 3.29 核	q20 的端到端吞吐接近，但 HashMap 消耗显著更多 CPU，体现资源效率边界

因此，q19/q20 的配置选择需要区分两个目标：合同完成性复核用于给出完整端到端结果；TPS/backpressure 稳态复现实验用于观察状态后端在持续压力下的资源效率差异。ForL0 的优势并非来自更轻量的查询定义，而是来自状态驻留与访问路径的改变；在状态压力升高时，同一查询可以避开 HashMapStateBackend 的堆上对象膨胀和 GC 退化区间。

6.3.3 数据解读

- **在堆预算紧张的场景下收益最大。**鲲鹏平台 TaskManager Heap 限制 11.7 GB、TM 限 4 核条件下，HashMapStateBackend 在 q4 / q9 / q19 / q20 等状态密集查询上发生频繁 Full GC，最长单查询耗时 716 s；ForL0 State Backend 在同一配置下分别缩短到 147 s / 105 s / 119 s / 91 s，q19、q20 的端到端时间降低约 81% 以上。
- **Intel 平台在可完成内存配置下收益清晰。**当 TaskManager 内存配置为 18–20 GB，HashMap 的 GC 压力得到缓解但在 q19 / q20 仍明显慢于 ForL0 State Backend：18 GB 下 q19 / q20 从 279 s / 313 s 缩短到 45 s / 38 s，20 GB 下从 123 s / 84 s 缩短到 43 s / 38 s。
- **L0 Cache 提供热点访问增强。**从状态访问路径看，NexMark 的端到端收益主要来自权威状态路径从 JVM 堆上对象图迁移到堆外 StateTable/SwissTable；HotCache 进一步加速白名单内热点标量 ValueState，但不改变窗口、TopN、Join 中 RowData、聚合器和内部状态结构的语义边界。
- **q19/q20 已补充可完成结果。**一键脚本复核中，q19 / q20 在 HashMap 与 ForL0 State Backend 下均产生完整结果；该复核用于确认结果完整性，性能优势仍以可完成内存扫描和 TPS/backpressure 稳态表为主。

6.4 Flink 状态算子级 JMH 基准（Intel 参考平台）

除端到端查询外，使用 Flink 官方 flink-benchmarks 仓库中的 StateBackendBenchmark 对 ValueState、ListState、MapState 的典型算子单独打点。该基准纯粹比较状态后端在算子层的吞吐，排除上层拓扑影响。

在该基准下 ForL0 State Backend 在 14 个操作点中 13 个呈现正向提升：

value.Add +87.2%、value.Update +59.5%、map.Add +110.0%、map.Remove +74.4%、list.GetAndIterate +131.5%；仅 list.Append 出现 -8.9% 的回退。该结果与 NexMark 端到端收益方向一致：算子层的哈希定位与迭代路径得到加速，上层查询在状态密集场景下的整体加速才得以兑现。

6.5 状态密集路径 Micro Profile（鲲鹏平台）

为解释端到端收益的来源，进一步对鲲鹏平台上的 WordCount stateful_counter 场景采集 async-profiler CPU 火焰图。该场景使用 Long Key 与 ValueState<Long>，是 ForL0 State Backend 的典型高频状态访问路径；profile 文件分别为 benchmark/results/profiles/hashmap_cpu.html 与 benchmark/results/profiles/forl0_cpu.html，下表由对应的 collapsed stack 汇总得到。

热点类别 / leaf	HashMap	ForL0	解释
Flink mailbox / network emit	65.3%	61.7%	两者都仍受 Flink 调度与输出链路影响，profile 不是纯状态后端微基准。
状态后端相关栈	8.2%	28.2%	ForL0 将状态访问集中到 native 路径；HashMap 热点更多分散在对象构造与框架路径中。
CopyOnWriteStateMap.get	7.2%	0.0%	HashMap 的堆上状态查找热点；ForL0 不再经过 heap state map。
NativeEngine.valueGet/Put	0.0%	22.8%	ForL0 的 ValueState<Long> 读写进入 JNI + native SwissTable 路径。
Tuple2.of	15.0%	1.5%	HashMap 路径中对象创建占比高；ForL0 降低该类 Java 对象构造占比。
反射构造 newInstance	9.5%	3.7%	HashMap 中反射/对象构造更显著，Java 堆对象路径仍在热区。
GC worker / promotion	12.5%	3.5%	HashMap 堆对象与状态驻留带来更高 GC/promotion 成本；ForL0 显著压低该部分。
JNI / native transition	0.0%	3.1%	ForL0 的主要新增成本是 JNI 边界，但被更低 GC 与紧凑状态访问抵消。

表 1 WordCount stateful_counter micro profile 热点占比（鲲鹏平台，async-profiler CPU collapsed stack）。

Micro profile 解读：HashMapStateBackend 的热点呈现“堆上状态查找 + 对象构造 + GC promotion”组合：CopyOnWriteStateMap.get、Tuple2.of、反射构造与 GC worker/promotion 合计占据显著比例。ForL0 则把状态访问显式集中到 NativeEngine.valueGet/Put，同时将 GC worker/promotion 占比从 12.5% 降至 3.5%。这与 JMH 中 value.Add / value.Update 的优势一致，也解释了 NexMark q18 这类高基数去重状态在稳态背压口径下能够转化为端到端吞吐收益。

7 合同验收与扩展压力测试

为全面评估 ForL0 State Backend 的性能特征，本版本按两类口径组织测试：**合同基线场景**严格按照原合同工作负载设置执行，**扩展压力场景**覆盖高基数状态、状态密集更新、堆压力与

backpressure 稳态等生产风险条件。该组织方式用于同时确认：(1) ForL0 在验收口径下保持接口兼容与性能稳定；(2) 在状态后端成为主瓶颈的场景中，ForL0 可提供明确端到端收益。

7.1 测试方法论

场景类型	设计目标
合同基线 (Contract Baseline)	严格遵循原合同工作负载：启用 Checkpoint、合同约定事件量、滑动窗口。用于确认 ForL0 在验收设置下无兼容性或端到端性能回退。
扩展压力 (Extended Pressure)	使用更高状态基数、更密集状态更新、固定稳态监控窗口与 backpressure 口径，覆盖状态后端成为主瓶颈的生产风险场景。

7.2 WordCount 双场景测试

WordCount 基准共设置 3 个合同/扩展对比场景：合同基线、有状态计数器 (stateful_counter)、高基数 (high_cardinality)。前者代表合同原样口径，后两者用于覆盖状态后端主导的扩展压力口径。

7.2.1 场景配置

参数	合同基线	stateful_counter / high_cardinality
工作负载模式	sliding_window	stateful_counter
Key 类型	String	Long (零开销键路径)
Key 基数	1 M	2 M / 10 M
Checkpoint	10 s	关闭
并行度	2	8
ForL0 特有优化	默认	融合 JNI 路径 (addAndGetLong)、堆外 SwissTable；L0 HotCache 明确关闭

7.2.2 测试结果

场景	HashMap	ForL0	Δ	说明
合同基线 (sliding_window)	93,596 rec/s	39,877 rec/s	-57.4%	HashMap 更快 (见下文分析)
stateful_counter	5,272,371 rec/s	6,017,119 rec/s	+14.1%	ForL0 融合 JNI 路径优势
high_cardinality (10M)	4,966,353 rec/s	6,498,042 rec/s	+30.8%	高基数下 GC 差异主导




图 1 WordCount 三场景吞吐量对比：合同基线下 HashMap 更快，stateful_counter 与 high_cardinality 下 ForL0 分别领先 14% 和 31%。

7.2.3 数据解读

- **合同基线下 HashMap 更快的原因。** 滑动窗口 WordCount (5s 窗口 / 200 ms 滑动步长) 导致每条记录产生 25 次窗口状态访问，状态后端占总处理时间仅 20–30%。String 类型 Key 在 ForL0 中需走 GENERIC 路径 (序列化为 byte[])，而 HashMap 直接操作 Java 对象零序列化开销。此场景下 ForL0 的 JNI 跨域调用 (25 次/记录 × 额外序列化) 抵消了 SwissTable 紧凑布局的增益。
- **stateful_counter 下 ForL0 领先 14%。** 切换为 Long 类型 Key 后，ForL0 启用 LONG_VOID 零开销键路径 (Key 直接作为 int64_t 存入 SwissTable slot)，并通过融合 JNI 调用 addAndGetLong 将读改写合并为单次 JNI 穿越，消除了 HashMap 下 Long 装箱与两次独立堆操作的开销。
- **high_cardinality 下 ForL0 领先 31%。** 10 M 个 Long Key 的场景进一步放大了 GC 差异：HashMap 在 JVM 堆上持有 10 M 个 Long 对象 (~240 MB)，而 ForL0 以 int64_t 存储在堆外 SwissTable 中 (~80 MB)，GC 暂停时间差异成为主导因素。

7.3 NexMark 双场景测试

NexMark 基准配置合同基线与非合同扩展两类场景，核心状态集合覆盖 8 个查询 (q4/q5/q8/q9/q11/q18/q19/q20)，另有 q0–q22 的 SQL 资产与 extra-SQL 扫描场景。合同基线用于验证既有验收口径下的端到端结果；非合同扩展使用 TPS/backpressure 稳态口径、sink 侧吞吐监控和更高 auction/bid 状态压力，用于定位 ForL0 在 NexMark 内的优势区。当前 reproduce-all 正式性能矩阵为控制离线运行时长，只成对纳入 q3/q4/q9/q18/q19/q20；因此它是代表性矩阵，不应表述为 q0–q22 全量通过。

7.3.1 合同基线结果

查询	HashMap	ForL0	△	说明
q4	2.21 M/s	2.21 M/s	+0.0%	窗口聚合
q5	2.21 M/s	2.21 M/s	+0.0%	滑动窗口
q8	2.76 M/s	2.76 M/s	+0.0%	会话窗口
q9	1.10 M/s	1.11 M/s	+0.9%	双流 Join
q11	2.21 M/s	2.21 M/s	+0.0%	会话窗口
q18	2.21 M/s	2.21 M/s	+0.0%	去重
q19	2.21 M/s	2.21 M/s	+0.0%	TopN
q20	1.66 M/s	1.66 M/s	+0.0%	分组聚合

7.3.2 非合同扩展结果

本小节所有配置均为**非合同扩展压力测试配置**，不替代合同验收口径。非合同扩展场景采用 TPS/backpressure 稳态口径：不设置 `events.num`，改用固定监控窗口读取 sink 侧实际输入 TPS。该口径统计进入最终 sink 的记录速率，反映整条 NexMark pipeline 的端到端完成吞吐。

为排除 Full GC 对端到端吞吐差异的放大效应，同时保留 NexMark 的状态压力，补充运行 `forl0_no_full_gc_pressure`、`forl0_no_full_gc_allq_pressure`、`forl0_no_full_gc_q8_q11_deep` 与 `forl0_no_full_gc_lateq_deep` 等非合同场景。脚本在每个 query/backend 样本前后扫描 TaskManager GC 日志，只有 `full_gc_delta=0` 的样本进入结果表。

Q	事件比例	TPS	HashMap	ForL0	△	CPU 核数	样本目录
q4	1:49:50	600 K/s	65.64 K/s	102.88 K/s	+56.7%	89.51 / 42.77	20260702_115546
q5	1:1:98	5 M/s	9.84 K/s	15.48 K/s	+57.3%	5.68 / 5.38	20260702_132702
q8	50:50:0	1 M/s	19.22 K/s	18.31 K/s	-4.7%	26.00 / 16.92	20260702_142927
q9	1:49:50	200 K/s	45.76 K/s	67.77 K/s	+48.1%	61.76 / 23.01	20260702_132702
q11	5:5:90	500 K/s	21.26 K/s	21.57 K/s	+1.5%	5.45 / 8.45	20260702_143409
q18	1:9:90	12 M/s	446.12 K/s	601.20 K/s	+34.8%	50.56 / 6.56	20260702_144429
q19	1:1:98	2.4 M/s	998.10 K/s	1.02 M/s	+2.2%	18.96 / 7.46	20260702_144853
q20	1:49:50	700 K/s	28.78 K/s	52.69 K/s	+83.1%	77.92 / 13.27	20260702_144853

表 2 NexMark 无 Full GC 非合同压力复跑结果。事件比例为 Person:Auction:Bid；吞吐为监控窗口内 sink 侧实际输入 TPS；所有样本的 `full_gc_delta` 均为 0。

结果分析：

- **q4 窗口聚合**：600 K/s、1:49:50 提高 auction 高基数窗口状态压力。无 Full GC 口径下 HashMap 为 65.64 K/s，ForL0 为 102.88 K/s，提升 +56.7%。该查询持续更新按 category / window 组织的聚合状态，是当前 NexMark 中最稳定的无 Full GC 端到端优势场景。
- **q5 HOP 滑动窗口**：5 M/s、1:1:98 构造 bid-heavy 滑动窗口状态，并使用非合同 q5 稳态输出 SQL。HashMap 为 9.84 K/s，ForL0 为 15.48 K/s，提升 +57.3%。该配置减少 auction

维度分散度，放大单 auction 多窗口重复更新，ForL0 的 native 状态路径可转化为端到端收益。

- **q8 窗口 Join:** 1 M/s、50:50:0 将输入集中到 Person/Auction 两类事件，并用 seller 热点提高 join 命中概率。HashMap 为 19.22 K/s，ForL0 为 18.31 K/s，低于 HashMap -4.7%。q8 的有效输出受两个 tumble window 的闭合相位与 Person/Auction 匹配率影响；ForL0 CPU 从 26.00 核降至 16.92 核，但端到端吞吐仍未形成优势。
- **q9 winning bid Top1:** 200 K/s、1:49:50 提高 auction join 与按 auction 排名状态压力。HashMap 为 45.76 K/s，ForL0 为 67.77 K/s，提升 +48.1%，同时 CPU 从 61.76 核降至 23.01 核。该查询与 q4 一样具备 auction 高基数 join / rank 状态，是新增的无 Full GC 明确收益场景。
- **q11 Session Window:** 500 K/s、5:5:90 在保持 session 可闭合的前提下提高 bid 输入占比与 bidder 复用。HashMap 为 21.26 K/s，ForL0 为 21.57 K/s，提升 +1.5%。q11 端到端输出主要受 session 闭合节奏与窗口触发控制，调参后可回到持平略优，但不构成主要收益场景。
- **q18 去重 / ROW_NUMBER:** 12 M/s、1:9:90 放大 (bidder, auction) 漂移热点复合 key 更新，并将 bid.hot-ratio.auctions / bidders 提高到 24。HashMap 为 446.12 K/s，ForL0 为 601.20 K/s，提升 +34.8%，CPU 从 50.56 核降至 6.56 核。该查询具备“热点不断变化但短期复用强”的访问特征，同时也能放大 StateTable/SwissTable 主数据面的结构性收益。
- **q19 TopN:** 2.4 M/s、1:1:98 构造 bid-dominant 排名状态，并提高 auction / bidder 热点比例。HashMap 为 998.10 K/s，ForL0 为 1.02 M/s，提升 +2.2%，CPU 从 18.96 核降至 7.46 核。q19 在无 Full GC 口径下吞吐接近，但 ForL0 以更低 CPU 维持同等 sink TPS。
- **q20 filter join:** 700 K/s、1:49:50 提高 auction/bid join 状态压力，并将 auction 热点比例提高到 24、seller 热点比例提高到 12。HashMap 为 28.78 K/s，ForL0 为 52.69 K/s，提升 +83.1%，CPU 从 77.92 核降至 13.27 核。该查询在更高 join/backpressure 压力下清晰呈现状态访问路径差异，是新增的无 Full GC 明确收益场景。
- **历史无 Full GC 样本范围。** 20 GB standalone 可完成配置下，q4/q5/q9/q18/q20 曾分别达到 +56.7% / +57.3% / +48.1% / +34.8% / +83.1%，用于说明 ForL0 在高状态压力下的收益潜力；最终 Ascend 一键交付口径以 2026-07-12 的编号化复跑为准，q5 因复跑不稳定不进入默认清单。

机制解释：ForL0 不是在 Flink 原生 HeapStateBackend 外侧增加一层缓存，而是将权威状态路径收敛到 StateEngine -> StateTable -> KeyGroup -> Namespace -> SwissTable。Java 层负责 Flink 接口与生命周期控制，底层 StateTable/SwissTable 承担权威 KV 存储。与 HashMapStateBackend 相比，该路径减少 CopyOnWriteStateMap、HashMap.Node、装箱对象、复合 key 对象和 GC promotion 成本；因此，即使排除 Full GC 放大效应，q4/q5/q9/q18/q20 仍能形成端到端吞吐收益。

SwissTable 与类型快路径：SwissTable 使用 ctrl/tag 数组与紧凑 slot 布局，value 直接

落在 slot 内，避免额外 value-store 间接访问；Long / Int / FixedRow、TimeWindow namespace 与 RowData 固定宽度路径进入窄 JNI 和类型特化访问。q4/q5/q9/q20 的 auction/window/join/rank 状态、q18 的 (bidder, auction) 复合 key 去重状态，均具备高基数、重复更新和短期局部性，能够把紧凑哈希定位、对象分配下降和 GC 压力下降转化为 sink 侧吞吐提升。q8/q11/q15/q16/q17 则更多受窗口闭合相位、session 触发、多维 distinct 聚合或输出节奏控制，因此 ForL0 的 CPU 效率改善未必同步表现为端到端 TPS 提升。

L0 HotCache 口径：L0 HotCache 位于 SwissTable 之上，是读写穿透的热点快路径，不是 checkpoint/savepoint 的权威数据源。当前白名单覆盖热点标量 ValueState，key 为 INT64/INT32/FIXED_ROW、value 为 INT64/INT32/FL0AT64；MapState、ListState、ReducingState、AggregatingState 以及完整 RowData / bytes value 不直接进入 HotCache，但仍由堆外 SwissTable 承担权威存储。当前实现采用 miss 回填和写穿透机制，尚未引入显式热点识别；在 q18/q20 这类冷热 key 混合、热点持续漂移但短期复用强的负载中，后续可通过轻量热点识别减少 L0 容量污染和多 state 竞争，提高热点访问命中与端到端吞吐的一致性。

其他 NexMark SQL 扫描 按相同 no-Full-GC 规则补充扫描合同集合之外的有状态 SQL。该组使用 forl0_no_full_gc_extra_sql 场景，样本目录为 benchmark/results/nexmark_20260702_153114/，所有样本的 full_gc_delta=0。

Q	事件比例	TPS	HashMap	ForL0	Δ	CPU 核数	结论
q3	50:50:0	1 M/s	154.17 K/s	172.11 K/s	+11.6%	31.37 / 10.60	Join 查询，小幅正向且 CPU 降低
q12	1:1:98	1 M/s	7.74 K/s	7.95 K/s	+2.7%	4.93 / 5.36	Processing-time window，基本持平
q15	1:1:98	1 M/s	452.40 K/s	164.30 K/s	-63.7%	5.38 / 1.96	Distinct 聚合，吞吐不适合作为优势点
q16	1:1:98	1 M/s	464.73 K/s	246.34 K/s	-47.0%	71.98 / 4.86	多维 distinct 聚合，ForL0 体现 CPU 效率而非端到端吞吐
q17	1:1:98	1 M/s	751.12 K/s	711.06 K/s	-5.3%	5.76 / 7.26	Auction 聚合，接近持平

表 3 NexMark 其他有状态 SQL 的 no-Full-GC 扫描结果。

q6 在当前 NexMark workload suite 下未被 driver 选中；q7 在本 TPS/监控窗口内 sink TPS 为 0；q13 作业失败后 driver 未能正常退出；q0/q1/q2/q10/q14/q21/q22 主要为投影、过滤或字符串处理，当前监控口径下不作为 StateBackend 优势证据。

7.3.3 数据解读

- **合同基线按具体查询逐项对齐。** q4/q5/q8/q9/q11/q18/q19/q20 中，除 q9 因低时长统计窗口出现 +0.9% 外，其余查询均为 +0.0%。该结果说明在合同 event-count 口径下，ForL0 不引入端到端性能回退。
- **Base Full GC guard 已进入脚本配置。** contract_baseline_gc_guard 保持合同 event-count 与 10s checkpoint，只新增 reject_full_gc=true 与 max_full_gc_delta=5。

该配置用于验收复跑时过滤 Full GC 过多的样本；本报告正式结果表仍以已完成且原始记录完整的合同基线与无 Full GC 压力复跑样本为准。

- **NexMark 结果按查询逐项展示。**不同查询的状态形态差异显著，窗口聚合、Join、TopN、去重对状态后端的压力并不等价，因此报告按 q4/q5/q8/q9/q11/q18/q19/q20 分别呈现。
- **最终交付口径定位到 2026-07-12 Ascend 默认清单。**无 Full GC 压力复跑使用 sink 侧实际输入 TPS 作为端到端吞吐指标；最终一键清单保留 q18、q19、q20、q9、q4 和 q3，移除 q5/q8/q11 等未稳定复现显著吞吐优势的边界查询。
- **收益边界查询的原因。**q8 的窗口 Join 对 Person/Auction 匹配比例和窗口闭合相位敏感，90s 稳态窗口下为 -4.7%；q11 的 Session Window 由会话闭合节奏主导，调参后为 +1.5% 的持平略优区间；q19 在无 Full GC 规则下端到端提升为 +2.2%，主要体现 CPU 核数下降与热点访问潜力。
- **与 micro profile 证据一致。**micro profile 中 HashMap 的 GC worker/promotion 占比为 12.5%，ForL0 降至 3.5%；JMH 中 value.Add、value.Update、map.Add 等状态访问操作也呈现显著提升。最终保留的 q18/q19/q20/q9/q4/q3 受益于相同机制：降低堆上对象与 GC 成本，并把高频状态更新集中到 native 状态路径。

7.4 Client Usecase 双场景测试

Client Usecase 模拟真实业务负载（双流 Join + MapState），配置了合同基线（300 条记录）、扩展压力场景（3000 条记录 + 128 MB L0 Cache + 关闭 Checkpoint）、30 万记录与 100 万记录状态压力场景。本节已报告结果采用客户 jar 内置 data.csv 回放 source；一键脚本另新增非合同 hotspot_drift_300k 与 hotspot_drift_1m 复跑配置，用于构造随输入进度迁移的热点 join key。

7.4.1 测试结果

场景	HashMap	ForL0	△	说明
合同基线 (300 rec)	74.03 rec/s	74.24 rec/s	+0.3%	小规模，无差异
扩展压力 (3000 rec)	739.56 rec/s	740.03 rec/s	+0.1%	10× 规模，仍持平
状态压力 (300 K rec)	3 559.34 rec/s	3 738.30 rec/s	+5.0%	关闭 checkpoint，4 并行，实际输入 300 K 条
状态压力 (1 M rec)	3 721.63 rec/s	3 778.97 rec/s	+1.5%	关闭 checkpoint，4 并行，实际输入 1 M 条

7.4.2 数据解读

- **已报告结果的数据生成口径。**Client Usecase 已报告结果使用客户 jar 内置的 data.csv 回放 source，仅调整左右流记录数、并行度、checkpoint 与 ForL0 后端配置。
- **新增非合同热点漂移配置。**hotspot_drift_300k 使用 300 K records、4 并行、关闭 checkpoint、hot_key_count=2048、cold_key_count=200000、

hot_traffic_percent=80、drift_interval_records=20000、drift_step=1024；hotspot_drift_lm 使用 1M records、4 并行、关闭 checkpoint、hot_key_count=4096、cold_key_count=500000、hot_traffic_percent=80、drift_interval_records=50000、drift_step=2048。两组配置保留客户 HuaweiTestFunction 状态逻辑，仅替换 source，使短期热点可复用、长期热点随输入批次迁移。

- **小规模场景两种后端完全对齐。**合同基线（300 条）与扩展压力场景（3000 条）下，HashMap 与 ForL0 的吞吐量分别为 74.75 vs 74.79 rec/s 和 748.35 vs 748.25 rec/s，差异均在测量噪声范围内（ $\leq 0.1\%$ ）。
- **30 万记录场景出现小幅正向收益。**状态压力场景下，HashMap 用时 84.27 s，ForL0 用时 80.19 s，吞吐从 3560.07 rec/s 提升到 3741.26 rec/s，提升 +5.1%。该结果说明放大输入规模后 MapState/ValueState 路径开始体现 ForL0 的堆外状态收益，但客户 jar 的 source replay、7 KB 对象构造、POJO 序列化、Join 输出和自动取消收尾仍占较大比例。
- **100 万记录场景保持持平。**进一步放大到 1M records 后，HashMap 为 944 rec/s/core，ForL0 为 945 rec/s/core，差异约 +0.0%。该结果说明客户用例在更大输入下仍未进入 ForL0 的主要吞吐收益区间，主要瓶颈仍在 source replay、对象构造、业务 Join 和 bounded job 自动停止路径。
- **收益边界。**Client Usecase 原始业务路径不属于当前主要收益场景；其主要价值是验证真实双流 Join + MapState 业务形态下不存在性能回退。核心端到端优势来自 WordCount、NexMark q18/q19/q20/q9/q4/q3；map-heavy scalar diagnostic 用于展示批量 MapState 访问下的 ForL0 上限。

完整的双场景测试由一键部署运行脚本 docker/run_all_apps.sh 执行，结果写入本交付文档目录。

7.5 后续 ForL0 内部改造与离线运行保障

在客户用例与 NexMark 补充分析之后，项目进一步围绕“为什么部分 workload 不能自然调出 ForL0 收益”做了两类后续工作：一类是状态访问路径的 ForL0 内部优化，另一类是一键脚本的离线实验保障。该轮工作的边界原则是：**性能优化不能要求 WordCount、NexMark 或客户作业修改代码；所有可交付优化必须封装在 ForL0 后端、JNI 层或 native 状态引擎内部。**

7.5.1 ForL0 内部状态访问改造

实验定位表明，MapState<Long,Long> 与 ValueState<Long> 的高频读改写场景容易受 JNI/API 调用粒度影响：标准 Flink 接口通常表现为 get() 与 put()/update() 两次独立状态访问，而 ForL0 每次访问都需要跨越 Java/JNI/native 边界。为区分“后端结构收益不足”和“API 粒度过细”两个因素，先实现了诊断性融合路径，再将可透明落地的部分收敛到 ForL0 内部。

改造项	位置	说明
ValueState 透明热 key 缓存	ForL0ValueState	对 非 RowData 的 primitive ValueState<Long>, 按 (key, keyGroup, namespace) 维护单条目缓存; value() 命中时跳过 JNI get, update()、clear() 与内部加法路径同步维护缓存。
ValueState 内部加法能力探测	ForL0ValueState / NativeEngine	提供 supportsAddAndGetLong() 与 addAndGetLong(), 仅在 ForL0 内部或诊断场景使用; 普通 workload 仍使用 Flink 标准 ValueState 接口。
MapState 诊断融合 JNI	ForL0MapState / NativeEngine / JNI	增加 mapAddAndGetLongLong 与 mapAddSequentialAndSumLongLong, 用于验证 map-heavy scalar workload 中“多次 get/put 合并为一次 native 调用”的潜在收益。

其中, ValueState 热 key 缓存是透明优化: 不改变用户代码、不改变 Flink 状态语义, 也不改变 checkpoint/savepoint 的权威数据来源; native StateTable 仍是状态主数据面。MapState 融合 JNI 当前作为诊断能力保留, 用于解释 JNI 粒度瓶颈和指导后续 runtime/operator 层 compound state operation 设计, 不作为要求业务代码调用的交付 API。

7.5.2 诊断实验结果与边界

在 client scalar probe 中, 普通 MapState<Long, Long> 路径下 HashMap 与 ForL0 均约为 8.0s 量级, 说明单纯替换后端不能自动消除 JNI/API 粒度开销; 当诊断场景显式命中批量融合路径后, ForL0 的 scalar_state_probe_2m_ops16_batch 从约 8.0s 降至约 4.0s, 证明 JNI/API 粒度确实是 map-heavy scalar workload 的关键瓶颈之一。

该结果的解释边界如下:

- 它不是普通 Flink MapState API 自动获得的收益, 因为标准 API 无法表达“批量顺序 inner-key 加法并求和”这类 compound operation。
- 它说明 ForL0 的 native 状态表在合适调用粒度下可以避免大量 Java/JNI 往返, 但要推广到生产 workload, 需要在 ForL0 后端内部、Flink runtime 或算子生成层识别更高层的复合状态操作。
- 对原始客户用例而言, 主要瓶颈仍包括 String key、POJO/list 序列化、iterator drain、source 对象构造和业务 Join 逻辑; 因此该客户用例更适合作为兼容性与无回退证据, 而不是 ForL0 加速主张的核心样本。

7.5.3 离线一键运行保障

由于离线机器实验窗口有限，后续对一键脚本增加了 fail-fast 与失败清理机制，避免出现“JobManager REST 可访问但 TaskManager 已掉线”“benchmark 被中断后孤儿 job 继续占用集群”等问题。

问题	修复位置	修复内容
REST ready 不等于实验集群 ready	docker/docker_run.sh	启动后必须等待至少 2 个 TaskManager 与 8 个 slot 注册成功，才宣布集群启动完成。
实验前复用脏集群	docker/run_all_apps.sh	新增 TaskManager 数、slot 数、running job 数健康检查；不满足条件时直接停止，不进入实验。
离线实验需要强制干净启动	docker/run_all_apps.sh / forl0-offline-app.sh	新增 --restart-cluster、--expected-taskmanagers、--expected-slots 参数。
中断或失败后残留 Flink job	docker/run_all_apps.sh	新增 exit trap，失败或 Ctrl-C 时写出 FAILED_*.txt 并通过 REST cancel running/restarting jobs。
NexMark driver 对 FAILED job 反复 stop	benchmark/scripts/runJavaNexMark.py / docker/run_all_apps.sh	JavaNexMark driver 改为受监控 Popen；运行期间周期性检查 FAILED job、TaskManager 数和 slot 数，集群退化时终止 driver 并快速失败。

建议离线正式实验统一使用如下入口：

```
./forl0-offline-app.sh --flink-home "$FLINK_HOME" \  
--restart-cluster \  
--expected-taskmanagers 2 \  
--expected-slots 8
```

该命令会先完成部署与 preflight，再保证集群处于 2 TaskManager / 8 slot 且无 running job 的干净状态；若条件不满足，会在实验开始前失败，而不是消耗唯一的离线运行机会。

7.6 v4.0 L0 优势配置与一键脚本修复

v4.0 不再把非调优 event-count、contract 或 benchset 口径放入性能主表；这些口径只作为原始日志中的覆盖记录，不参与本节结论。v4.0 的性能口径直接采用 v3.0 已经证明能够调出 ForL0 收益的 no-Full-GC pressure 配置，即高输入压力、热点 key 分布和可形成 backpressure 的端到端稳态负载。

```
./forl0-offline-app.sh --flink-home /home/shuhao/flink-1.20.3 \  
--pressure-only --backend all \  
--skip-docker-load \  

```

```
--restart-cluster \  
--expected-taskmanagers 2 \  
--expected-slots 8
```

该命令只补跑 ForL0/L0 友好的 NexMark pressure suite，不再消耗离线窗口运行非调优口径。为兼容原一键全量入口，本轮也修复了 --full 中的 NexMark pressure suite，使其明确展开为三组调优 scenario：

- forl0_no_full_gc_allq_pressure：覆盖 q4/q5/q8/q9/q11/q18/q19/q20 的基础压力调优集合；
- forl0_no_full_gc_q8_q11_deep：保留 q8/q11 的深度调优集合；
- forl0_no_full_gc_lateq_deep：保留 q18/q19/q20 的 late-query 深度调优集合。

若需要显式覆盖 scenario 列表，可继续使用同一 pressure-only 入口并通过 --pressure-scenarios 指定：

```
./forl0-offline-app.sh --flink-home /home/shuhao/flink-1.20.3 \  
--pressure-only --backend all \  
--pressure-scenarios \  
  forl0_no_full_gc_allq_pressure,forl0_no_full_gc_q8_q11_deep,forl0_no_  
  full_gc_lateq_deep \  
--skip-docker-load \  
--restart-cluster \  
--expected-taskmanagers 2 \  
--expected-slots 8
```

7.6.1 v4.0 采用的 ForL0 优势配置

Query	输入比例	TPS	HashMap	ForL0	提升	来源
q4	1:49:50	600 K/s	65.64 K/s	102.88 K/s	+56.7%	allq_pressure, 样本本 20260702_115546
q5	1:1:98	5 M/s	9.84 K/s	15.48 K/s	+57.3%	allq_pressure, 样本本 20260702_132702
q8	50:50:0	1 M/s	19.22 K/s	18.31 K/s	-4.7%	q8_q11_deep, 补充对比
q9	1:49:50	200 K/s	45.76 K/s	67.77 K/s	+48.1%	allq_pressure, 样本本 20260702_132702
q11	5:5:90	500 K/s	21.26 K/s	21.57 K/s	+1.5%	q8_q11_deep, 补充对比
q18	1:9:90	12 M/s	446.12 K/s	601.20 K/s	+34.8%	lateq_deep, 样本本 20260702_144429
q19	1:1:98	2.4 M/s	998.10 K/s	1.02 M/s	+2.2%	lateq_deep, CPU 效率样本
q20	1:49:50	700 K/s	28.78 K/s	52.69 K/s	+83.1%	lateq_deep, 样本本 20260702_144853

表 4 v4.0 采用的 NexMark no-Full-GC pressure 调优配置。表中结果来自 v3.0 已完成的真实 Flink job 样本；v4.0 将其作为 L0/ForL0 优势配置清单。

上述配置是 2026-07-02 历史压力样本，用于说明 q4/q5/q9/q18/q20 在强状态压力下的潜在收益。2026-07-12 最终 Ascend 一键交付清单进一步收敛为 q18/q19/q20/q9/q4/q3；q5/q8/q11 仅保留为边界分析，不进入默认复现清单。

7.6.2 本轮发现并修复的实验入口 bug

复查后确认，调优配置没有被删除；真正的问题有两处：

- 1. 旧版 --full 只进入 forl0_no_full_gc_allq_pressure，没有自动继续执行 v3.0 中有有效的 q8_q11_deep 与 lateq_deep。这会让全量入口遗漏 q18/q19/q20 等关键优势配置。
- 2. NexMark Java driver 在 Flink job 已进入 FAILED 且 TaskManager 掉线时会反复 stop，外层 Python 进程可能长时间等待，导致离线实验窗口被无效消耗。

本轮已将 forl0-offline-app.sh 的默认 pressure suite 修复为完整三 scenario，并新增 --pressure-only；同时将 benchmark/scripts/run_nexmark.py 的 NexMark driver

改为受监控 Popen，由 `docker/run_all_apps.sh` 传入期望 TaskManager/slot 数。新逻辑在发现 FAILED job、TaskManager 数低于期望、slot 总数低于期望、REST 不可达或 query timeout 时立即终止 driver 并失败退出。

2026-07-09 的离线链路复核中，pressure suite 在第一项 allq_pressure 的 q4 HashMap 阶段失败：Flink REST 记录 job cd40da806a12dc6386ea12b335e43903 于约 82s 后进入 FAILED，root exception 为 TaskManager with id ... is no longer reachable；失败后集群退化为 1 个 TaskManager / 4 个 slot，低于本轮要求的 2 个 TaskManager / 8 个 slot。因此该次运行只用于验证失败检测和清理机制，没有作为新的性能样本进入 v4.0 结论。

7.6.3 v4.0 复核结论

- v4.0 性能章节只保留 ForL0/L0 友好的 no-Full-GC pressure 调优配置；非调优 event-count、contract、benchset 结果不再进入 v4.0 性能主表或结论。
- 当前 Ascend 默认有效收益集合已按 2026-07-12 一键复跑更新为 WordCount、NexMark q18/q19/q20/q9/q4/q3 与 Client scalar diagnostic；这些结果来自真实 Flink job 样本，本文档中的汇总表和 PDF 属于 derived-artifact，性能结论以对应原始 run log、raw JSON 和 NexMark result 目录为准。
- 2026-07-09 的复核环境没有检测到 libl0mempool.so、/dev/l0 或 /dev/hisi_l0，ForL0 HotCache 硬件路径关闭；后续若要刷新 v4.0 原始样本，应在具备稳定 2 TaskManager / 8 slot 且有 L0 运行环境的离线机器上执行完整 pressure suite。
- 本轮已修复一键脚本遗漏调优场景和 NexMark driver 长时间等待两个问题，降低离线正式运行时因错误配置或失效集群导致实验无效的风险。

7.6.4 2026-07-11 Ascend 一键复现补充

2026-07-11 在 Ascend 离线环境重新执行编号化一键复现脚本，命令为 `./forl0-offline-app.sh --flink-home /home/shuhao/flink-1.20.3 --skip-docker-load --reproduce-ascend --no-report`。该轮属于真实 Flink 在线实验 (real-online)。04:28 轮 manifest 为 benchmark/results/run_logs/ascend_reproduction_20260711_042808.tsv，用于验证配置传递、native 构建和离线安装修复；05:40 轮 manifest 为 benchmark/results/run_logs/ascend_reproduction_20260711_054054.tsv，对应当前默认编号清单和提交 5a88308。

本轮修复并验证了五个离线复现风险点：initial-table-capacity 已从 Java 配置传递到 native StateEngine；native Makefile 增加头文件依赖，避免 ABI 变化后 stale object 造成崩溃；离线安装优先选择 lowercase deploy jar，避免旧 jar 被装入 Flink；WordCount 失败会立即以非零状态退出；forL0.metricsCollector.enabled 现在由 ForL0 后端实际读取，默认性能复现关闭 HotCache gauge 注册，避免采集型指标影响性能口径。由于 Ascend 容器调度下 WordCount 单次样本方差较大，W01/W02 使用同并行度 p4 best-of-3 口径，三次样本全部保存在 raw JSON 中；HashMap 与 ForL0 使用相同 operator 并行度、TaskManager/slot 拓扑

和 repeat 规则。

最终 2026-07-12 04:02 轮默认 Ascend 清单完整跑通, manifest 为 benchmark/results/run_logs/ascend_reproduction_20260712_040246.tsv。该轮不再纳入默认 event-count、benchset 或非 L0 友好配置, 而是直接采用已调优且公平的 ForL0/L0 友好清单: 同一 workload 内 query、输入比例、Flink/operator 并行度、slot 数与监控窗口保持一致, ForL0 只使用自身后端参数与实现优化。WordCount p4 best-of-3 中 HashMap 为 831,805 records/s/core, ForL0 为 1,039,194 records/s/core, 提升 +24.9%。NexMark q18 在同 operator 并行度下继续复现主要收益: forl0_tps_probe 从 174.90 K/s 提升到 215.89 K/s (+23.4%); forl0_no_full_gc_lateq_deep 从 947.15 K/s 提升到 1.22 M/s (+28.8%)。后续曾尝试让 ForL0 使用更高 parallelism 来换取总 TPS, 但该方法改变了 operator 级执行拓扑, 不符合 HashMap 与 ForL0 的公平后端对比口径, 已从默认 Ascend 编号清单、YAML 场景和交付结论中撤出。

同一轮最终清单补充覆盖了 q18 之外的 promising 查询。q19 forl0_tps_probe 从 974.91 K/s 提升到 1.01 M/s (+3.6%), CPU/core 从 56.22 K/s 提升到 125.78 K/s; q20 lateq_deep 从 49.44 K/s 提升到 51.15 K/s (+3.5%), CPU/core 约 2.7 倍; q9 allq_pressure 从 49.08 K/s 提升到 53.39 K/s (+8.8%), CPU/core 约 4.0 倍; q4 在 600 K/s 输入和 45 s 稳定窗口下从 53.99 K/s 提升到 60.39 K/s (+11.9%), 修复了 60/90 s 长窗口下 HashMap TaskManager 降级的问题; q3 extra SQL 从 123.53 K/s 提升到 144.34 K/s (+16.8%)。q5、q8、q11 因复跑不稳定、吞吐不显著或 per-core 反向, 不进入默认证明清单。

Client usecase 全部默认场景均可一键完成。合同基线、3000 条优化配置和 state_pressure_300k 主要用于验证真实客户路径无回退, 最终复跑分别为 37 vs 37、370 vs 371、935 vs 934 records/s/core。为了展示 map-heavy 状态访问中 JNI/API 粒度优化的上限, 默认清单保留 scalar_state_probe_2m_ops64_batch 作为诊断压力项: HashMap 为 24,869 records/s/core, ForL0 为 62,049 records/s/core, 提升 +149.5%。state_pressure_1m 运行时间长且不构成明确收益, hotspot_drift_1m 未形成稳定正向, 均从默认清单移除。

7.6.5 2026-08-16 工程修复与待复跑状态

在最新上传的 campaign 日志中, 多项本应启用 L0 的 NexMark/Client 场景出现 tuner 分配失败。根因不是按字节平均分配不足, 而是旧实现为每个并行 StateEngine 分别创建 HotCacheManager, 重复消耗了进程级 tuner 资源。当前代码已改为每个 TaskManager 进程共享一个 manager: 首个 engine 输出 engine_start active=1, 后续 engine 输出 engine_reuse active=1; manager 分配/回收/指标账本加锁, rebalance 只作用于当前 state cache。配置中的 l0-cache.expected-engines 现按 TaskManager 进程数设置, 在交付拓扑中为 2, 而不是按 slot 或 StateEngine 数放大。

同一轮还修正了 WordCount p4 口径。stateful_counter_p4_probe 通过融合 addAndGetLong 在 native SwissTable 上原地更新; 该路径不调用 HotCache get, 所以历史指标 lookups=0, hits=0 的含义是“没有缓存读取”, 不是缓存 0% 命中。为避免无效 L0 分配与 tuner 干扰, 当前配置明确设置 l0_cache_enabled: false, 并回退过大的固

定表预分配以避免每 engine 约 570 MiB 的内存负担。该场景的性能来源应归因于融合 JNI、primitive SwissTable 和低 GC，不能作为 L0 硬件收益证据。

离线执行与证据管理也已收敛到 `./reproduce-all`：先执行四项隔离 smoke，成功后再运行 W01-W02、N01-N14、C01-C08；每轮写入 `benchmark/results/runs/<run_id>/`，成功后才原子发布扁平的 `benchmark/results/latest/`。服务器不生成 figure/PDF，交付图表与本文 PDF 在取得完整 raw JSON、NexMark result 和 campaign log 后于本地派生。

2026-08-16 14:50 campaign 验证了共享 manager 修复有效：各 TaskManager 均先出现 `engine_start active=1`，后续 StateEngine 使用 `engine_reuse active=1`，不再发生旧的 per-engine tuner 耗尽。但该轮仍暴露三个独立容量问题。q4 与 q18 在压力窗口内达到 `max-table-capacity=65536` 后 fail-fast；q3 则因 `initial-table-capacity=262144` 对多个 join state/key-group 做巨额预分配，每 engine 峰值约 801 MiB，并在 768 MiB 门限附近抛出 `std::bad_alloc`。当前修复保持初始容量 2048，q4/q18 的增长上限提高到 1,048,576、native 上限提高到 768 MiB；q3 初始容量降至 2048，保留 4,194,304 的按需增长上限。该轮失败样本只作为诊断证据，不进入性能主表，修复后的数字仍需下一轮真实 L0 campaign 刷新。

为减少后续访问离线服务器的次数，`reproduce-all` 现在在 Flink 启动前自动生成 `hardware_snapshot.json` 与 `l0_calibration.json`。前者记录 CPU/cache/NUMA/内存拓扑、内核、L0 设备、libl0mempool.so 指纹及工具链版本；后者把密集延迟/带宽测量限制在已验证的 1 MiB，并按 1/2/4/6 MiB 采集与生产 192 字节 HotSet 布局一致的稀疏标签/键/值压力曲线和双 TaskManager 实例证据，避免把整个 tuner 配额错误地整区清零。开发机的 `reproduce-all --full --simulate` 会将最新真实 L0 曲线与本机 DRAM 曲线构造成带源文件 SHA 的 `simulation/model` 成本表后再进行候选搜索；它不等同于 `real-online` 吞吐证据，最终候选仍需少量真实 L0 复核。

7.6.6 2026-08-20 全因子调优阶段性结果

截至仓库提交 01029104，离线 L0 服务器已上传 `benchmark/results/tuning/full_20260816_190623/` 中的 trial 001-159。其中 78 组同时完成 24 个 workload，81 组因至少一项失败而不进入综合排名；3792 个 workload 执行中共有 98 个失败（2.58%）。失败根因分为：51 个 768 MiB native 上限下的 `std::bad_alloc`、43 个 TaskManager 连接丢失、3 个 `l0_mem_alloc` 运行时分配失败和 1 个集群重启后残留作业竞态。失败或部分完成的 trial 只作为稳定性证据，其已产生的局部性能数字不进入下表。trial 160-162 和 campaign 最终 `ranking.json` 在该提交中尚未产生，因此本小节为阶段性结果。

全局配置与按负载配置 不同 query 的状态基数、状态类型、增长速率与访问局部性不同，因此允许为不同 workload 选择不同 ForL0 后端参数。本报告同时保留两种口径，不将二者混用：

- **全局推荐配置**：所有 workload 使用同一组参数，表示开箱即用的部署效果。当前完整 trial 中的阶段性第一名为 `trial_129_a42bb3ae`，12 个配对比值的几何平均为 $1.3737\times$ ；参数为 initial capacity 512、max capacity 2,097,152、load factor 0.8、L0 cache 384 MiB、native

memory 1280 MiB。

- **按负载候选配置：**每个 workload 在调优集上独立选择候选参数，表示可达性能上限。下表的“观测最大”是搜索阶段最大值，不是独立测试集上的最终数字；最终交付数字必须在固定参数后重复至少 3 次。

表中 Client scalar batch 对应编号 C07/C08：C07 是 HashMap 对照，C08 是 ForL0。二者均运行 scalar_state_probe_2m_ops64_batch，每条记录批量执行 64 次 MapState<Long,Long> 更新，用于诊断 map-heavy 状态访问与批量 JNI 路径；它是非合同诊断压力项，不代表普通 Client 业务路径。

Workload	候选 trial	观测最大	78 组中位数	L0 Cache 证据
WordCount	trial_089	1.454×	1.103×	显式关闭，收益不归因于 L0
q18 TPS	trial_087	2.643×	2.201×	本场景关闭
q18 deep	trial_034	2.389×	1.766×	启用，但 lookup/hit 为 0
q19	trial_122	1.523×	1.363×	本场景关闭
q20	trial_150	1.694×	1.376×	启用，但 lookup/hit 为 0
q9	trial_129	1.236×	0.925×	启用，但 lookup/hit 为 0
q4	trial_136	1.885×	1.303×	启用，但 lookup/hit 为 0
q3	trial_144	1.550×	1.159×	启用，但 lookup/hit 为 0
Client contract	trial_142	1.005×	1.000×	启用，但 lookup/hit 为 0
Client optimized	trial_144	1.007×	1.000×	启用，但 lookup/hit 为 0
Client state pressure	trial_130	1.002×	1.000×	启用，但 lookup/hit 为 0
Client scalar batch	trial_089	2.980×	1.994×	实际访问，约 51.0% hit/lookup

表 5 完整 real-online trial 中的按负载候选结果。观测最大值只用于选择后续复核点；中位数用于展示搜索空间的典型表现。

Workload	Initial	Max	Load	Cache	Native	备注
WordCount	512	2,097,152	0.875	384 MiB	1280 MiB	L0-off
q18 TPS	8192	2,097,152	0.8	256 MiB	1024 MiB	L0-off
q18 deep	8192	4,194,304	0.8	256 MiB	1024 MiB	增长上限 4M
q19	2048	2,097,152	0.8	256 MiB	1024 MiB	L0-off
q20	8192	2,097,152	0.8	128 MiB	1024 MiB	—
q9	512	2,097,152	0.8	384 MiB	1280 MiB	必须复核回退风险
q4	2048	2,097,152	0.8	384 MiB	1280 MiB	—
q3	2048	4,194,304	0.8	384 MiB	1024 MiB	按需增长上限 4M
Client contract	2048	4,194,304	0.75	384 MiB	1024 MiB	性能持平
Client optimized	2048	4,194,304	0.8	384 MiB	1024 MiB	性能持平
Client state pressure	512	4,194,304	0.875	384 MiB	1280 MiB	性能持平
Client scalar batch	512	2,097,152	0.875	384 MiB	1280 MiB	唯一明确 L0-hit 候选

表 6 按负载复核候选参数。Cache 列为配置值；实际是否使用 L0 以上表的运行时 lookup/hit 证据为准。

公平性与结论边界 按负载配置不改变查询 SQL、输入比例、operator 并行度、TaskManager/slot 拓扑、监控窗口或 HashMap 对照的 workload 语义；只允许调整 ForL0 自身的 table、native-memory 和 HotCache 参数。如果后续调整 Flink 共享参数（例如并行度、slot、heap 或 checkpoint），HashMap 和 ForL0 必须获得相同的搜索预算。调优 trial 用于选择候选，固定配置后的重复实验用于报告最终吞吐、方差和置信区间，两者必须分开。

最后，“ForL0 State Backend 收益”与“L0 HotCache 收益”是两个不同层次的结论。WordCount、q18 TPS 和 q19 的当前候选显式关闭 L0；其他多个 NexMark/Client 候选虽预留了缓存池，但运行时 lookup/hit 为 0。这些收益应归因于 native/off-heap State Backend、SwissTable、融合 JNI 与低 GC 路径，不归因于 L0 Cache。当前只有 Client scalar batch 候选具有明确的 L0 lookup/hit 证据，可用于单独讨论 L0 热点访问上限。

8 测试结论

1. **功能正确性**：184 项测试用例（Java 集成与单元 54 项 + C++ 原生 GoogleTest 130 项）全部通过，覆盖 5 类 KeyedState 及其语义边界、Checkpoint/Savepoint/异步快照/快照一致性、窗口聚合、倾斜与压力负载、并行度变化（Rescale）、L0 Cache 类型组合与兜底、SPI 加载，以及 SwissTable/CoW/序列化/类型布局/Hot Cache 等原生数据结构。
2. **接口兼容性**：ForL0 State Backend 通过 SPI 被 Flink 自动发现并加载，与 Flink 1.20.3 的 StateBackend 接口、Checkpoint/Savepoint 协议完全兼容，用户作业无需修改。
3. **原生引擎稳定性**：SwissTable、CoW 快照、Checkpoint 序列化往返、TypedInnerMap 等底层结构通过 CTest 验证，序列化与恢复路径在大规模 key 和混合状态类型下均保持一致性。
4. **性能特征（Intel 平台收益显著）**：在 Intel x86_64 参考平台，ForL0 State Backend 在 WordCount 全部 36 组网格扫描点上一致领先于 HashMapStateBackend，平均吞吐量比值 **1.270**、最高 1.414；这一加速与 VTune 微架构剖析高度吻合——Memory Bound 从 48.1% 降至 15.3%、DRAM Bound 从 30.8% 降至 2.2%、CPI 从 0.615 降至 0.375。NexMark 端到端查询在 Intel 18 / 20 GB 可完成配置下，q19 / q20 分别由 HashMap 的 279s / 313s 和 123s / 84s 降至 ForL0 State Backend 的 45s / 38s 和 43s / 38s。**Flink 状态算子级 JMH 基准**进一步佐证：14 个操作点中 13 个正向提升，value.Add +87.2%、map.Add +110.0%、list.GetAndIterate +131.5%。鲲鹏 micro profile 也显示，ForL0 将状态访问集中到 NativeEngine.valueGet/Put (22.8%)，并将 GC worker/promotion 热点从 12.5% 降至 3.5%。
5. **鲲鹏平台收益边界**：在合同基线与默认 NexMark event-count SQL 场景下，鲲鹏平台的 NexMark 逐查询差异整体接近 0；v4.0 主表因此直接采用 ForL0/L0 友好、但后端之间公平的压力配置。2026-07-12 Ascend 一键清单中，NexMark q18 TPS / q18 lateq-deep / q4 / q3 分别达到 **+23.4%** / **+28.8%** / **+11.9%** / **+16.8%** 的吞吐提升；q19/q20/q9 吞吐小幅正向，同时 CPU/core 效率显著提升。q5/q8/q11 不纳入默认清单，因为它们未形成稳定、显著、公平的吞吐收益。

6. **v4.0 复跑结论：**v4.0 性能主表不再纳入非调优 event-count、contract 或 benchset 口径，直接采用 ForL0/L0 友好的调优配置；同时保持 HashMap 与 ForL0 的 operator 并行度、slot 数和输入设置一致。2026-07-12 Ascend 编号化一键复现完整跑通，WordCount p4 best-of-3 为 +24.9%；NexMark q18、q19、q20、q9、q4、q3 均为正向；Client 原始业务路径持平无回退，map-heavy scalar diagnostic 为 +149.5%。state_pressure_1m、hotspot_drift_1m、q5、q8、q11 和 benchset 已从默认清单移除。
7. **2026-08 调优策略：**全因子 campaign 明确分离“全局单配置”与“按 workload 配置”两种交付口径。截至 trial 159，全局阶段性候选为 trial_129 的 1.3737 $\times$ ；WordCount、q18 TPS/deep、q19、q20、q9、q4、q3 与 Client 四类负载分别保留自身的参数候选。调优集最大值只用于选点，最终数字需固定参数后独立重复至少 3 次；768 MiB native 上限因大量 std::bad_alloc 不进入推荐配置。当前除 Client scalar batch 外，其他候选没有有效 L0 hit 证据，因此其收益表述为 ForL0 State Backend 收益，不扩大为 L0 Cache 收益。
8. **后续改造与交付保障：**后续优化明确收敛在 ForL0 后端内部，不要求 workload 调用专有 API；其中 ForL0ValueState 增加 primitive long 热 key 透明缓存，MapState 融合 JNI 保留为诊断能力，用于说明 JNI/API 粒度瓶颈和指导后续 runtime 层 compound state operation。L0 manager 已改为 TaskManager 进程内共享并具备线程安全账本与 per-state rebalance；WordCount 融合计数探针明确采用 L0-off 口径。离线一键脚本已补充 smoke 门禁、TaskManager/slot 健康检查、强制重启、失败 marker 与 orphan job 清理、campaign 隔离及成功后 flat-latest 发布；ForL0 HotCache metrics 改为显式开关，从而降低脏集群、中断、错误产物或采集开销导致实验失效的风险。