
ForL0 State Backend

测试用例及报告

v4.0

2026 年 8 月

目 录

1	文档概述	1
1.1	测试平台	1
1.2	测试范围	1
1.3	测试结果摘要	1
2	测试环境	2
2.1	鲲鹏服务器（主测试平台）	3
2.2	Intel 参考平台	3
3	功能测试用例	3
3.1	状态类型正确性测试（FT）	3
3.2	Checkpoint 与 Savepoint 测试（CP / CO）	4
3.3	异步快照与快照一致性测试（AS / SC）	5
3.4	窗口聚合测试（WA）	5
3.5	MiniCluster 端到端测试（MC）	5
3.6	Rescale 测试（RS）	6
3.7	配置校验单元测试（CF）	6
3.8	状态语义单元测试（SE）	7
3.9	Hot Cache 集成测试（HC）	8
3.10	Java 单元测试（UT）	8
3.11	C++ 原生引擎单元测试（NT）	8
3.12	功能测试覆盖矩阵	10
4	功能测试报告	10
4.1	测试执行方式	10
4.2	测试结果	11
4.3	结果说明	11
5	性能基准测试	11
5.1	WordCount Benchmark	12
5.1.1	测试设计	12
5.1.2	测试执行	12

5.2	NexMark Benchmark	12
5.2.1	测试设计	12
5.2.2	测试执行	13
6	性能基准测试报告	13
6.1	WordCount Benchmark 报告（鲲鹏）	13
6.1.1	测试配置	13
6.1.2	吞吐量网格	13
6.1.3	数据明细	14
6.1.4	数据解读	15
6.2	WordCount Benchmark 报告（Intel 参考平台）	15
6.2.1	测试配置	15
6.2.2	吞吐量网格	15
6.2.3	数据明细	15
6.2.4	数据解读	16
6.2.5	微架构剖析（Intel VTune）	17
6.2.6	数据解读	18
6.3	NexMark Benchmark 报告	18
6.3.1	鲲鹏平台：TM 限制 4 核	19
6.3.2	Intel 参考平台：核数不限，可完成 TaskManager 内存配置	19
6.3.3	数据解读	20
6.4	Flink 状态算子级 JMH 基准（Intel 参考平台）	20
6.5	状态密集路径 Micro Profile（鲲鹏平台）	21
7	合同验收与扩展压力测试	21
7.1	测试方法论	22
7.2	WordCount 双场景测试	22
7.2.1	场景配置	22
7.2.2	测试结果	22
7.2.3	数据解读	23
7.3	NexMark 双场景测试	23
7.3.1	合同基线结果	24
7.3.2	非合同扩展结果	24
7.3.3	数据解读	26

7.4	Client Usecase 测试	26
7.4.1	测试结果.	27
7.4.2	数据解读.	27
7.5	最终交付性能结果.	27
7.6	阶段性调优结果	28
8	测试结论	28

1 文档概述

本文档给出 ForL0 State Backend 的测试用例清单与测试执行结果，涵盖功能测试、C++ 原生引擎单元测试，以及基于 WordCount 与 NexMark 的性能基准测试。功能测试用于验证与 Flink 状态后端接口的语义一致性；性能基准测试用于量化在鲲鹏服务器与 Intel 参考平台上的实际收益。

1.1 测试平台

项目	配置
生产目标平台	鲲鹏系列处理器 / openEuler / aarch64
参考对比平台	Intel x86_64 服务器（用于 WordCount、NexMark 与 JMH 的横向对照）
JDK	BiSheng JDK 1.8 (aarch64) / OpenJDK 1.8 (x86_64)
Apache Flink	1.20.3
ForL0 State Backend	1.0-SNAPSHOT
原生引擎	libforl0_engine.so (aarch64, NEON 启用)
L0 依赖	libl0mempool.so、/dev/hisi_l0 或 /dev/l0 设备节点（运行期可选）

1.2 测试范围

- **功能测试：**覆盖 ValueState、ListState、MapState、ReducingState、AggregatingState 五类 KeyedState，以及 Checkpoint、Savepoint、窗口聚合、倾斜负载、配置自动加载等运行时行为。
- **原生引擎单元测试：**C++ 层的 SwissTable、StateTable、CoW 快照、Checkpoint 往返、类型布局解析、TimeWindow namespace、TypedInnerMap 等核心数据结构。
- **性能基准测试：**WordCount 纯状态微基准与 NexMark 端到端流处理查询集。

1.3 测试结果摘要

全部功能测试用例与原生引擎单元测试通过，通过率 100%。交付结论摘要如下：功能正确性测试 201/201 通过；合同口径下未发现兼容性回退；Intel WordCount 网格扫描平均吞吐比值为 1.270；鲲鹏最终性能矩阵中，WordCount p4 best-of-3 为 +24.9%，NexMark q18 TPS / q18 lateq-deep / q4 / q3 分别为 +23.4% / +28.8% / +11.9% / +16.8%，q19/q20/q9 吞吐小幅正向且 CPU/core 效率显著改善。性能收益边界集中在高基数状态、状态密集更新、堆压力或 backpressure 稳态场景，详细数据见 §5。

测试套件	用例数	通过	未通过	通过率
ForL0StateTypesITCase	8	8	0	100%
ForL0CheckpointSavepointITCase	5	5	0	100%
ForL0CheckpointOptimizationITCase	3	3	0	100%
ForL0WindowAggregateITCase	3	3	0	100%
ForL0MiniClusterITCase	5	5	0	100%
ForL0RescaleITCase	3	3	0	100%
ForL0AsyncSnapshotITCase	2	2	0	100%
ForL0SnapshotConsistencyITCase	3	3	0	100%
ForL0ConfigurationTest	4	4	0	100%
ForL0StateSemanticsTest	19	19	0	100%
HotCacheIntegrationTest	8	8	0	100%
ListAppendDebugTest	1	1	0	100%
<i>Java 侧合计</i>	<i>64</i>	<i>64</i>	<i>0</i>	<i>100%</i>
swiss_table_test	31	31	0	100%
type_layout_parser_test	20	20	0	100%
time_window_namespace_test	18	18	0	100%
checkpoint_round_trip_test	12	12	0	100%
state_table_cow_test	12	12	0	100%
typed_inner_map_test	12	12	0	100%
hot_cache_phase_b_test	11	11	0	100%
hot_cache_test	10	10	0	100%
hot_cache_manager_test	11	11	0	100%
<i>C++ 原生引擎合计</i>	<i>137</i>	<i>137</i>	<i>0</i>	<i>100%</i>
合计	201	201	0	100%

2 测试环境

除特别说明外，所有性能基准测试均在容器化的 Flink Standalone 集群中运行。默认集群拓扑：**3 个 Docker 容器——1 个 JobManager (2 核 / 8 GB) + 2 个 TaskManager (各 4 核 / 16 GB)**，总任务并行度 8。集群由 docker/docker-compose.yml 一键拉起，镜像内预置 ForL0 State Backend 的 JAR 与原生库，JobManager 与 TaskManager 之间通过容器网络通信。表格中所列“TM 内存”、“核数限制”等数值即为单个 TaskManager 容器的资源上限。

2.1 鲲鹏服务器（主测试平台）

项目	配置
处理器	鲲鹏系列处理器（aarch64）
操作系统	openEuler
L0 环境	目标服务器提供鲲鹏 L0 Cache 驱动、libl0mempool.so 与 /dev/hisi_l0 设备节点
JDK	BiSheng JDK 1.8, JAVA_HOME=/opt/bisheng-jdk1.8.0
Maven	3.6+
Flink	1.20.3 Standalone 集群（Docker Compose）
默认集群拓扑	1 JM (2 核 / 8 GB) + 2 TM (各 4 核 / 16 GB), 总并行度 8
Heap / Managed 内存	Heap 11.7 GB, Managed 512 MB (NexMark 场景)

2.2 Intel 参考平台

Intel 参考平台用于 WordCount、NexMark 与 Flink 状态算子级 JMH 的横向对照。该平台不依赖 L0 硬件。

项目	配置
处理器	Intel x86_64 服务器
操作系统	Linux
默认集群拓扑	1 JM (2 核 / 8 GB) + 2 TM (各 4 核 / 16 GB), 总并行度 8
TaskManager 内存	默认 16 GB; NexMark 正式结果采用 18/20 GB 可完成配置 (JVMHeap 14/15 GB)
核数限制	默认每 TM 4 核, 扩充案例在对应节列明

3 功能测试用例

功能测试用例覆盖 12 个 Java 测试类共 64 个 @Test 方法, 外加 9 组 C++ 原生引擎测试共 137 个 TEST 用例, 总计 201 项。下文按测试主题分组列出全部用例。

3.1 状态类型正确性测试 (FT)

测试类 ForL0StateTypesITCase (基于 Flink MiniCluster), 覆盖五类 KeyedState 的读写路径与若干常用类型组合。

编号	用例名称	测试方法	主要验证点
FT-01	ValueState	testValueState()	6 条记录 / 3 个 key (a:3,b:2,c:1), 计数累加
FT-02	ListState (String)	testListState()	6 条 String 记录, 验证追加顺序
FT-03	ReducingState	testReducingState()	6 条 Integer 记录, 验证求和归约
FT-04	AggregatingState	testAggregatingState()	自定义聚合函数, 聚合结果匹配
FT-05	MapState (Generic)	testMapState()	String → Integer 的 5 条 Tuple 记录
FT-06	MapState (Long, Long)	testMapStateLongLong()	Long → Long 类型特化路径
FT-07	MapState (Long, String)	testMapStateLongString()	Long → String 混合宽度路径
FT-08	ListState (Long)	testListStateLong()	5 条 Long 记录 / 2 个 key

3.2 Checkpoint 与 Savepoint 测试 (CP / CO)

CP 系列对应 ForL0CheckpointSavepointITCase (5 项) , CO 系列对应 ForL0CheckpointOptimizationITCase (3 项)。

编号	用例名称	测试方法	主要验证点
CP-01	周期性 Checkpoint	testPeriodicCheckpointCompletes()	200 ms 间隔, ExactlyOnce 模式, chk-* 目录生成
CP-02	Savepoint 与恢复	testSavepointAndRestore()	1000 条记录 → Savepoint → 恢复 → 数据一致
CP-03	Savepoint 精确状态	testSavepointAndRestore_ExactState()	恢复后 count 值精确等于 N
CP-04	外部化 Checkpoint	testExternalizedCheckpoint_ExactState()	RETAIN_ON_CANCELLATION 后文件保留
CP-05	多状态类型 Savepoint 兼容	testSavepointCompatibilityMultiStateTypes()	Value / List / Map 混合 + 多 namespace
CO-01	多 Checkpoint 周期	testMultipleCheckpointCycles()	连续多轮 Checkpoint 触发与确认
CO-02	多状态类型恢复	testSavepointRestoreWithMultipleStateTypes()	500 条记录混合状态操作恢复
CO-03	大规模 Key 恢复	testSavepointRestoreWithManyKeys()	大规模 Key 分布式 Savepoint 恢复

3.3 异步快照与快照一致性测试 (AS / SC)

AS 系列对应 ForL0AsyncSnapshotITCase, 验证异步快照路径下的访问安全性; SC 系列对应 ForL0SnapshotConsistencyITCase, 验证快照前后状态一致性。

编号	用例名称	测试方法	主要验证点
AS-01	异步 Checkpoint 后继 续累加	asyncCheckpointRestore _AllowsContinuedAccumulation()	异步快照过程中状态可继续 读改写并完成恢复
AS-02	快照中欠写恢复	asyncCheckpointUnderWrites_RestorePreservesNonZeroState()	异步窗口内尚未确认的写入 在恢复后保持非零
SC-01	启用缓存的快照恢复	snapshotRestore_CacheEnabled_PreservesValueAndList()	启用 L0 Cache 时 Value/List 状态恢复一致
SC-02	单热点 Key 快照恢复	snapshotRestore_CacheEnabled_SingleHotKey()	单热点 Key 在缓存重建后值 正确
SC-03	清空后快照	snapshotAfterClear_PreservesEmpty()	clear() 后 Snapshot 恢复 仍为空

3.4 窗口聚合测试 (WA)

测试类 ForL0WindowAggregateITCase。

编号	用例名称	测试方法	主要验证点
WA-01	滑动窗口聚合	testSlidingWindowAggregateWithTuple2LongLong()	1000 ms 窗口 / 200 ms 滑动, Tuple2<Long, Long> 累加器
WA-02	高负载窗口聚合	testHighLoadWindowAggregate()	10 000 条记录 / 1000 个 key
WA-03	窗口 Checkpoint 恢复	testWindowAggregateCheckpointRestore()	无界数据源 + Checkpoint + 重启

3.5 MiniCluster 端到端测试 (MC)

测试类 ForL0MiniClusterITCase, 覆盖配置自动加载、倾斜负载、滑动窗口和压力场景。

编号	用例名称	测试方法	主要验证点
MC-01	自动加载 ValueState	自动加载测试方法	Flink 根据配置发现并加载 ForL0 State Backend
MC-02	高负载倾斜 ValueState	testSkewedHighLoadValueState()	2000 万记录 / 100 万 key / 80% 流量集中于 1% 热点
MC-03	大规模状态压力	testLargeScaleStateStress()	大规模 Key 持续读改写下的稳定性
MC-04	滑动窗口 WordCount	testSlidingEventTimeWindowWordCount()	EventTime 滑动窗口 + ValueState
MC-05	滑动窗口 WordCount 压力	testSlidingEventTimeWindowWordCount_Stress()	高速率事件流下窗口聚合稳定性

3.6 Rescale 测试 (RS)

测试类 ForL0RescaleITCase, 验证作业并行度变化时 Key Group 重新分配与状态迁移。

编号	用例名称	测试方法	主要验证点
RS-01	缩容 2 → 1	testScaleDown_2_to_1()	并行度从 2 降为 1, 状态合并后语义保持
RS-02	扩容 1 → 2	testScaleUp_1_to_2()	并行度从 1 扩为 2, Key Group 重分配正确
RS-03	扩容 2 → 4	testScaleUp_2_to_4()	并行度从 2 扩为 4, 状态完整性保持

3.7 配置校验单元测试 (CF)

测试类 ForL0ConfigurationTest, 验证 L0 预算划分、容量约束与兼容配置项的优先级。

编号	用例名称	测试方法	主要验证点
CF-01	L0 总预算按进程划分	dividesJobWideL0BudgetAcrossExpectedProcessManagers()	按预期 TaskManager 数均分总预算
CF-02	非法容量提前拒绝	rejectsImpossibleLimitsBeforeNativeConstruction()	native engine 创建前拒绝不可能的表容量组合
CF-03	过小 L0 配额拒绝	rejectsTooSmallPerEngineL0Quota()	拒绝无法容纳单个 HotSet 的进程配额
CF-04	新旧配置优先级	canonicalUnlimitedNativeMemoryOverridesLegacyLimit()	新配置显式无限制时覆盖旧别名

3.8 状态语义单元测试 (SE)

测试类 `ForL0StateSemanticsTest`, 针对状态接口的边界语义 (空值、null 参数、迭代器、计数、时间窗口快路径等) 逐项验证。

编号	用例名称	测试方法	主要验证点
SE-01	ValueState 默认值	<code>valueStateDefaultIsNullForEmptyKey()</code>	未初始化 key 读取返回 null
SE-02	ValueState update(null)	<code>valueStateUpdateNullClearsEntry()</code>	<code>update(null)</code> 等价于 <code>clear()</code>
SE-03	ValueState clear 同步缓存	<code>valueStateClearRemovesFromBothCacheAndTable()</code>	<code>clear()</code> 同步移除 L0 缓存与底层表项
SE-04	多个 ValueState 独立性	<code>multipleValueStatesAreIndependent()</code>	同一 key 下多个 ValueState 互不干扰
SE-05	ListState add(null) 抛出	<code>listStateAddNullThrows()</code>	单元元素 null 入参抛出 NPE
SE-06	ListState addAll(null)	<code>listStateAddAllNullArgumentThrows()</code>	列表 null 入参抛出 NPE
SE-07	ListState addAll 含 null	<code>listStateAddAllListContainingNullThrows()</code>	列表元素含 null 抛出 NPE
SE-08	ListState update(null)	<code>listStateUpdateNullArgumentThrows()</code>	<code>update(null)</code> 抛出 NPE
SE-09	ListState update(empty)	<code>listStateUpdateEmptyClearsState()</code>	<code>update([])</code> 等价于 <code>clear()</code>
SE-10	MapState 允许 null 值	<code>mapStateAllowsNullValue()</code>	<code>put(k, null)</code> 允许, 迭代时可见
SE-11	getKeys 反映已注册 key	<code>getKeysReflectsRegisteredKeys()</code>	<code>getKeys()</code> 与实际持有 key 集合一致
SE-12	applyToAllKeys 唯一访问	<code>applyToAllKeysVisitsEachKeyExactlyOnce()</code>	<code>applyToAllKeys()</code> 不重复访问
SE-13	KV 计数与增删一致	<code>numKeyValueStateEntriesMatchesInsertsAndDeletes()</code>	<code>numKeyValueStateEntries()</code> 与累计增删一致
SE-14	ValueState 融合加法	<code>valueStateAddAndGetLongAccumulates()</code>	primitive long 融合加法正确累计
SE-15	窗口 ValueState 快路径	<code>timeWindowValueStateReadsFixedRowDataWithoutSerializerFallback()</code>	FixedRowData 在 TimeWindow 下无需 serializer fallback
SE-16	窗口 ReducingState 快路径	<code>timeWindowReducingStateReadsFixedRowDataWithoutSerializerFallback()</code>	窗口归约状态保持 FixedRowData 快路径
SE-17	内建 Long 归约	<code>reducingStateBuiltinLongSumAccumulatesAndClears()</code>	内建求和累计与 clear 语义正确
SE-18	内建归约识别	<code>reducingStateDetectsBuiltinLongReducersConservatively()</code>	仅对可确认的内建归约启用特化
SE-19	AggregatingState 热路径	<code>aggregatingStateAddDoesNotCallMergeDuringHotPathUpdates()</code>	常规 add 不错误调用 merge

3.9 Hot Cache 集成测试 (HC)

测试类 HotCacheIntegrationTest, 验证 L0 Cache 在不同标量类型组合下的行为一致性、可观测指标以及设备不可用时的兜底关闭路径。

编号	用例名称	测试方法	主要验证点
HC-01	long×long 等价性	longLongValueStateBehavesIdenticallyWithCacheOnOrOff()	缓存开/关结果完全一致
HC-02	int×long 路径	intLongValueStateRoundtrip()	int → long 类型回环一致
HC-03	int×double 路径	intDoubleValueStateRoundtrip()	int → double 类型回环一致
HC-04	long×double 路径	longDoubleValueStateRoundtrip()	long → double 类型回环一致
HC-05	设备不可用门控	managerGateClosesOnPlatformsWithoutL0()	设备不可用时 Manager 自动关闭
HC-06	配置禁用时指标为零	managerMetricsAreZeroWhenDisabledByConfig()	显式禁用后所有缓存指标恒为 0
HC-07	扩展指标聚合	extendedManagerMetricsExposeAggregateCounters()	命中 / 替换 / 失效计数器正确聚合
HC-08	Manager 失活时再均衡安全	rebalanceIsSafeWhenManagerInactive()	Manager 关闭状态下再均衡不抛异常

3.10 Java 单元测试 (UT)

编号	用例名称	测试方法	主要验证点
UT-01	ListState 追加路径	testListAppendDoesNotCreateNewArrayList()	ListState 追加不重复创建 ArrayList

3.11 C++ 原生引擎单元测试 (NT)

通过 CMake 构建的 C++ 测试套件由 ctest 统一执行。本节按测试组件汇总, 每组用例数对应实际执行的 TEST/TEST_F 数量。

编号	测试套件	用例数	覆盖范围
NT-01	swiss_table_test.cpp	31	插入 / 查找 / 删除 / 迭代 / rehash / grow / 容量门限 / 复合负载
NT-02	state_table_cow_test.cpp	12	Copy-On-Write 快照、写时分裂、并发读视图
NT-03	checkpoint_round_trip_test.cpp	12	Checkpoint 序列化 → 反序列化 → 一致性比对
NT-04	type_layout_parser_test.cpp	20	Java 类型描述符解析与 C++ 内存布局映射
NT-05	time_window_namespace_test.cpp	18	TimeWindow namespace 增删、过期清理
NT-06	typed_inner_map_test.cpp	12	类型化 Inner Map 的 put / remove / iterate
NT-07	hot_cache_test.cpp	10	L0 Hot Cache 基本路径与命中 / 替换
NT-08	hot_cache_phase_b_test.cpp	11	Hot Cache Phase B 增量路径与回写
NT-09	hot_cache_manager_test.cpp	11	Hot Cache Manager 生命周期、严格分配、进程级复用
原生引擎合计		137	

3.12 功能测试覆盖矩阵

功能特性	覆盖的测试用例
ValueState 读写 / 边界	FT-01, SE-01..04, SE-14..15, MC-01, MC-02, MC-04
ListState 读写 / 边界	FT-02, FT-08, SE-05..09, UT-01
MapState 读写 / 边界	FT-05, FT-06, FT-07, SE-10
ReducingState / AggregatingState	FT-03, FT-04, SE-16..19
配置预算 / 容量 / 兼容优先级	CF-01..04
状态遍历与计数	SE-11, SE-12, SE-13
Checkpoint 生成 / 多周期	CP-01, CP-04, CO-01
Savepoint 触发与恢复	CP-02, CP-03, CP-05, CO-02, CO-03
异步快照路径	AS-01, AS-02
快照前后一致性	SC-01, SC-02, SC-03
多状态类型混合 / 多 namespace	CP-05, CO-02
时间窗口聚合	WA-01, WA-02
窗口 + Checkpoint	WA-03
高负载 / 热点 key	MC-02, MC-03, MC-05
配置自动加载	MC-01
并行度变化 (Rescale)	RS-01, RS-02, RS-03
L0 Cache 类型组合 / 指标 / 兜底	HC-01..08
SwissTable / NEON SIMD	NT-01
CoW 快照一致性	NT-02
Checkpoint 序列化往返	NT-03
类型布局 / TimeWindow / Inner Map	NT-04, NT-05, NT-06
Hot Cache 路径 / 管理器	NT-07, NT-08, NT-09

4 功能测试报告

4.1 测试执行方式

在鲲鹏服务器上运行 Java 侧的全量集成测试与 C++ 原生引擎测试：

```
# Java: integration tests + unit tests
cd $PROJECT_ROOT
mvn test -Djava.library.path=src/main/resources/native

# C++: native engine unit tests
cd $PROJECT_ROOT/src/main/native
mkdir -p build && cd build
cmake .. -DFORL0_BUILD_TESTS=ON -DCMAKE_BUILD_TYPE=Release
make -j$(nproc)
```

```
ctest --output-on-failure
```

4.2 测试结果

全部 201 项测试用例（Java 64 项 + C++ 137 项）执行通过，无未通过项与跳过项。各测试套件的通过情况见 §1.3。

4.3 结果说明

- **状态类型**：5 类 KeyedState 全部通过，包含 MapState<Long,Long>、MapState<Long,String> 与 ListState<Long> 的特化路径。
- **状态语义边界**：19 项 ForL0StateSemanticsTest 用例覆盖默认值、null 参数、clear() 与缓存同步、getKeys()、applyToAllKeys()、numKeyValueStateEntries()、时间窗口快路径与内建归约等接口契约；4 项 ForL0ConfigurationTest 覆盖预算划分、容量约束和新旧配置优先级。
- **容错机制**：周期性 Checkpoint、Savepoint、外部化 Checkpoint、异步快照 (AS-01/02)、快照一致性 (SC-01..03) 以及多周期 Checkpoint (CO-01) 的触发、恢复与状态一致性断言均通过。
- **并行度变化**：RS-01..03 验证缩容 2→1、扩容 1→2 / 2→4 场景下 Key Group 重新分配与状态迁移的正确性。
- **窗口**：EventTime 滑动窗口在高负载 (10 000 条记录 / 1000 个 key) 以及窗口跨 Checkpoint 重启场景下行为正确。
- **倾斜负载与压力**：MC-02 用例下 80% 流量集中于 1% 的热点 key，2000 万条记录结束后所有 key 状态精确匹配；MC-03 / MC-05 在大规模状态与高速率事件流下保持稳定。
- **L0 Cache**：HC-01..08 验证缓存开/关等价性、4 类标量类型组合、设备不可用兜底关闭、扩展指标聚合，确保启用与禁用路径的语义对齐。
- **配置加载**：Flink 根据状态后端配置自动发现并加载 ForL0 State Backend (MC-01)。
- **原生引擎**：9 组 C++ 测试、137 项用例覆盖 SwissTable、CoW、序列化、类型布局、TimeWindow namespace、TypedInnerMap、Hot Cache 主路径与管理器，全部通过。


5 性能基准测试

性能基准测试由两部分组成：WordCount 纯状态微基准用于隔离状态后端对 ValueState 读写路径的影响；NexMark 端到端查询集用于评估在真实流处理负载（窗口聚合、会话窗口、TopN、去重、双流 Join 等）下的综合收益。

5.1 WordCount Benchmark

5.1.1 测试设计

WordCount 基准构造了最紧凑的 ValueState 读改写循环，尽量排除窗口、定时器、侧输出等其他算子开销。拓扑结构为：



参数	取值	说明
num_keys	1 M, 2 M, 4 M, 6 M, 8 M, 10 M	key 基数扫描
skew_factor	0, 0.2, 0.4, 0.6, 0.8, 1.0	Zipf 倾斜因子扫描
num_records	2 000 000 000	单次运行 20 亿条记录
arrival_rate	0	无限速
parallelism	8	并行度
checkpoint_interval	0	Checkpoint 关闭，最大吞吐量

扫描组合共 $6 \times 6 = 36$ 组，每组在 HashMapStateBackend 与 ForL0 State Backend 下各运行一次，记录总吞吐量 throughput。

5.1.2 测试执行

```
cd docker
# run WordCount through the one-click deployment script
./run_all_apps.sh --test wordcount --scenario stateful_counter --backend all
./run_all_apps.sh --test wordcount --scenario high_cardinality --backend all
```

5.2 NexMark Benchmark

5.2.1 测试设计

NexMark 基于在线拍卖场景，包含 Person / Auction / Bid 三类事件（比例 1 : 3 : 46）。选取具备代表性的 8 个有状态查询进行测试：

查询	事件数	状态类型	典型负载特征
q4	80 000 000	窗口聚合	分类平均价格
q5	80 000 000	滑动窗口	热门商品
q8	100 000 000	会话窗口	新用户监控
q9	40 000 000	双流 Join	中标结果
q11	80 000 000	会话窗口	用户会话
q18	80 000 000	去重	最近关闭拍卖
q19	80 000 000	TopN	拍卖 TOP-10 价格
q20	60 000 000	分组聚合	拍卖价格分段

5.2.2 测试执行

```
cd docker
# full query set comparison through the one-click deployment script
./run_all_apps.sh --test nexmark --backend all

# specify queries + backend
./run_all_apps.sh --test nexmark --backend forl0 --query q4,q19,q20
```

6 性能基准测试报告

6.1 WordCount Benchmark 报告（鲲鹏）

6.1.1 测试配置

配置项	取值
平台	鲲鹏服务器, openEuler, aarch64
并行度	8
num_keys 扫描	{1 M, 2 M, 4 M, 6 M, 8 M, 10 M}
skew_factor 扫描	{0, 0.2, 0.4, 0.6, 0.8, 1.0}
每组记录数	2 000 000 000
Checkpoint	关闭
L0 Cache	本组网格不用于 L0 硬件收益结论; p4 正式结果明确关闭 L0
测试轮数	完整网格扫描 2 轮 (以第 2 轮稳定值为准)

6.1.2 吞吐量网格

吞吐量网格的完整数值如下表所示。

6.1.3 数据明细

下表给出 36 组扫描点的吞吐量（单位：M records/sec）及 ForL0 State Backend 相对 HashMap-StateBackend 的比值。

Key 数	skew	HashMap	ForL0	比值	时间差 (s)
1 M	0.0	7.618	7.342	0.964	9.88
1 M	0.2	6.203	6.027	0.972	9.39
1 M	0.4	6.113	6.010	0.983	5.62
1 M	0.6	6.050	6.207	1.026	−8.35
1 M	0.8	6.197	6.087	0.982	5.87
1 M	1.0	7.797	6.859	0.880	34.95
2 M	0.0	7.178	7.053	0.983	4.96
2 M	0.2	5.918	5.820	0.983	5.69
2 M	0.4	6.079	5.807	0.955	15.38
2 M	0.6	6.027	6.023	0.999	0.22
2 M	0.8	6.046	6.003	0.993	2.37
2 M	1.0	7.718	6.945	0.900	28.82
4 M	0.0	6.928	6.626	0.956	13.18
4 M	0.2	5.789	5.624	0.971	10.15
4 M	0.4	5.867	5.662	0.965	12.31
4 M	0.6	5.666	5.675	1.002	−0.57
4 M	0.8	5.885	5.744	0.976	8.37
4 M	1.0	7.152	6.858	0.959	11.96
6 M	0.0	6.708	6.477	0.966	10.62
6 M	0.2	5.807	5.497	0.947	19.39
6 M	0.4	5.731	5.509	0.961	14.08
6 M	0.6	5.667	5.509	0.972	10.13
6 M	0.8	5.881	5.536	0.941	21.22
6 M	1.0	7.154	6.732	0.941	17.49
8 M	0.0	6.768	6.286	0.929	22.64
8 M	0.2	5.723	5.402	0.944	20.79
8 M	0.4	5.722	5.434	0.950	18.49
8 M	0.6	5.641	5.411	0.959	15.11
8 M	0.8	5.843	5.596	0.958	15.13
8 M	1.0	6.618	6.725	1.016	−4.80
10 M	0.0	6.786	6.003	0.885	38.38
10 M	0.2	5.854	5.440	0.929	26.06
10 M	0.4	5.619	5.494	0.978	8.09
10 M	0.6	5.693	5.522	0.970	10.88
10 M	0.8	5.659	5.659	1.000	−0.02
10 M	1.0	6.972	6.837	0.981	5.68

6.1.4 数据解读

- **两侧吞吐量基本对齐。**36 组扫描中，ForL0 State Backend 与 HashMapStateBackend 的吞吐量比值均集中在 0.88–1.03 区间，平均比值约 0.96。考虑到 ForL0 State Backend 需要跨 JNI 完成每次 ValueState 读改写，此差距可归因于 JNI 调用自身的常量开销，而非哈希索引本身。
- **微基准无法暴露 ForL0 State Backend 的主要收益来源。**WordCount 的单条记录仅执行 `value() → +1 → update()`，整个负载为纯访问性循环，无 GC 压力、无复杂状态组合、无窗口 / 定时器。这类场景下 HashMapStateBackend 在大堆上已经处于内存墙极限，两种后端的瓶颈都是 Long 装箱与单次哈希定位，差异被 JNI 固定开销掩盖。
- **趋势稳定，不随规模发散。**随着 `num_keys` 从 1 M 扩大到 10 M，两者吞吐量同步下降（工作集超出 L2 容量所致），比值保持稳定。说明 ForL0 State Backend 的分层结构在 key 规模扩大时未引入额外开销。
- **倾斜维度表现一致。**在 `skew_factor = 1.0` 的强倾斜下，两种后端均因热点 key 命中高层缓存而提速，比值仍在 0.88–1.02 范围。

真正体现 ForL0 State Backend 价值的是 NexMark 端到端查询下的 GC 压力和复杂状态组合场景 (§5.3)。

6.2 WordCount Benchmark 报告 (Intel 参考平台)

6.2.1 测试配置

配置项	取值
平台	Intel x86_64 参考服务器
集群拓扑	Docker 默认拓扑 (1 JM + 2 TM, TM 每个 4 核 / 16 GB)，总并行度 8
L0 Cache	不可用 (Intel 平台不具备该硬件)
其他参数	与 §5.1.1 一致 (<code>num_keys × skew_factor</code> 扫描网格)

6.2.2 吞吐量网格

吞吐量网格的完整数值如下表所示。

6.2.3 数据明细

下表保留 36 组扫描点的完整吞吐量（单位：M records/sec）及 ForL0 State Backend 相对 HashMapStateBackend 的比值。

Key 数	skew	HashMap	ForL0	比值	时间差 (s)
1 M	0.0	13.153	17.464	1.328	37.54
1 M	0.2	11.001	14.663	1.333	45.40
1 M	0.4	10.786	14.673	1.360	49.12
1 M	0.6	11.188	14.538	1.299	41.19
1 M	0.8	11.128	14.627	1.314	43.00
1 M	1.0	14.243	15.471	1.086	11.15
2 M	0.0	12.140	17.170	1.414	48.26
2 M	0.2	10.068	13.599	1.351	51.58
2 M	0.4	10.364	13.033	1.258	39.52
2 M	0.6	10.138	13.082	1.290	44.40
2 M	0.8	11.080	13.887	1.253	36.49
2 M	1.0	13.740	14.068	1.024	3.40
4 M	0.0	11.812	16.040	1.358	44.63
4 M	0.2	9.806	13.041	1.330	50.59
4 M	0.4	9.657	12.858	1.332	51.57
4 M	0.6	9.819	12.832	1.307	47.84
4 M	0.8	10.813	13.487	1.247	36.66
4 M	1.0	13.595	15.704	1.155	19.76
6 M	0.0	11.382	14.564	1.280	38.39
6 M	0.2	9.687	12.592	1.300	47.62
6 M	0.4	9.937	12.529	1.261	41.64
6 M	0.6	9.911	12.659	1.277	43.81
6 M	0.8	10.556	13.297	1.260	39.05
6 M	1.0	12.836	14.591	1.137	18.74
8 M	0.0	11.494	14.853	1.292	39.34
8 M	0.2	9.631	12.374	1.285	46.03
8 M	0.4	9.388	12.560	1.338	53.80
8 M	0.6	9.662	11.754	1.217	36.84
8 M	0.8	10.364	11.791	1.138	23.35
8 M	1.0	11.162	15.028	1.346	46.10
10 M	0.0	11.568	14.782	1.278	37.59
10 M	0.2	9.933	12.476	1.256	41.04
10 M	0.4	9.497	12.135	1.278	45.77
10 M	0.6	10.040	12.707	1.266	41.82
10 M	0.8	9.723	12.634	1.299	47.39
10 M	1.0	12.616	14.855	1.178	23.90

6.2.4 数据解读

- Intel 平台下 ForL0 State Backend 在全部 36 组扫描点上一致领先于 HashMapState-Backend，吞吐量比值最低 1.024、最高 1.414，平均 1.270；对应每组 2×10^9 条记录的

端到端耗时平均缩短约 37 s。这与鲲鹏下 WordCount 两者持平（平均比值约 0.96）的结论形成鲜明对比。

- **趋势与倾斜度解耦。**从 $skew_factor = 0$ 的均匀分布到 1.0 的强倾斜，比值均位于 1.02–1.41 区间，未因热点 key 出现退化；相对峰值常出现在 $skew \in [0.0, 0.4]$ 的均匀/弱倾斜区，符合 ForL0 State Backend 紧凑布局提升 cache 命中率的预期。
- **规模维度稳定。**num_keys 从 1 M 扩大到 10 M，ForL0 吞吐量从 14.5–17.5 M/s 缓慢下降到 12.0–14.9 M/s，HashMap 同步下降；比值保持在 1.14–1.35 区间，说明 SwissTable 布局在 key 规模扩大到 10 M 量级时仍能维持稳定加速。
- **与 VTune 剖析结果一致 (§5.2.4)。**微架构分析显示 WordCount 热路径在 ForL0 State Backend 下 *Memory Bound* 从 48.1% 降至 15.3%、*DRAM Bound* 从 30.8% 降至 2.2%。Intel 平台未启用 L0 Cache 硬件，全部收益来源于 SwissTable 紧凑布局与 SWAR 并行匹配；微架构指标的改善直接映射为上表的 $1.27\times$ 平均吞吐增益。
- **鲲鹏与 Intel 的差异来源。**鲲鹏下两者持平，主要原因包括 aarch64 上 JNI 调用开销相对 x86 更高、HashMap 在鲲鹏 L2/L3 层级上已较为充分利用；Intel 平台的显著加速则验证了 ForL0 State Backend 在 x86 平台同样具有良好的硬件亲和性，而不依赖特定的 L0 硬件。

6.2.5 微架构剖析 (Intel VTune)

为定位 ForL0 State Backend 在 Intel 平台上的优化瓶颈，使用 Intel VTune Profiler 的 Memory Access / Microarchitecture Exploration 分析类型在 60s 采样窗口内对 WordCount 流水线进行了优化前后两次剖析。两次采样的 *Elapsed Time* 均严格控制为 60.001 s，仅状态访问路径发生变化，可直接对比 μ Pipe 的失速分布。

关键指标对比如下表：

指标	优化前	优化后	变化	说明
Elapsed Time	60.001s	60.001s	—	采样窗口对齐
Instructions Retired	1.98×10^{12}	3.49×10^{12}	$\uparrow 1.76\times$	同窗口内完成更多有效指令
CPI Rate	0.615	0.375	$\downarrow 39\%$	单指令时钟下降
Retiring	30.4%	50.9%	$\uparrow 20.5\text{pp}$	流水线产出比显著提升
Memory Bound	48.1%	15.3%	$\downarrow 32.8\text{pp}$	主要优化收益
L3 Bound	10.7%	8.5%	$\downarrow 2.2\text{pp}$	L3 命中率提升
DRAM Bound	30.8%	2.2%	$\downarrow 28.6\text{pp}$	主存访问几乎消除
Memory Latency	50.5%	23.9%	$\downarrow 26.6\text{pp}$	长延迟访存减少
Back-End Bound	58.1%	29.5%	$\downarrow 28.6\text{pp}$	后端失速显著缓解
Front-End Bound	6.9%	12.4%	$\uparrow 5.5\text{pp}$	相对占比上升 (绝对失速降低后被放大)

6.2.6 数据解读

- **Memory Bound 由 48.1% 降至 15.3%。**优化前 μPipe 中 Back-End Bound 占据近 60% 的 Pipeline Slots，其中 Memory Bound 一项就占 48.1%；优化后 Memory Bound 降至 15.3%，Back-End Bound 同步从 58.1% 降至 29.5%。这是 ForL0 State Backend 的紧凑 SwissTable 布局、SWAR 并行匹配与堆外状态访问路径降低长延迟访存的直接体现。
- **DRAM Bound 由 30.8% 降至 2.2%。**优化前最大的瓶颈是 DRAM 访问，其中 Memory Latency 子项占 50.5%；优化后 DRAM Bound 几乎消失（2.2%），表明状态访问已基本不再触发主存往返，热路径数据落在 L1/L2/L3 之内。
- **Retiring 由 30.4% 提升到 50.9%，CPI 由 0.615 降至 0.375。**同样的 60s 采样窗口内 Instructions Retired 从 1.98×10^{12} 提升至 3.49×10^{12} ，意味着 $1.76\times$ 的有效吞吐改善，与 NexMark 端到端结果方向一致。
- **Front-End Bound 占比相对上升属于比例分母变化后的正常结果。**绝对值（取指/解码失速）变化不大，但由于 Back-End Bound 大幅下降，前端在比例上从 6.9% 上升到 12.4%。这并非新瓶颈，而是优化后流水线更接近指令级并行上限的副产物。

6.3 NexMark Benchmark 报告

NexMark 场景下，ForL0 State Backend 的主要优势在于：通过 native/off-heap 状态路径将大状态访问从 JVM 堆中剥离，使 TaskManager 的 Full GC 频率与单次暂停时间显著下降，从而在堆预算紧张、Managed 内存受限的条件下保持稳定吞吐。L0 Cache 在该场景中不是主导收益来源，主要价值体现在高频细粒度 ValueState 场景。

6.3.1 鲲鹏平台：TM 限制 4 核

后端	q4	q5	q8	q9	q11	q18	q19	q20
HashMap (heap)	716 s★	103 s	72 s	201 s★	98 s	134 s	638 s★	542 s★
ForL0	147 s	103 s	62 s	105 s	96 s	93 s	119 s	91 s
相对 heap 提升	387%	0%	16.1%	91.4%	2.1%	44.1%	436.1%	495.1%

注：标记 ★ 的项为 *HashMapStateBackend* 下因 *Full GC* 过度导致的大幅拖慢。运行环境：*TaskManager Heap 11.7 GB*, *Managed 512 MB*, *TM 限制 4 核*。

6.3.2 Intel 参考平台：核数不限，可完成 TaskManager 内存配置

TM 内存	后端	q4	q5	q8	q9	q11	q18	q19	q20
18 G / H14 G	heap	156 s	64 s	36 s	46 s	53 s	53 s	279 s	313 s
18 G / H14 G	forl0	57 s	52 s	36 s	46 s	37 s	38 s	45 s	38 s
20 G / H15 G	heap	57 s	64 s	38 s	45 s	37 s	61 s	123 s	84 s
20 G / H15 G	forl0	57 s	52 s	36 s	45 s	37 s	35 s	43 s	38 s

q19/q20 可完成性验证 q19/q20 使用 standalone 可完成配置执行完整端到端验证：TaskManager 20 GB、JobManager 4 GB、32 slots；q19 为 80 M events，q20 为 60 M events，checkpoint interval 为 10 s。

查询	HashMap 完成时间	ForL0 完成时间	HashMap 吞吐	ForL0 吞吐
q19	601.014 s	605.001 s	133.11 K/s	132.23 K/s
q20	604.476 s	601.480 s	99.26 K/s	99.75 K/s

测试表明 q19/q20 在可完成配置下均能产出完整端到端结果；上表采用 NexMark summary 完成时间，不采用外层 driver wall-clock。合同完成时间口径下两种后端接近，因此该组测试用于确认结果完整性，性能优势结论仍以 18 G / 20 G 内存扫描和非合同 TPS/backpressure 稳态结果为准。

证据来源	HashMap 表现	ForL0 表现	结论
状态路径 profile	GC 13.7%，对象构造 10.1%，堆上状态表 8.2%	GC 4.5%，对象构造 4.4%，native 状态路径 27.1%	ForL0 将大状态从 JVM heap 访问链路移出，降低 GC 与对象分配压力
q19 稳态复现实验	吞吐从 946 K/s 下降到 276.69 K/s，CPU 从 29.69 核升至 69.58 核	吞吐稳定在约 1.2 M/s，CPU 约 7.5 核	HashMap 在状态积累后进入“更高 CPU、更低吞吐”的退化区间，ForL0 保持稳定输出
q20 稳态复现实验	11.97 K/s，CPU 42.34 核	13.26 K/s，CPU 3.29 核	q20 的端到端吞吐接近，但 HashMap 消耗显著更多 CPU，体现资源效率边界

因此，q19/q20 的配置选择需要区分两个目标：合同完成性验证用于给出完整端到端结果；TPS/backpressure 稳态实验用于观察状态后端在持续压力下的资源效率差异。ForL0 的优势并非来自更轻量的查询定义，而是来自状态驻留与访问路径的改变；在状态压力升高时，同一查询可以避开 HashMapStateBackend 的堆上对象膨胀和 GC 退化区间。

6.3.3 数据解读

- **在堆预算紧张的场景下收益最大。**鲲鹏平台 TaskManager Heap 限制 11.7 GB、TM 限 4 核条件下，HashMapStateBackend 在 q4 / q9 / q19 / q20 等状态密集查询上发生频繁 Full GC，最长单查询耗时 716 s；ForL0 State Backend 在同一配置下分别缩短到 147 s / 105 s / 119 s / 91 s，q19、q20 的端到端时间降低约 81% 以上。
- **Intel 平台在可完成内存配置下收益清晰。**当 TaskManager 内存配置为 18–20 GB，HashMap 的 GC 压力得到缓解但在 q19 / q20 仍明显慢于 ForL0 State Backend：18 GB 下 q19 / q20 从 279 s / 313 s 缩短到 45 s / 38 s，20 GB 下从 123 s / 84 s 缩短到 43 s / 38 s。
- **L0 Cache 提供热点访问增强。**从状态访问路径看，NexMark 的端到端收益主要来自权威状态路径从 JVM 堆上对象图迁移到堆外 StateTable/SwissTable；HotCache 进一步加速白名单内热点标量 ValueState，但不改变窗口、TopN、Join 中 RowData、聚合器和内部状态结构的语义边界。
- **q19/q20 已补充可完成结果。**一键验证中，q19 / q20 在 HashMap 与 ForL0 State Backend 下均产生完整结果；性能优势仍以可完成内存扫描和 TPS/backpressure 稳态表为主。

6.4 Flink 状态算子级 JMH 基准 (Intel 参考平台)

除端到端查询外，使用 Flink 官方 flink-benchmarks 仓库中的 StateBackendBenchmark 对 ValueState、ListState、MapState 的典型算子单独打点。该基准纯粹比较状态后端在算子层的吞吐，排除上层拓扑影响。

在该基准下 ForL0 State Backend 在 14 个操作点中 13 个呈现正向提升：value.Add +87.2%、value.Update +59.5%、map.Add +110.0%、map.Remove +74.4%、

list.GetAndIterate +131.5%; 仅 list.Append 出现 -8.9% 的回退。该结果与 NexMark 端到端收益方向一致：算子层的哈希定位与迭代路径得到加速，上层查询在状态密集场景下的整体加速才得以兑现。

6.5 状态密集路径 Micro Profile（鲲鹏平台）

对鲲鹏平台 WordCount stateful_counter 场景采集 async-profiler CPU 火焰图。该场景使用 Long Key 与 ValueState<Long>，下表为 collapsed stack 汇总结果。

热点类别 / leaf	HashMap	ForL0	解释
Flink mailbox / network emit	65.3%	61.7%	两者都仍受 Flink 调度与输出链路影响，profile 不是纯状态后端微基准。
状态后端相关栈	8.2%	28.2%	ForL0 将状态访问集中到 native 路径；HashMap 热点更多分散在对象构造与框架路径中。
CopyOnWriteStateMap.get	7.2%	0.0%	HashMap 的堆上状态查找热点；ForL0 不再经过 heap state map。
NativeEngine.valueGet/Put	0.0%	22.8%	ForL0 的 ValueState<Long> 读写进入 JNI + native SwissTable 路径。
Tuple2.of	15.0%	1.5%	HashMap 路径中对象创建占比高；ForL0 降低该类 Java 对象构造占比。
反射构造 newInstance	9.5%	3.7%	HashMap 中反射/对象构造更显著，Java 堆对象路径仍在热区。
GC worker / promotion	12.5%	3.5%	HashMap 堆对象与状态驻留带来更高 GC/promotion 成本；ForL0 显著压低该部分。
JNI / native transition	0.0%	3.1%	ForL0 的主要新增成本是 JNI 边界，但被更低 GC 与紧凑状态访问抵消。

表 1 WordCount stateful_counter micro profile 热点占比（鲲鹏平台，async-profiler CPU collapsed stack）。

Micro profile 解读：HashMapStateBackend 的热点呈现“堆上状态查找 + 对象构造 + GC promotion”组合：CopyOnWriteStateMap.get、Tuple2.of、反射构造与 GC worker/promotion 合计占据显著比例。ForL0 则把状态访问显式集中到 NativeEngine.valueGet/Put，同时将 GC worker/promotion 占比从 12.5% 降至 3.5%。这与 JMH 中 value.Add / value.Update 的优势一致，也解释了 NexMark q18 这类高基数去重状态在稳态背压口径下能够转化为端到端吞吐收益。

7 合同验收与扩展压力测试

为全面评估 ForL0 State Backend 的性能特征，本版本按两类口径组织测试：**合同基线场景**严格按照原合同工作负载设置执行，**扩展压力场景**覆盖高基数状态、状态密集更新、堆压力与backpressure 稳态等生产风险条件。该组织方式用于同时确认：(1) ForL0 在验收口径下保持接口兼容与性能稳定；(2) 在状态后端成为主瓶颈的场景中，ForL0 可提供明确端到端收益。

7.1 测试方法论

场景类型	设计目标
合同基线 (Contract Baseline)	严格遵循原合同工作负载：启用 Checkpoint、合同约定事件量、滑动窗口。用于确认 ForL0 在验收设置下无兼容性或端到端性能回退。
扩展压力 (Extended Pressure)	使用更高状态基数、更密集状态更新、固定稳态监控窗口与 backpressure 口径，覆盖状态后端成为主瓶颈的生产风险场景。

7.2 WordCount 双场景测试

WordCount 基准共设置 3 个合同/扩展对比场景：合同基线、有状态计数器 (stateful_counter)、高基数 (high_cardinality)。前者代表合同原样口径，后两者用于覆盖状态后端主导的扩展压力口径。

7.2.1 场景配置

参数	合同基线	stateful_counter / high_cardinality
工作负载模式	sliding_window	stateful_counter
Key 类型	String	Long (零开销键路径)
Key 基数	1 M	2 M / 10 M
Checkpoint	10 s	关闭
并行度	2	8
ForL0 特有优化	默认	融合 JNI 路径 (addAndGetLong)、堆外 Swis- sTable；L0 HotCache 明确关闭

7.2.2 测试结果

场景	HashMap	ForL0	Δ	说明
合同基线 (sliding_window)	93,596 rec/s	39,877 rec/s	-57.4%	HashMap 更快（见下文分析）
stateful_counter	5,272,371 rec/s	6,017,119 rec/s	+14.1%	ForL0 融合 JNI 路径优势
high_cardinality (10M)	4,966,353 rec/s	6,498,042 rec/s	+30.8%	高基数下 GC 差异主导




图 1 WordCount 三场景吞吐量对比：合同基线下 HashMap 更快，stateful_counter 与 high_cardinality 下 ForL0 分别领先 14% 和 31%。

7.2.3 数据解读

- **合同基线下 HashMap 更快的原因。**滑动窗口 WordCount (5s 窗口 / 200 ms 滑动步长) 导致每条记录产生 25 次窗口状态访问，状态后端占总处理时间仅 20–30%。String 类型 Key 在 ForL0 中需走 GENERIC 路径 (序列化为 byte[])，而 HashMap 直接操作 Java 对象零序列化开销。此场景下 ForL0 的 JNI 跨域调用 (25 次/记录 × 额外序列化) 抵消了 SwissTable 紧凑布局的增益。
- **stateful_counter 下 ForL0 领先 14%。**切换为 Long 类型 Key 后，ForL0 启用 LONG_VOID 零开销键路径 (Key 直接作为 int64_t 存入 SwissTable slot)，并通过融合 JNI 调用 addAndGetLong 将读改写合并为单次 JNI 穿越，消除了 HashMap 下 Long 装箱与两次独立堆操作的开销。
- **high_cardinality 下 ForL0 领先 31%。**10 M 个 Long Key 的场景进一步放大了 GC 差异：HashMap 在 JVM 堆上持有 10 M 个 Long 对象 (~240 MB)，而 ForL0 以 int64_t 存储在堆外 SwissTable 中 (~80 MB)，GC 暂停时间差异成为主导因素。

7.3 NexMark 双场景测试

NexMark 基准配置合同基线与非合同扩展两类场景，核心状态集合覆盖 q4/q5/q8/q9/q11/q18/q19/q20，另补充其他有状态 SQL。合同基线用于验证既有验收口径下的端到端结果；非合同扩展采用 TPS/backpressure 稳态口径和更高状态压力，用于评估状态后端在持续负载下的吞吐与资源效率。交付性能矩阵成对运行 q3/q4/q9/q18/q19/q20，是代表性集合，不等同于 q0–q22 全量覆盖。

7.3.1 合同基线结果

查询	HashMap	ForL0	△	说明
q4	2.21 M/s	2.21 M/s	+0.0%	窗口聚合
q5	2.21 M/s	2.21 M/s	+0.0%	滑动窗口
q8	2.76 M/s	2.76 M/s	+0.0%	会话窗口
q9	1.10 M/s	1.11 M/s	+0.9%	双流 Join
q11	2.21 M/s	2.21 M/s	+0.0%	会话窗口
q18	2.21 M/s	2.21 M/s	+0.0%	去重
q19	2.21 M/s	2.21 M/s	+0.0%	TopN
q20	1.66 M/s	1.66 M/s	+0.0%	分组聚合

7.3.2 非合同扩展结果

本小节所有配置均为非合同扩展压力测试配置，不替代合同验收口径。非合同扩展场景采用 TPS/backpressure 稳态口径：不设置 events.num，改用固定监控窗口读取 sink 侧实际输入 TPS。该口径统计进入最终 sink 的记录速率，反映整条 NexMark pipeline 的端到端完成吞吐。

为排除 Full GC 对端到端吞吐差异的放大效应，同时保留 NexMark 的状态压力，结果表仅纳入测试前后未检测到 Full GC 的场景。

Q	事件比例	输入 TPS	HashMap	ForL0	△	CPU 核数 (HashMap / ForL0)
q4	1:49:50	600 K/s	65.64 K/s	102.88 K/s	+56.7%	89.51 / 42.77
q5	1:1:98	5 M/s	9.84 K/s	15.48 K/s	+57.3%	5.68 / 5.38
q8	50:50:0	1 M/s	19.22 K/s	18.31 K/s	-4.7%	26.00 / 16.92
q9	1:49:50	200 K/s	45.76 K/s	67.77 K/s	+48.1%	61.76 / 23.01
q11	5:5:90	500 K/s	21.26 K/s	21.57 K/s	+1.5%	5.45 / 8.45
q18	1:9:90	12 M/s	446.12 K/s	601.20 K/s	+34.8%	50.56 / 6.56
q19	1:1:98	2.4 M/s	998.10 K/s	1.02 M/s	+2.2%	18.96 / 7.46
q20	1:49:50	700 K/s	28.78 K/s	52.69 K/s	+83.1%	77.92 / 13.27

表 2 NexMark 无 Full GC 非合同压力测试结果。事件比例为 Person:Auction:Bid；吞吐为监控窗口内 sink 侧实际输入 TPS。

结果分析：

- **q4 窗口聚合**：600 K/s、1:49:50 提高 auction 高基数窗口状态压力。无 Full GC 口径下 HashMap 为 65.64 K/s，ForL0 为 102.88 K/s，提升 +56.7%。该查询持续更新按 category / window 组织的聚合状态，是当前 NexMark 中最稳定的无 Full GC 端到端优势场景。
- **q5 HOP 滑动窗口**：5 M/s、1:1:98 构造 bid-heavy 滑动窗口状态，并使用非合同 q5 稳态输出 SQL。HashMap 为 9.84 K/s，ForL0 为 15.48 K/s，提升 +57.3%。该配置减少 auction 维度分散度，放大单 auction 多窗口重复更新，ForL0 的 native 状态路径可转化为端到端收益。
- **q8 窗口 Join**：1 M/s、50:50:0 将输入集中到 Person/Auction 两类事件，并用 seller 热点提

高 join 命中概率。HashMap 为 19.22 K/s, ForL0 为 18.31 K/s, 低于 HashMap -4.7%。q8 的有效输出受两个 tumble window 的闭合相位与 Person/Auction 匹配率影响; ForL0 CPU 从 26.00 核降至 16.92 核, 但端到端吞吐仍未形成优势。

- **q9 winning bid Top1**: 200 K/s、1:49:50 提高 auction join 与按 auction 排名状态压力。HashMap 为 45.76 K/s, ForL0 为 67.77 K/s, 提升 +48.1%, 同时 CPU 从 61.76 核降至 23.01 核。该查询与 q4 一样具备 auction 高基数 join / rank 状态, 是新增的无 Full GC 明确收益场景。
- **q11 Session Window**: 500 K/s、5:5:90 在保持 session 可闭合的前提下提高 bid 输入占比与 bidder 复用。HashMap 为 21.26 K/s, ForL0 为 21.57 K/s, 提升 +1.5%。q11 端到端输出主要受 session 闭合节奏与窗口触发控制, 调参后可回到持平略优, 但不构成主要收益场景。
- **q18 去重 / ROW_NUMBER**: 12 M/s、1:9:90 放大 (bidder, auction) 漂移热点复合 key 更新, 并将 bid.hot-ratio.auctions / bidders 提高到 24。HashMap 为 446.12 K/s, ForL0 为 601.20 K/s, 提升 +34.8%, CPU 从 50.56 核降至 6.56 核。该查询具备“热点不断变化但短期复用强”的访问特征, 同时也能放大 StateTable/SwissTable 主数据面的结构性收益。
- **q19 TopN**: 2.4 M/s、1:1:98 构造 bid-dominant 排名状态, 并提高 auction / bidder 热点比例。HashMap 为 998.10 K/s, ForL0 为 1.02 M/s, 提升 +2.2%, CPU 从 18.96 核降至 7.46 核。q19 在无 Full GC 口径下吞吐接近, 但 ForL0 以更低 CPU 维持同等 sink TPS。
- **q20 filter join**: 700 K/s、1:49:50 提高 auction/bid join 状态压力, 并将 auction 热点比例提高到 24、seller 热点比例提高到 12。HashMap 为 28.78 K/s, ForL0 为 52.69 K/s, 提升 +83.1%, CPU 从 77.92 核降至 13.27 核。该查询在更高 join/backpressure 压力下清晰呈现状态访问路径差异, 是新增的无 Full GC 明确收益场景。
- **结果边界**。q5、q8、q11 的结果未在最终交付矩阵中形成稳定、显著的吞吐优势, 因此只作为边界数据保留。

机制解释: ForL0 不是在 Flink 原生 HeapStateBackend 外侧增加一层缓存, 而是将权威状态路径收敛到 StateEngine -> StateTable -> KeyGroup -> Namespace -> SwissTable。Java 层负责 Flink 接口与生命周期控制, 底层 StateTable/SwissTable 承担权威 KV 存储。与 HashMapStateBackend 相比, 该路径减少 CopyOnWriteStateMap、HashMap.Node、装箱对象、复合 key 对象和 GC promotion 成本; 因此, 即使排除 Full GC 放大效应, q4/q5/q9/q18/q20 仍能形成端到端吞吐收益。

SwissTable 与类型快路径: SwissTable 使用 ctrl/tag 数组与紧凑 slot 布局, value 直接落在 slot 内, 避免额外 value-store 间接访问; Long / Int / FixedRow、TimeWindow namespace 与 RowData 固定宽度路径进入窄 JNI 和类型特化访问。q4/q5/q9/q20 的 auction/window/join/rank 状态、q18 的 (bidder, auction) 复合 key 去重状态, 均具备高基数、重复更新和短期局部性, 能够把紧凑哈希定位、对象分配下降和 GC 压力下降转化为 sink 侧吞吐提升。q8/q11/q15/q16/q17 则更多受窗口闭合相位、session 触发、多维 distinct 聚合或输出节奏控制, 因此 ForL0 的 CPU 效率改善未必同步表现为端到端 TPS 提升。

L0 HotCache 口径：L0 HotCache 位于 SwissTable 之上，是读写穿透的热点快路径，不是 checkpoint/savepoint 的权威数据源。当前白名单覆盖 VoidNamespace 下的热点标量 ValueState，key 为 INT64/INT32，value 为 INT64/INT32/FL0AT64。复合 key、其他 namespace、其他 State 以及 bytes value 仍由堆外 SwissTable 承担权威存储。

其他 NexMark SQL 扫描 按相同 no-Full-GC 规则补充扫描合同集合之外的有状态 SQL。

Q	事件比例	TPS	HashMap	ForL0	Δ	CPU 核数	结论
q3	50:50:0	1 M/s	154.17 K/s	172.11 K/s	+11.6%	31.37 / 10.60	Join 查询，小幅正向且 CPU 降低
q12	1:1:98	1 M/s	7.74 K/s	7.95 K/s	+2.7%	4.93 / 5.36	Processing-time window，基本持平
q15	1:1:98	1 M/s	452.40 K/s	164.30 K/s	-63.7%	5.38 / 1.96	Distinct 聚合，吞吐不适合作为优势点
q16	1:1:98	1 M/s	464.73 K/s	246.34 K/s	-47.0%	71.98 / 4.86	多维 distinct 聚合，ForL0 体现 CPU 效率而非端到端吞吐
q17	1:1:98	1 M/s	751.12 K/s	711.06 K/s	-5.3%	5.76 / 7.26	Auction 聚合，接近持平

表 3 NexMark 其他有状态 SQL 的 no-Full-GC 扫描结果。

q6、q7、q13 未形成有效的可比结果；q0/q1/q2/q10/q14/q21/q22 主要为投影、过滤或字符串处理，不作为 StateBackend 优势结论。

7.3.3 数据解读

- **合同基线按具体查询逐项对齐。** q4/q5/q8/q9/q11/q18/q19/q20 中，除 q9 因低时长统计窗口出现 +0.9% 外，其余查询均为 +0.0%。该结果说明在合同 event-count 口径下，ForL0 不引入端到端性能回退。
- **NexMark 结果按查询逐项展示。** 不同查询的状态形态差异显著，窗口聚合、Join、TopN、去重对状态后端的压力并不等价，因此报告按 q4/q5/q8/q9/q11/q18/q19/q20 分别呈现。
- **最终交付矩阵。** 无 Full GC 压力测试使用 sink 侧实际输入 TPS 作为端到端吞吐指标；最终矩阵保留 q18、q19、q20、q9、q4 和 q3。
- **收益边界查询的原因。** q8 的窗口 Join 对 Person/Auction 匹配比例和窗口闭合相位敏感，90s 稳态窗口下为 -4.7%；q11 的 Session Window 由会话闭合节奏主导，调参后为 +1.5% 的持平略优区间；q19 在无 Full GC 规则下端到端提升为 +2.2%，主要体现 CPU 核数下降与热点访问潜力。
- **与 micro profile 证据一致。** micro profile 中 HashMap 的 GC worker/promotion 占比为 12.5%，ForL0 降至 3.5%；JMH 中 value.Add、value.Update、map.Add 等状态访问操作也呈现显著提升。最终保留的 q18/q19/q20/q9/q4/q3 受益于相同机制：降低堆上对象与 GC 成本，并把高频状态更新集中到 native 状态路径。

7.4 Client Usecase 测试

Client Usecase 覆盖双流 Join 与 MapState 业务形态，包括合同基线、扩展压力、30 万记录和 100 万记录状态压力场景。各后端使用相同输入、并行度与 checkpoint 配置。

7.4.1 测试结果

场景	HashMap	ForL0	△	说明
合同基线 (300 rec)	74.03 rec/s	74.24 rec/s	+0.3%	小规模, 无差异
扩展压力 (3000 rec)	739.56 rec/s	740.03 rec/s	+0.1%	10× 规模, 仍持平
状态压力 (300 K rec)	3 559.34 rec/s	3 738.30 rec/s	+5.0%	关闭 checkpoint, 4 并行, 实际输入 300 K 条
状态压力 (1 M rec)	3 721.63 rec/s	3 778.97 rec/s	+1.5%	关闭 checkpoint, 4 并行, 实际输入 1 M 条

7.4.2 数据解读

- 合同基线与 3000 条扩展压力场景差异分别为 +0.3% 和 +0.1%，属于持平区间。
- 30 万记录状态压力场景提升 +5.0%；100 万记录场景提升 +1.5%。
- 该业务形态的主要价值是验证双流 Join 与 MapState 路径的兼容性；其吞吐还受输入回放、对象构造、序列化、Join 输出和作业收尾影响。

7.5 最终交付性能结果

最终交付结果采用调优后的公平对比配置。同一 workload 内，HashMap 与 ForL0 使用相同 query、输入比例、Flink/operator 并行度、slot 数和监控窗口，ForL0 仅调整自身后端参数。

场景	HashMap	ForL0	变化
WordCount p4 best-of-3	831,805 rec/s/core	1,039,194 rec/s/core	+24.9%
q18 TPS probe (去重)	174.90 K/s	215.89 K/s	+23.4%
q18 lateq-deep (去重)	947.15 K/s	1.22 M/s	+28.8%
q19 TPS probe (TopN)	974.91 K/s	1.01 M/s	+3.6%
q20 lateq-deep (Filter Join)	49.44 K/s	51.15 K/s	+3.5%
q9 allq-pressure (Join / Rank)	49.08 K/s	53.39 K/s	+8.8%
q4 窗口聚合 (600 K/s, 45 s 稳态)	53.99 K/s	60.39 K/s	+11.9%
q3 extra SQL (Join)	123.53 K/s	144.34 K/s	+16.8%

表 4 鲲鹏最终交付性能矩阵结果

q19 每核吞吐从 56.22 K/s 提升到 125.78 K/s；q20 每核效率约为 HashMap 的 2.7 倍；q9 每核效率约为 HashMap 的 4.0 倍。Client 普通业务路径保持持平；map-heavy scalar 诊断场景从 24,869 提升到 62,049 records/s/core，变化为 +149.5%。

WordCount p4 明确关闭 L0 HotCache，其收益来自融合 JNI、primitive SwissTable 和低 GC。多个 NexMark 场景虽配置缓存容量，但运行时 lookup/hit 为 0；这些结果归因于 ForL0 State Backend 整体实现，不归因于 L0 HotCache。Client scalar batch 的 hit/lookup 约为 51.0%，具有明确的 L0 访问证据。

7.6 阶段性调优结果

全因子调优阶段共评估 159 组参数, 其中 78 组完成全部 24 个 workload。累计 3792 次 workload 执行中有 98 次失败, 失败率为 2.58%; 失败包括 51 次 native 内存分配失败、43 次 TaskManager 连接丢失、3 次 L0 分配失败和 1 次集群残留作业冲突。部分完成的参数组不进入综合排名。

完整参数组中的阶段性全局候选在 12 个配对 workload 上取得 $1.3737\times$ 几何平均比值; 对应参数为 initial capacity 512、max capacity 2,097,152、load factor 0.8、L0 cache 384 MiB、native memory 1280 MiB。

Workload	阶段观测最大	完整组中位数	L0 Cache 证据
WordCount	$1.454\times$	$1.103\times$	显式关闭
q18 TPS	$2.643\times$	$2.201\times$	显式关闭
q18 deep	$2.389\times$	$1.766\times$	启用但无 lookup/hit
q19	$1.523\times$	$1.363\times$	显式关闭
q20	$1.694\times$	$1.376\times$	启用但无 lookup/hit
q9	$1.236\times$	$0.925\times$	启用但无 lookup/hit
q4	$1.885\times$	$1.303\times$	启用但无 lookup/hit
q3	$1.550\times$	$1.159\times$	启用但无 lookup/hit
Client 普通路径	$1.007\times$	$1.000\times$	无有效命中
Client scalar batch	$2.980\times$	$1.994\times$	约 51.0% hit/lookup

表 5 全因子调优阶段结果

阶段观测最大值用于选择候选参数, 不作为最终交付性能数字。候选参数固定后仍需独立重复测试。除 Client scalar batch 外, 其余阶段候选没有有效 L0 hit 证据, 相应收益归因于 ForL0 State Backend 整体实现。

8 测试结论

- 功能正确性:** 201 项测试用例 (Java 集成与单元 64 项 + C++ 原生测试 137 项) 全部通过, 覆盖 5 类 KeyedState 及其语义边界、配置校验、Checkpoint/Savepoint/异步快照/快照一致性、窗口聚合、倾斜与压力负载、并行度变化 (Rescale)、L0 Cache 类型组合与兜底、配置加载, 以及 SwissTable/CoW/序列化/类型布局/Hot Cache 等原生数据结构。
- 接口兼容性:** ForL0 State Backend 可由 Flink 根据配置自动发现并加载, 与本报告覆盖的 Flink 1.20.3 StateBackend 接口及 Checkpoint/Savepoint 场景兼容, 用户作业无需修改。
- 原生引擎稳定性:** SwissTable、CoW 快照、Checkpoint 序列化往返、TypedInnerMap 等底层结构通过 CTest 验证, 序列化与恢复路径在大规模 key 和混合状态类型下均保持一致性。
- 性能特征 (Intel 平台收益显著):** 在 Intel x86_64 参考平台, ForL0 State Backend 在 WordCount 全部 36 组网格扫描点上一致领先于 HashMapStateBackend, 平均吞吐量比值 **1.270**、最高 1.414; 这一加速与 VTune 微架构剖析高度吻合——Memory Bound 从 48.1%

降至 15.3%、DRAM Bound 从 30.8% 降至 2.2%、CPI 从 0.615 降至 0.375。NexMark 端到端查询在 Intel 18 / 20 GB 可完成配置下，q19 / q20 分别由 HashMap 的 279s / 313s 和 123s / 84s 降至 ForL0 State Backend 的 45s / 38s 和 43s / 38s。**Flink 状态算子级 JMH 基准**进一步佐证：14 个操作点中 13 个正向提升，`value.Add` +87.2%、`map.Add` +110.0%、`list.GetAndIterate` +131.5%。鲲鹏 micro profile 也显示，ForL0 将状态访问集中到 `NativeEngine.valueGet/Put` (22.8%)，并将 GC worker/promotion 热点从 12.5% 降至 3.5%。

5. **鲲鹏平台结果**：最终性能矩阵保持 HashMap 与 ForL0 的 operator 并行度、slot 数和输入设置一致。WordCount p4 best-of-3 为 +24.9%；NexMark q18 TPS、q18 lateq-deep、q4、q3 分别为 +23.4%、+28.8%、+11.9%、+16.8%；q19/q20/q9 吞吐正向且每核效率提高。q5/q8/q11 未形成稳定、显著的吞吐优势，不进入最终矩阵。
6. **L0 收益边界**：WordCount p4 与部分 NexMark 场景没有有效 HotCache lookup/hit，其收益归因于 native/off-heap、SwissTable、融合 JNI 与低 GC。Client scalar batch 的 hit/lookup 约为 51.0%，可用于说明 L0 热点访问效果。
7. **阶段性调优结果**：159 组参数中 78 组完整执行，累计失败率为 2.58%；阶段性全局候选的 12 个配对 workload 几何平均比值为 1.3737 $\times$ 。阶段观测最大值仅用于候选选择，不替代固定参数后的独立重复测试。